


Quantification en commande

De la dimension finie aux équations aux dérivées partielles

Un cours progressif, du novice au chercheur



Florent Koudohode

18 janvier 2026

Conçu pour être lu sans prérequis avancé, puis relu comme un manuel de recherche.

Avant-propos

Un capteur numérique ne transmet pas un nombre réel. Il transmet un symbole choisi dans une liste finie, sur huit, douze ou seize bits. Un actionneur commandé par bus ne reçoit pas non plus un réel. Entre le monde continu que décrivent nos équations et le monde fini que manipulent nos machines, il y a une opération d'arrondi, la *quantification*, et cette opération n'est pas innocente : elle peut détruire la stabilité d'une boucle par ailleurs parfaitement conçue.

Ce document raconte comment on répare cela. Il part d'un thermostat domestique et arrive, sans saut, à la stabilisation d'équations aux dérivées partielles hyperboliques dont les mesures et la commande sont quantifiées. Le fil conducteur tient en une phrase.

Avec une résolution fixe, on ne peut pas stabiliser asymptotiquement. Mais si l'on autorise le contrôleur à changer d'échelle au cours du temps, en élargissant d'abord la portée pour retrouver l'état, puis en affinant la résolution pour le ramener à l'origine, alors la stabilité asymptotique globale redevient possible. Tout le cours consiste à rendre cette phrase quantitative, puis à la transporter en dimension infinie.

Pour qui ? Trois lecteurs ont été gardés en tête simultanément.

- **L'étudiant ou le curieux venu d'une autre discipline.** Le chapitre 1 et le début du chapitre 2 ne demandent que de l'algèbre linéaire et des équations différentielles de base. Aucune connaissance préalable de l'automatique n'est supposée : les notions de boucle fermée, de fonction de Lyapunov et de stabilité entrée-état sont introduites au moment où elles servent. Les encadrés « Intuition » et « En pratique » lui sont destinés.
- **L'ingénieur.** Les encadrés « Recette », les tables de dimensionnement et l'exemple numérique complet de la section 2.4 donnent de quoi implémenter réellement une boucle quantifiée, et surtout de quoi diagnostiquer ce qui ne marche pas. Tous les chiffres sont recalculés par les codes du dépôt compagnon.
- **Le futur chercheur.** Le chapitre 3 et l'annexe A suivent la ligne de démonstration des articles de référence du domaine, avec les constantes explicites, mais rédigées de façon auto-contenue. La section B.4 liste des questions réellement ouvertes, avec ce qui bloque dans chacune.

Comment lire ce document ? Il n'est pas nécessaire de tout lire dans l'ordre, et trois parcours sont proposés sur la figure 1. Les sections marquées d'une étoile [★] peuvent être sautées en première lecture sans rien perdre du fil.

Sur les sources. Le domaine a une histoire courte et bien identifiée, et j'ai tenu à ce que chaque affirmation renvoie à un endroit précis de la littérature. Les notes de bas de page sont réservées aux points où le lecteur a intérêt à aller voir la source lui-même ; le reste est en bibliographie. La partie en dimension finie suit la lignée ouverte par [4] et [6], dont on a repris la *méthode de démonstration*, quitte à en détailler chaque étape ; la section 3.2 suit [24] ; la section 3.3 suit

[26]. Les codes qui produisent toutes les figures numériques sont en accès libre (annexe F), et les illustrations empruntées sont créditées en légende puis récapitulées à l'annexe G.




FIGURE 1 : Trois parcours de lecture possibles.

Table des matières

Avant-propos	i
Notations et conventions	vi
1 Le monde est continu, la machine ne l'est pas	1
1.1 Trois histoires pour commencer	1
1.2 Une brève histoire du problème	3
1.3 Des applications documentées	5
1.4 Où la quantification apparaît dans une boucle	5
1.5 Ce que la quantification n'est pas	6
1.6 Le fil rouge : l'analogie de l'appareil photo	7
1.7 Le quantificateur : définition, propriétés, exemples	9
1.7.1 Définition	9
1.7.2 Les deux paramètres qui gouvernent tout : M et Δ	9
1.7.3 Catalogue d'exemples	10
1.7.4 La famille à zoom q_μ	14
1.7.5 Une subtilité de régularité $[\star]$	14
1.7.6 Exercices	16
1.8 Ce que la quantification fait à une boucle fermée	16
1.8.1 Un exemple que l'on peut faire à la main	16
1.8.2 Pourquoi aucune loi statique ne peut faire mieux	17
1.8.3 Voir les trois régimes	18
1.8.4 Trois messages à emporter	19
1.9 Feuille de route	19
2 La quantification en dimension finie	21
2.1 Boîte à outils : Lyapunov, ISS, comparaison	21
2.1.1 Lyapunov quadratique pour un système linéaire	21
2.1.2 Stabilité entrée-état	22
2.1.3 Lemme de comparaison et Grönwall	22
2.2 Retour d'état quantifié à zoom figé : stabilité pratique	23
2.2.1 Le modèle et la loi de commande	23
2.2.2 Décroissance de V hors saturation	23
2.2.3 Les deux ellipsoïdes emboîtés	24
2.2.4 Invariance et contraction en temps <i>explicitement</i> borné	25
2.2.5 Corollaire : stabilité pratique à μ figé	27
2.3 La stratégie hybride : stabilité asymptotique globale	28
2.3.1 Vue d'ensemble	28
2.3.2 L'événement de capture est-il détectable ?	28
2.3.3 Phase 1 : capture en temps fini	29
2.3.4 Théorème principal en dimension finie	30

2.3.5	Recette de dimensionnement	30
2.4	Exemple numérique complet	31
2.5	Variantes : entrée quantifiée, sortie quantifiée, secteur	35
2.5.1	Quantification de l'entrée	35
2.5.2	Quantification de sortie et observateur	36
2.5.3	L'autre école : quantificateur logarithmique et condition de secteur	37
3	Quantification pour les EDP : cas hyperbolique	39
3.1	Le cadre en une page	39
3.2	Stabilisation frontière sous quantification, d'après Bekiaris-Liberis	40
3.2.1	La loi hybride sous quantification des mesures	41
3.2.2	Le théorème de stabilité et sa preuve	43
3.2.3	Quantification de l'entrée	47
3.2.4	Simulation de l'EDP quantifiée	48
3.3	Retard d'entrée et quantification simultanés, d'après Koudohode et Bekiaris-Liberis	52
3.3.1	Un retard d'entrée <i>est</i> une EDP de transport	53
3.3.2	Quantificateur dynamique et commande commutée	55
3.3.3	Le théorème principal et sa démonstration	58
3.3.4	Variante : entrée quantifiée, retard connu	62
3.3.5	Simulation du système à retard quantifié	64
A	Boîte à outils pour la dimension infinie	68
A.1	L'EDP de transport : tout ce qu'il faut savoir	68
A.1.1	Le modèle et sa solution explicite	68
A.1.2	L'espace d'état L^∞ et pourquoi ce choix	69
A.1.3	Le modèle « strict-feedback »	69
A.2	Backstepping frontière : construire le système cible	70
A.2.1	L'idée en une phrase	70
A.2.2	La transformation de Volterra	70
A.2.3	Les équations du noyau	71
A.2.4	Le cas explicite $\bar{g} \equiv 0$, g constante	71
A.2.5	Contrôleur nominal et système cible	72
A.2.6	Vérification numérique	72
A.2.7	Équivalence des normes : les constantes M_1, M_2, M_3	74
A.3	ISS, mémoire évanescence et petit gain	74
A.3.1	Le schéma général de l'analyse	75
A.3.2	Normes pondérées	75
A.3.3	ISS de l'EDP de transport en norme sup	75
A.3.4	ISS de l'EDO en norme pondérée	76
A.3.5	Le lemme de mémoire évanescence $[\star]$	76
A.3.6	Le lemme de petit gain	77
A.4	Le pont : EDP de transport et équations à retard	77
A.4.1	Une EDP de transport <i>est</i> un retard	77
A.4.2	L'équation intégrale à retard associée	78
B	Pour aller plus loin	79
B.1	Quantification de la sortie : observateurs	79
B.1.1	Le problème	79
B.1.2	L'observateur backstepping	79
B.1.3	La stratégie à trois phases	80
B.2	Systèmes hyperboliques 2×2 et commande événementielle	81
B.2.1	Pourquoi deux équations plutôt qu'une	81

B.2.2	Deux ressources, deux leviers	81
B.2.3	Entrée quantifiée et commande événementielle	81
B.2.4	Sortie quantifiée : observateur et résultat semi-global	83
B.2.5	Ce que ces deux travaux apprennent au praticien	85
B.3	Robustesse : ce qui casse en vrai	85
B.3.1	Le zoom infini n'existe pas	85
B.3.2	Échantillonnage : quantifier n'est pas discrétiser	86
B.3.3	Retard incertain	86
B.3.4	Pertes de paquets et canal non idéal	87
B.4	Ce qui est fait, ce qui reste à faire	87
B.4.1	L'état des lieux en une page	87
B.4.2	Problème 1 : le caractère bien posé sous quantification exacte	88
B.4.3	Problème 2 : le débit minimal pour une EDP	88
B.4.4	Problème 3 : réduire le conservatisme	89
B.4.5	Problème 4 : au-delà du transport linéaire	89
B.4.6	Problème 5 : identification et quantification	89
B.4.7	Problème 6 : valider expérimentalement	90
B.5	Programme de travail	90
B.5.1	Lectures graduées	90
B.5.2	Six mini-projets	91
B.5.3	Comment lire un article de ce domaine	91
B.6	Combien de bits faut-il ? Le théorème du débit minimal	91
B.6.1	L'intuition du volume	92
B.6.2	Le cas bruité, et ce que change le codage	93
B.6.3	Ce que consomme notre schéma	93
C	Rappels d'analyse	95
C.1	Inégalité de Grönwall	95
C.2	Normes et conditionnement	95
C.3	Semi-groupes et estimation exponentielle	95
C.4	Opérateurs de Volterra	95
C.5	ISS : définitions	95
C.6	Normes pondérées : le seul truc à retenir	96
D	Corrigés des exercices	97
E	Glossaire français-anglais	105
F	Codes et reproductibilité	106
F.1	Le dépôt compagnon	106
F.2	Les codes MATLAB des articles	107
F.3	Structure commune des programmes	107
G	Crédits des illustrations	109
G.1	Photographies et schémas sous licence Creative Commons	109
G.2	Figures reprises d'articles	110
	Bibliographie	111

Notations et conventions

Toutes les notations sont regroupées ici une fois pour toutes ; on a volontairement harmonisé les symboles des trois cadres étudiés.

Symbole	Signification
$\mathbb{R}, \mathbb{R}_+$	réels, réels positifs
$ \cdot $	valeur absolue, ou norme euclidienne d'un vecteur de $\mathbb{R}^n$
$\ f\ _\infty$	ess sup $_{x \in [0, D]}$ $ f(x) $, norme sup spatiale
$\ (X, u)\ $	$ X + \ u\ _\infty$, norme de l'espace d'état $\mathbb{R}^n \times L^\infty$
$\lambda_{\min}(P), \lambda_{\max}(P)$	plus petite / plus grande valeur propre de $P = P^\top$
q	quantificateur « statique », $q : \mathbb{R}^\ell \rightarrow \mathcal{Q}$
M	<i>seuil de saturation</i> (portée) du quantificateur
Δ	<i>borne d'erreur</i> (résolution) hors saturation
$\widehat{M}$	rayon de la zone morte (propriété (P3))
$\mu > 0$	<i>variable de zoom</i> ; $q_\mu(z) = \mu q(z/\mu)$
μ_0, τ, T, Ω	zoom initial, pas de la phase 1, temps de séjour, facteur de contraction
$\lambda, \nu, \varepsilon, \delta$	paramètres de réglage (marges) des preuves
t_1^*	instant de <i>capture</i> (fin de la phase « dézoomer »)
A, B, K	matrices de l'EDO, gain de retour d'état, $A + BK$ Hurwitz
P, Q	matrices de Lyapunov, $(A + BK)^\top P + P(A + BK) = -Q$
D	longueur du domaine spatial, ou retard d'entrée (c'est la même chose !)
$u(x, t)$	état de l'EDP de transport, $x \in [0, D]$
$U(t)$	commande appliquée à la frontière $x = D$
$U_{\text{nom}}(t)$	commande nominale (non quantifiée)
$w(x, t)$	état transformé (backstepping), système cible
$k(x, y), \ell(x, y)$	noyaux direct et inverse de la transformation de Volterra
M_1, M_2	constantes d'équivalence de normes : $M_2 \ (X, u)\ \leq \ (X, w)\ \leq M_1 \ (X, u)\ $
M_3	gain du contrôleur nominal vis-à-vis de l'état
M_0	constante d' <i>overshoot</i> issue de la fermeture petit gain
ϑ	marge sans dimension $\in (0, 1]$ utilisée dans l'événement de capture
$d(t)$	perturbation frontière engendrée par la quantification
e_q	erreur de quantification, $e_q = q_\mu(\cdot) - (\cdot)$
ISS	<i>Input-to-State Stability</i> (stabilité entrée-état)

Conventions.

- On écrit indifféremment $u(x, t)$ (convention EDP) ou $u(t, x)$; dans tout ce document on fixe $u(x, t)$, la variable d'espace en premier.
- « zoomer / dézoomer » sont ambigus en français. On adopte la convention **explicite** suivante, utilisée partout :

Phase 1 (« agrandir la portée ») : μ *augmente*. Le quantificateur voit plus loin mais plus grossièrement.

Phase 2 (« affiner ») : μ *diminue*. Le quantificateur voit moins loin mais plus finement.

On évitera donc autant que possible les mots « zoom-in / zoom-out ».

- Les preuves se terminent par $\square$. Les passages techniques que l'on peut sauter en première lecture sont signalés par le symbole $[\star]$.

Chapitre 1

Le monde est continu, la machine ne l'est pas

1.1 Trois histoires pour commencer

Les trois situations qui suivent viennent de trois mondes différents. Elles n'ont l'air d'avoir aucun rapport. Ce sont pourtant trois visages du même problème, et ce document ne parle que de celui-là.

Histoire 1 : le thermostat qui oscille

Vous réglez votre chauffage sur 20°C. Le capteur de température de votre box domotique renvoie une valeur avec une résolution de 0,5°C. La régulation, elle, a été conçue par un ingénieur qui a supposé qu'il connaissait la température *exactement*. Résultat : la pièce ne se stabilise jamais à 20,0°C. Elle oscille lentement dans une bande d'environ $\pm 0,5^\circ\text{C}$. Ce n'est pas un défaut de réglage, ni un bruit : c'est *structurel*. Le régulateur ne peut pas corriger une erreur qu'il ne voit pas.



FIGURE 1.1 : Le thermostat domestique, modèle réduit de tout ce cours : la consigne et la mesure ne peuvent prendre qu'un nombre fini de valeurs, ici matérialisées par les graduations du cadran. Entre deux graduations, le régulateur est aveugle.¹

Histoire 2 : le drone et la liaison radio

Un drone envoie sa position à une station sol via une liaison qui transporte 8 bits par échantillon, soit 256 symboles distincts. Si l'on code ± 100 m sur ces 256 symboles, la résolution

1. *Source* : photographie du thermostat Honeywell T87 « The Round », par l'utilisateur Flickr *midnightcomm*, via Wikimedia Commons, licence CC BY 2.0, [Honeywell_round_thermostat.jpg](#).

vaut 0,78 m : parfait pour un vol lointain, catastrophique pour un atterrissage de précision. Si l'on code ± 1 m, la résolution vaut 0,8 cm : parfait à l'atterrissage, mais dès que le drone s'éloigne, la station reçoit systématiquement « +1 m », c'est-à-dire plus aucune information. On tient là, en une phrase, le *dilemme central* de tout ce cours : **portée contre précision**, à budget de bits fixé.




FIGURE 1.2 : Un quadrirotor en vol. Sa position est estimée à bord, puis transmise au sol sur un canal à débit fini. Le nombre de symboles disponibles est fixé par le matériel ; ce que l'on peut choisir, et *changer en cours de vol*, c'est l'intervalle de valeurs que ces symboles recouvrent.²

Histoire 3 : la vanne tout-ou-rien

Un actionneur industriel est souvent une électrovanne : ouverte ou fermée. La loi de commande calcule $u^*(t) = -3,47$. L'actionneur ne sait délivrer que $\{-U_{\max}, 0, U_{\max}\}$. Ici la quantification n'est pas sur la mesure mais sur *la commande*. C'est le troisième visage du même problème.

Cet exemple n'est pas un artifice de rédaction : c'est exactement la liste d'exemples que donne Liberzon en ouverture de [6], où la quantification de l'entrée est illustrée par l'amplificateur à modulation de largeur d'impulsion et par la *boîte de vitesses manuelle* d'une automobile. Dans les deux cas, le calcul demande un réel et le matériel ne sait produire qu'un niveau parmi une poignée.

2. Source : photographie par *Project Kei*, via Wikimedia Commons, licence CC BY-SA 4.0, [Quadcopter_Drone_in_flight.jpg](#).



(a) électrovanne : ouverte ou fermée



(b) boîte manuelle : 5 rapports

FIGURE 1.3 : Deux actionneurs à alphabet fini. (a) Une électrovanne à commande par solénoïde : la section de passage ne prend que deux valeurs. (b) Une boîte de vitesses manuelle : le rapport de transmission ne prend que cinq valeurs, alors que la loi de commande « naturelle » en voudrait un continuum. Ce second exemple est celui que [6, §1] met en avant pour la quantification d'entrée.³

Intuition : les trois histoires n'en font qu'une

Dans les trois cas, un signal réel $z \in \mathbb{R}$ (température, position, commande) est remplacé par un élément d'un ensemble *fini* $\mathcal{Q}$. L'application $z \mapsto q(z)$ qui réalise ce remplacement s'appelle un *quantificateur*. Le reste du document étudie une seule question :

que devient une loi de commande stabilisante quand on la nourrit de $q(z)$ au lieu de z , et que peut-on faire pour réparer les dégâts ?

Remarque 1.1 (sur les illustrations de ce document). Les photographies et schémas empruntés à des sources extérieures sont systématiquement accompagnés, dans leur légende, de l'auteur, de la licence et de l'adresse exacte du fichier. Les figures numériques, elles, sont toutes produites par les codes du dépôt compagnon (annexe F) et reproductibles en une commande. L'annexe G récapitule l'ensemble.

1.2 Une brève histoire du problème

Le sujet a une histoire courte et bien datée. La reconstituer aide à comprendre pourquoi les objets techniques de ce cours ont la forme qu'ils ont.

3. Sources : (a) schéma par l'utilisateur *Sparpo*, Wikimedia Commons, CC BY-SA 4.0, [Solenoid_Valve_Closed.png](#); (b) photographie par *Winkelbohrer*, Wikimedia Commons, CC BY-SA 2.0, [SEAT_Leon_Mk2_gear_lever.jpg](#).

date	auteurs	apport
1956	Kalman	Première observation du phénomène : un correcteur stabilisant devient, une fois quantifié sur un alphabet fini, générateur de cycles limites et de comportements chaotiques. ⁴
1989 à 1990	à Delchamps [1, 2]	Formalisation : pour un système linéaire instable et un quantificateur uniforme <i>fixe</i> , aucun retour d'état statique ne rend l'origine asymptotiquement stable.
1999	Wong & Brockett [3]	Le problème est reformulé comme une contrainte de <i>bande passante</i> : combien de bits par seconde faut-il pour stabiliser ?
2000	Brockett & Liberzon [4]	L'idée décisive : rendre le quantificateur <i>réglable</i> en cours de route. C'est la naissance du zoom et de tout ce cours.
2001 à 2005	à Elia & Mitter [5], Fu & Xie [8]	L'autre école : quantificateur logarithmique fixe, condition de secteur, synthèse par inégalités matricielles linéaires.
2003	Liberzon [6]	Extension aux systèmes non linéaires et aux trois configurations (état, sortie, entrée quantifiés), avec la stabilité entrée-état comme outil central.
2004 à 2007	à Tatikonda & Mitter [7], Nair <i>et al.</i> [10]	Le théorème du débit minimal : la borne fondamentale ne dépend que des valeurs propres instables.
2016 à 2020	à Tanwani <i>et al.</i> [22], Espitia <i>et al.</i> [23], Bekiaris-Liberis [24]	Le passage à la dimension infinie, d'abord en stabilité pratique, puis en stabilité asymptotique globale pour les EDP hyperboliques du premier ordre.
2024 à 2026	à Koudohode <i>et al.</i> [26, 28, 29, 30, 31]	Retard d'entrée et quantification simultanés, EDP de réaction-diffusion, systèmes hyperboliques 2×2 , couplage avec la commande événementielle.

Intuition : la ligne de partage

Deux stratégies coexistent depuis 2001, et il faut savoir dès maintenant laquelle on suit.

- **Quantificateur fixe, plus fin près de l'origine** (logarithmique). Éléphant, sans commutation, mais il faut une infinité de niveaux, donc un débit binaire non borné au sens strict.
- **Quantificateur à alphabet fini, mais dont on règle l'échelle en ligne** (le zoom). Plus lourd conceptuellement, mais réalisable avec un convertisseur à N bits réel.

Ce cours suit la seconde voie, celle de [4, 6], et consacre la section 2.5.3 à la première.

4. R. E. Kalman, *Nonlinear aspects of sampled-data control systems*, Proc. Symposium on Nonlinear Circuit Theory, Brooklyn, vol. 6, pp. 273 à 313, 1956. L'observation est rappelée en introduction de [8, §I].

1.3 Des applications documentées

Les trois histoires de la section précédente sont volontairement schématiques. Voici des situations réelles, avec les travaux qui les traitent.

Un hélicoptère de laboratoire. Schlanbusch, Aamo et Zhou [25] commandent l'attitude d'un banc d'essai hélicoptère à deux degrés de liberté dont la commande transite par un réseau qui la *quantifie* et la *retarde*. C'est exactement le cadre de la section 3.3 de ce cours, et l'un des rares travaux où les deux effets sont traités ensemble sur un dispositif physique.

Trafic routier, réseaux d'eau, forage pétrolier. Ces trois domaines sont modélisés par des systèmes hyperboliques du premier ordre, ce qui en fait la motivation standard du chapitre 3 ; on consultera le livre de Bastin et Coron [19] pour la modélisation. Les capteurs y sont distants, parfois enfouis, et communiquent par liaison bas débit : la quantification n'y est pas une hypothèse d'école.



(a) trafic routier



(b) canal d'irrigation



(c) colonne de forage

FIGURE 1.4 : Trois systèmes que l'on modélise par des lois de conservation hyperboliques du premier ordre, et dont les capteurs communiquent sur des liaisons à débit limité. (a) densité de véhicules le long d'un axe ; (b) hauteur et débit dans un canal à surface libre ; (c) ondes de torsion et de pression dans une colonne de forage. Modélisation détaillée dans [19].⁵

Réseaux et calcul embarqué. La revue de Nair, Fagnani, Zampieri et Evans [10] recense les contraintes de débit dans les systèmes commandés en réseau. Du côté du traitement du signal, la synthèse de Gray et Neuhoff [37] reste la référence historique sur la quantification elle-même, indépendamment de toute boucle de commande.

En pratique : le point commun

Dans tous les cas, ce n'est pas la précision du capteur en tant que telle qui pose problème, c'est le fait qu'elle soit *finie et fixée à l'avance*, alors que l'amplitude du signal à mesurer, elle, varie de plusieurs ordres de grandeur pendant le transitoire. Tout le cours consiste à casser ce « fixée à l'avance ».

1.4 Où la quantification apparaît dans une boucle

La figure 1.5 localise les points d'entrée de la quantification dans une architecture numérique typique.

5. Sources : (a) Ken Lund, Wikimedia Commons, CC BY-SA 2.0, [Traffic_Jam_on_Pyramid_Highway...jpg](#) ; (b) Mike Faherty, [geograph.org.uk](#) via Wikimedia Commons, CC BY-SA 2.0, [Hale,_irrigation_channel...jpg](#) ; (c) *Liberaler Humanist*, Wikimedia Commons, CC BY-SA 3.0, [Oil_drilling_rig_in_Frederikshavn.jpg](#).




FIGURE 1.5 : Les deux points de quantification d'une boucle numérique : à l'*actionnement* (convertisseur numérique vers analogique, modulation de largeur d'impulsion) et à la *mesure* (convertisseur analogique vers numérique, puis réseau). Le cas « quantification d'état » correspond à q_y , le cas « quantification d'entrée » à q_u .

Rappel : sigles

ADC (*Analog-to-Digital Converter*), convertisseur analogique vers numérique : transforme une tension en un entier codé sur N bits. **DAC** : l'opération inverse. **PWM** (*Pulse-Width Modulation*) : on commute très vite entre deux niveaux, la *moyenne* sur une période approche la commande souhaitée. **NCS** (*Networked Control System*) : boucle fermée à travers un réseau de communication.

1.5 Ce que la quantification n'est pas

Une source classique de confusion, en particulier chez le lecteur qui a déjà vu du « contrôle numérique » : il existe *quatre* imperfections distinctes, qui appellent quatre théories différentes.

Imperfection	Nature	Outil principal
Échantillonnage	discrétisation du <i>temps</i>	systèmes échantillonnés, temps de séjour
Quantification	discrétisation de l' <i>amplitude</i>	<i>ce document</i>
Retard	décalage temporel	prédicteurs, EDP de transport (section 3)
Bruit de mesure	perturbation aléatoire	filtrage, H_∞ , stochastique

Attention : la quantification n'est pas un bruit

Il est tentant de modéliser l'erreur de quantification comme un bruit blanc uniforme sur $[-\Delta/2, \Delta/2]$. C'est une approximation *utile en traitement du signal* et *dangereuse en commande*, pour deux raisons.

1. L'erreur est *déterministe* et fonction de l'état : $e = q(x) - x$ dépend de x . En boucle fermée, elle est corrélée avec l'état, ce qui crée des cycles limites, pas du bruit.
2. Hors de la portée, l'erreur n'est pas bornée par Δ : elle croît comme $|x|$. Un modèle « bruit borné » rate complètement le phénomène de saturation, qui est le mécanisme de *divergence*.

1.6 Le fil rouge : l'analogie de l'appareil photo

Cette analogie n'est pas une invention pédagogique : c'est celle que Liberzon pose en introduction de [6], et il vaut la peine de la restituer exactement, parce que sa force tient à un détail qu'on perd si on la raconte approximativement.

*Si un quantificateur représente un appareil photo, faire varier ses paramètres en ligne revient à zoomer, c'est-à-dire à changer la distance focale, le nombre de pixels, lui, restant bien entendu fixé.*⁶

Deux choses sont à retenir, et la seconde est la plus importante.

1. **L'appareil photo n'est pas qu'une métaphore.** C'est un exemple littéral de quantification de sortie : dans une boucle de commande asservie par vision, la mesure *est* produite par une caméra numérique, et les cellules de quantification dans l'espace d'état sont les images réciproques des pixels [6, §1].
2. **Le nombre de pixels est invariant.** C'est lui, et lui seul, que le matériel fixe. Le photographe ne peut pas créer des pixels en tournant la bague de zoom ; il peut seulement décider *sur quelle portion du monde* il les dépense.

Attention : ce que l'analogie ne dit pas

On lit souvent que « zoomer améliore la résolution ». C'est vrai de la résolution *sur la scène*, et faux de la résolution du capteur. La taille d'un pixel *sur le capteur* ne change jamais : ce qui change, c'est la taille de la *portion de scène* qu'un pixel recouvre. C'est cette empreinte-là, et non le pixel, qui correspond à $\Delta\mu$. Dire « taille du pixel $\leftrightarrow \Delta\mu$ » est une erreur de lecture : elle laisse croire qu'on pourrait gagner en précision sans rien perdre par ailleurs, alors que tout le sujet est précisément qu'on ne le peut pas.

Le dictionnaire correct est donc le suivant.

Appareil photo	Quantificateur $q_\mu = \mu q(\cdot/\mu)$
inverse de la distance focale	la variable de zoom μ elle-même [6, §2]
champ de vision (l'étendue de scène cadrée)	portée $M\mu$
empreinte d'un pixel <i>sur la scène</i>	résolution $\Delta\mu$
nombre de pixels	M/Δ, fixé par le matériel
grand angle (μ augmente)	on voit tout, mais grossièrement
téléobjectif (μ diminue)	on voit finement, mais peu

La figure 1.6 rend la chose littérale : même appareil, même capteur, donc même nombre de pixels, trois distances focales. Le champ cadré est divisé par plus de quarante entre la première et la troisième vue, et la finesse des détails est multipliée d'autant. Le produit « champ $\times$ finesse » est, lui, constant : c'est M/Δ .

6. Traduction de [6, §1]. Plus loin, l'article précise le dictionnaire : « μ correspond à l'inverse de la distance focale » [6, §2].





FIGURE 1.6 : L'analogie de [6, §1 et §2], prise au pied de la lettre : une même scène, depuis un même point de vue, avec un même capteur (donc un nombre de pixels *constant*), photographiée à trois distances focales. À gauche, la portée est maximale et l'on distingue mal le détail : c'est la **phase 1**, quand on cherche où se trouve l'état. À droite, le détail est net mais tout ce qui sort du cadre est perdu : c'est la **phase 2**, quand on sait où l'on est et que l'on veut y être précisément. Aucune des trois vues n'a plus de pixels que les autres.⁷

Ce que le contrôleur peut faire, et que le matériel ne peut pas, c'est *changer la distance focale au cours du temps*. Toute la stratégie développée dans ce document tient dans cette idée, et Liberzon en donne déjà la forme en deux temps [6, §3.1] : une première étape « *zooming-out* », en boucle ouverte, où l'on augmente la portée jusqu'à ce que l'état soit mesurable ; une seconde étape « *zooming-in* », en boucle fermée, où l'on diminue l'erreur de quantification de façon à ramener l'état à l'origine.



Intuition : pourquoi deux phases et pas une seule ?

Parce que les deux échecs possibles sont *opposés*. Ce sont exactement les deux phénomènes que [6, §1] identifie comme responsables de tout le problème.

- **Saturation.** Si μ est trop *petit* dès le départ, l'état sort de la portée $[-M\mu, M\mu]$; l'erreur de quantification n'est alors plus bornée par $\Delta\mu$, la loi conçue pour le cas idéal agit sur une information fausse : **divergence**.
- **Dégradation près de l'équilibre.** Si μ reste trop *grand*, il n'y a pas de saturation, mais l'erreur $\Delta\mu$ est grande en permanence : plus l'état approche de zéro, plus il faudrait de précision, et on n'en a pas. L'état converge vers une bande de taille $\sim \Delta\mu$ et **n'atteint jamais zéro**.

Ces deux phénomènes se manifestent, dit Liberzon, par l'existence de *deux régions invariantes emboîtées* : toute trajectoire partant de la grande rejoint la petite, et au-delà on ne garantit plus rien. On retrouvera littéralement ces deux régions à la section 2.2.3, sous la forme de deux ellipsoïdes de niveau.

La seule issue est donc temporelle : d'abord grand μ (pour capturer), puis $\mu \rightarrow 0$ (pour converger). C'est exactement ce que fait un photographe qui cherche un oiseau au grand

7. Source : série « Focal length » d'Armin Kübelbeck, Wikimedia Commons, licence CC BY-SA 3.0, fichiers [Focal_length_f24mm.jpg](#), [Focal_length_f70mm.jpg](#) et [Focal_length_1000mm.jpg](#).

angle avant de zoomer dessus, à ceci près que le photographe voit l'oiseau, tandis que le contrôleur doit *déduire* de la seule mesure quantifiée qu'il l'a trouvé. C'est ce que garantira la propriété (P2) de la section 1.7.2.

1.7 Le quantificateur : définition, propriétés, exemples

1.7.1 Définition

Définition 1.2 (Quantificateur). Soit $\ell \in \mathbb{N}^*$. Un *quantificateur* est une application

$$q : \mathbb{R}^\ell \longrightarrow \mathcal{Q}, \quad \mathcal{Q} \subset \mathbb{R}^\ell \text{ fini ou dénombrable,}$$

constante par morceaux : il existe une partition $\mathbb{R}^\ell = \bigcup_{i \in I} \mathcal{R}_i$, avec $\mathcal{R}_i \cap \mathcal{R}_j = \emptyset$ pour $i \neq j$, telle que $q(z) = q_i$ pour tout $z \in \mathcal{R}_i$. Les $\mathcal{R}_i$ sont les *régions* (ou cellules) de quantification et les q_i les *valeurs de reconstruction*.

Remarque 1.3 (lecture « transmission »). On peut voir q comme un protocole de communication : au lieu d'envoyer z (un réel, donc une infinité de bits), on envoie l'*indice* i de la cellule qui contient z ; le récepteur reconstruit q_i . Le nombre de bits nécessaires par échantillon est $\lceil \log_2 |I| \rceil$. C'est ce lien avec la théorie de l'information qui rend le sujet si riche (voir la section B.6 sur le théorème du débit minimal).




FIGURE 1.7 : Régions de quantification en dimension $\ell = 2$.

1.7.2 Les deux paramètres qui gouvernent tout : M et Δ

Définition 1.4 (Portée et résolution). On dit qu'un quantificateur q possède le *seuil de saturation* (ou *portée*) $M > 0$ et la *borne d'erreur* (ou *résolution*) $\Delta > 0$ s'il vérifie :

$$(P1) \quad \|z\| \leq M \implies \|q(z) - z\| \leq \Delta, \quad (1.1)$$

$$(P2) \quad \|z\| > M \implies \|q(z)\| > M - \Delta. \quad (1.2)$$

On suppose toujours $M > \Delta$.

Ces deux propriétés, sous cette forme exacte, remontent à Liberzon [6, §2] ; elles sont reprises telles quelles dans tous les travaux sur EDP qui suivront, par exemple [24, éq. (P1) à (P3)]. Elles méritent qu'on s'y arrête, car elles sont exactement ce dont les preuves auront besoin, ni plus ni moins.

- **(P1) est une garantie de précision.** Dans la boule de rayon M , on peut écrire $q(z) = z + e(z)$ avec $\|e(z)\| \leq \Delta$: la quantification devient une *perturbation bornée additive*. C'est ce qui permettra d'invoquer la robustesse (ISS) de la loi nominale.

- **(P2) est une garantie de *déteclabilité*.** Elle dit : « si l'état est hors de portée, la sortie du quantificateur le trahit, en collant près du bord ». Sa contraposée est l'outil réellement utilisé :

$$\|q(z)\| \leq M - \Delta \implies \|z\| \leq M.$$

Ceci est *capital* : cela signifie qu'un contrôleur qui ne dispose *que* de la mesure quantifiée peut néanmoins *savoir* qu'il n'est pas en saturation. Sans (P2), la phase 1 de la stratégie hybride serait impossible à déclencher.




FIGURE 1.8 : Quantificateur uniforme saturant scalaire (« mid-tread »). En bleu la zone non saturée où (P1) s'applique : l'écart à l'identité y est majoré par Δ . En rouge la saturation, où seule (P2) subsiste : la sortie reste au voisinage du bord. La droite pointillée est l'identité $q(z) = z$.

Définition 1.5 (Zone morte, (P3)). Certains résultats (notamment ceux de la section 3) requièrent en plus l'existence de $\widehat{M} \in (0, M)$ tel que

$$(P3) \quad \|z\| \leq \widehat{M} \implies q(z) = 0. \quad (1.3)$$

Intuition : à quoi sert la zone morte ?

Elle garantit que *l'origine est un point d'équilibre exact* de la boucle fermée. Sans (P3), la commande quantifiée peut rester non nulle même quand l'état est arbitrairement petit, ce qui provoque un *broutement* (*chattering*) autour de zéro et complique la définition même de solution. Avec (P3), une fois l'état dans la zone morte, la commande vaut exactement zéro. En pratique, tout ADC réel possède une zone morte (le pas autour de zéro) ; l'hypothèse est donc gratuite.

1.7.3 Catalogue d'exemples

1.7.3.1 Quantificateur uniforme scalaire (le plus courant)

Pour $\ell = 1$ et un pas $h > 0$:

$$q(z) = \begin{cases} M, & z > M, \\ h \left\lfloor \frac{z}{h} + \frac{1}{2} \right\rfloor, & |z| \leq M, \\ -M, & z < -M. \end{cases} \quad (1.4)$$

On remplace z par le multiple de h le plus proche : c'est l'arrondi. On a alors (P1) avec

$$\Delta = \frac{h}{2}.$$




FIGURE 1.9 : L'opération élémentaire, vue sur un signal : à gauche le signal continu et la grille de niveaux ; au milieu le signal quantifié, constant par morceaux ; à droite l'erreur $e = q(z) - z$, bornée par $\Delta = h/2$ tant que l'on reste dans la portée. Toute la difficulté de ce cours vient de ce que, en boucle fermée, cette erreur n'est pas un bruit extérieur : elle est une fonction déterministe de l'état, et l'état dépend d'elle.⁸

En pratique : le rapport Δ/M , et sa lecture en bits

La quantité qui apparaîtra dans *toutes* les conditions de ce cours est le rapport sans dimension

$$\frac{\Delta}{M} \in (0, 1),$$

c'est-à-dire la résolution rapportée à la portée. C'est lui, et lui seul, que les théorèmes contraignent. Les articles du domaine l'écrivent d'ailleurs directement sous la forme $\Delta = M/30$, $\Delta = M/40$ ou $\Delta = M/100$; voir par exemple [24, §5] et [26, §5].

La traduction en bits. Pour un quantificateur uniforme saturant, le lien avec le nombre de bits est une simple conséquence de la définition, et non un théorème ; il vaut la peine de l'écrire une fois. La convention standard en conversion analogique vers numérique [38, §4.8] est : un convertisseur à N bits de pleine échelle $\pm V$ dispose de 2^N niveaux régulièrement espacés, donc d'un pas

$$h = \frac{2V}{2^N}.$$

Avec $M = V$ et, d'après (1.4), $\Delta = h/2$, il vient

$$\frac{\Delta}{M} = \frac{h}{2M} = 2^{-N}, \quad \text{soit} \quad N = \log_2 \frac{M}{\Delta}.$$

On dispose donc d'une lecture commode : 8 bits donnent $\Delta/M \approx 3,9 \cdot 10^{-3}$, 12 bits $2,4 \cdot 10^{-4}$, 16 bits $1,5 \cdot 10^{-5}$. On l'utilisera souvent, parce qu'un ingénieur raisonne en bits et non en rapports.

D'où vient cette convention. Le fait que le débit d'un quantificateur à L niveaux vaille $R = \log_2 L$ bits par échantillon, et la façon dont la distorsion décroît alors comme 2^{-2R} , sont établis dans la synthèse de référence de Gray et Neuhoﬀ [37, §II]. Ce document n'a besoin que de la partie élémentaire de ce dictionnaire ; la question, bien plus délicate, du nombre de *symboles par seconde* réellement nécessaire à la stabilisation est traitée séparément à l'annexe B.6.

8. Source : Gregory Maxwell, Wikimedia Commons, licence CC BY 3.0, [Quantization_error.png](#).

Attention : ne pas confondre le budget et sa traduction

La traduction $\Delta/M = 2^{-N}$ vaut pour un quantificateur uniforme saturant. Elle ne vaut pas en général : les propriétés (P1) et (P2) n'imposent aucune structure sur les cellules, et un quantificateur non uniforme de même (M, Δ) peut utiliser bien plus, ou bien moins, de 2^N symboles. Quand on lira, dans la suite, « il faut 19 bits », il faudra donc entendre : « il faut $\Delta/M < 2^{-19}$, ce qu'un ADC uniforme atteint avec 19 bits ». La distinction devient importante à la section B.6, où la question du débit minimal se pose en nombre de *symboles*, et non en résolution.

1.7.3.2 Quantificateur logarithmique

Pour $z \neq 0$ et $\alpha > 1$:

$$q(z) = \text{sign}(z) \alpha^k, \quad k = \lfloor \log_\alpha |z| \rfloor.$$

Les niveaux sont espacés *multiplicativement* : l'erreur est *relative*, $|q(z) - z| \leq c |z|$ avec $c = \frac{\alpha-1}{\alpha+1}$ pour le choix d'arrondi géométrique. Les petites valeurs sont finement codées, les grandes grossièrement.



Remarque 1.6 (deux mondes). Le quantificateur logarithmique satisfait une *condition de secteur* : $q(z) \in [(1-c)z, (1+c)z]$. Cela ouvre une théorie différente (analyse par secteur, LMI, quantificateur « le moins dense possible » de Elia et Mitter [5], Fu et Xie [8]), que l'on présente au section 2.5. Attention : un quantificateur logarithmique a une *infinité* de niveaux (accumulation en 0), donc un débit binaire infini au sens strict. Le quantificateur uniforme à zoom, lui, garde un alphabet fini. C'est un point de doctrine important.

1.7.3.3 Base 2 : virgule flottante et réseaux de neurones

Le cas $\alpha = 2$ mérite un développement séparé, parce que c'est celui que tout le monde utilise sans le nommer.

La virgule flottante est un quantificateur logarithmique. Un nombre `float` de la norme IEEE 754 [39] s'écrit $\pm m \cdot 2^e$ avec une mantisse $m \in [1, 2)$ codée sur p bits et un exposant e entier. Autrement dit : *l'exposant réalise une quantification logarithmique de base 2, et la mantisse une quantification uniforme à l'intérieur de chaque octave*. L'erreur relative est bornée par 2^{-p} :

$$\text{float32} (p = 24) \Rightarrow 6 \cdot 10^{-8}, \quad \text{float16} (p = 11) \Rightarrow 5 \cdot 10^{-4}, \quad \text{bfloat16} (p = 8) \Rightarrow 4 \cdot 10^{-3}.$$

Le format `bfloat16` est instructif : il garde l'exposant du `float32` (donc la même dynamique, la même « portée ») et sacrifie la mantisse (donc la « résolution »). C'est le dilemme portée/précision de l'histoire 2, tranché au niveau du format de nombre.

La quantification entière en apprentissage automatique. Pour faire tourner un réseau de neurones sur huit bits, on remplace chaque tenseur réel x par

$$\hat{x} = s \cdot \left(\text{clip}(\lfloor x/s \rfloor + z, -128, 127) - z \right), \quad (1.5)$$

où $s > 0$ est appelé *scale* et z le *zero-point* [40, §III]. Comparez avec la famille à zoom (1.6) que l'on introduit à la section 1.7.4 :

	apprentissage	commande
Facteur d'échelle	<i>scale s</i>	variable de zoom μ
Écrêtage	<i>clipping</i> à ± 128	saturation, propriété (P2)
Choix de l'échelle	calibration hors ligne sur un jeu de données	mise à jour <i>en ligne</i> et en boucle fermée
Conséquence d'un mauvais choix	perte de précision du modèle	perte de stabilité

C'est le même objet mathématique. La différence tient à ce que, en apprentissage, le « système » est statique et l'échelle se choisit une fois pour toutes ; en commande, le signal à quantifier est produit par une boucle que la quantification elle-même perturbe. **L'échelle devient un état du système**, et c'est toute la difficulté.

Intuition : pourquoi cela devrait intéresser un lecteur venu du machine learning

La communauté de l'apprentissage a développé des techniques très fines pour choisir s (calibration par percentiles, quantification par canal, apprentissage conscient de la quantification). Elles supposent toutes que l'erreur commise se propage de façon *ouverte*, de la couche k à la couche $k + 1$. En boucle fermée, l'erreur revient sur son propre point d'application : elle peut s'amplifier indéfiniment. Les conditions de petit gain des sections A.3 et suivants sont précisément l'outil qui manque de l'autre côté.

1.7.3.4 Quantificateur à zone morte

$$q(z) = \begin{cases} 0, & |z| \leq d, \\ h \left\lfloor \frac{z}{h} + \frac{1}{2} \right\rfloor, & |z| > d, \end{cases}$$

avec $d > 0$. Modélise un capteur aveugle sous un seuil, ou un actionneur avec frottement sec / jeu mécanique. C'est la réalisation la plus simple de (P3).

1.7.3.5 Actionneur tout-ou-rien, PWM

$u \in \{-U_{\max}, 0, U_{\max}\}$ ou $\{0, U_{\max}\}$: c'est un quantificateur à 2 ou 3 niveaux appliqué à la commande, $u = q(u^*)$. La PWM raffine cela en jouant sur le *rapport cyclique* : sur une période T_{pwm} petite, la moyenne peut prendre toutes les valeurs de $[0, U_{\max}]$. On « achète » de la résolution en amplitude avec de la résolution en temps.

1.7.3.6 Quantification vectorielle composante par composante

En dimension $\ell > 1$, le choix le plus simple est $q(z) = (q^s(z_1), \dots, q^s(z_\ell))$ avec q^s scalaire. Si q^s a un pas h , alors pour la norme euclidienne $\|q(z) - z\| \leq \frac{h}{2}\sqrt{\ell}$; pour la norme sup, $\Delta = h/2$ indépendamment de ℓ .

Attention : choisir sa norme, c'est choisir sa constante

C'est une raison technique majeure pour laquelle les résultats sur EDP de ce cours sont écrits en **norme sup** $\|\cdot\|_\infty$ et non en L^2 : la quantification est une contrainte d'*amplitude*, elle s'exprime naturellement point par point. En L^2 , relier $\|q(u/\mu) - u/\mu\|_\infty$ à $\|u\|_{L^2}$ demande de contrôler des dérivées spatiales, ce qui alourdit énormément l'analyse.

1.7.4 La famille à zoom q_μ

C'est l'objet central du cours.

Définition 1.7 (Quantificateur dynamique). Soit q vérifiant (P1) et (P2) avec les paramètres (M, Δ) . Pour $\mu > 0$ on pose

$$q_\mu(z) := \mu q\left(\frac{z}{\mu}\right). \quad (1.6)$$

Proposition 1.8 (propriétés mises à l'échelle). q_μ vérifie (P1) et (P2) avec les paramètres $(M\mu, \Delta\mu)$:

$$\|z\| \leq M\mu \Rightarrow \|q_\mu(z) - z\| \leq \Delta\mu, \quad \|z\| > M\mu \Rightarrow \|q_\mu(z)\| > (M - \Delta)\mu.$$

Si de plus q vérifie (P3) avec $\widehat{M}$, alors $q_\mu(z) = 0$ dès que $\|z\| \leq \widehat{M}\mu$.

Démonstration. Posons $\zeta = z/\mu$. Si $\|z\| \leq M\mu$ alors $\|\zeta\| \leq M$, donc $\|q(\zeta) - \zeta\| \leq \Delta$ par (P1) ; en multipliant par μ , $\|q_\mu(z) - z\| = \mu \|q(\zeta) - \zeta\| \leq \Delta\mu$. Le second point est identique avec (P2). $\square$

Intuition : une seule ligne à retenir

$$\underbrace{\text{portée}}_{M\mu} \nearrow \text{ avec } \mu, \quad \underbrace{\text{erreur}}_{\Delta\mu} \nearrow \text{ aussi avec } \mu.$$

Le rapport Δ/M , lui, ne bouge **jamais** : c'est l'invariant matériel (le nombre de bits). Le zoom ne crée pas d'information, il la déplace.

1.7.5 Une subtilité de régularité $[\star]$

Un quantificateur exact est une fonction en escalier, donc discontinue. Quand on l'injecte dans une boucle fermée, la question « la solution existe-t-elle et est-elle unique ? » n'est plus triviale : le second membre de l'équation différentielle devient discontinu en l'état.

Deux issues sont possibles.

1. Travailler avec des *solutions de Filippov* ou dans le formalisme des *systèmes hybrides* (Goebel-Sanfelicce-Teel [35]).
2. Supposer, comme dans [24, 26], que q est *localement lipschitzienne* tout en satisfaisant (P1) à (P3) : on remplace les sauts par des rampes très raides. On parle de quantificateur « presque » quantifié.

C'est la seconde voie que l'on suit. Elle est indolore :

Proposition 1.9. Pour tout $\eta \in (0, \Delta)$ il existe $\tilde{q}$ localement lipschitzienne vérifiant (P1) et (P2) avec les paramètres (M, Δ) , et telle que $\tilde{q} = q$ hors d'un voisinage de mesure $\leq \eta$ de l'ensemble des discontinuités de q .

Idée. Sur chaque frontière de cellule, remplacer le saut de hauteur h par une rampe de largeur η . L'erreur sur la rampe reste comprise entre les deux valeurs de reconstruction voisines, donc majorée par Δ . $\square$

La construction explicite utilisée dans la littérature est celle de [24, éq. (11)] : on fixe une largeur de transition $\varepsilon \in (0, 1)$ et l'on définit, sur $[-3, 3]$ et pour $k \in \{1, 2\}$,

$$q(z) = \begin{cases} 0, & |z| \leq 1, \\ \frac{z - \varepsilon k}{\varepsilon} + k - 1, & k \leq z \leq k + \varepsilon, \\ k, & k + \varepsilon \leq z \leq k + 1, \\ 2, & z \geq 3, \end{cases}$$

prolongée par imparité, avec ici $M = 3$, $\widehat{M} = 1$ et $\Delta = 1 + \varepsilon/2$ pour ε petit. La figure 1.10 en donne l'allure.




FIGURE 1.10 : Quantificateur approché localement lipschitzien : les sauts sont remplacés par des rampes de largeur ε . Construction reprise de [24, Fig. 1], redessinée ici avec les notations du cours.




FIGURE 1.11 : La même construction, telle qu'elle est publiée : quantificateur approché à couche ε , de pente $1/\varepsilon$ sur chaque rampe. Les deux droites en tirets matérialisent l'encadrement $z - \Delta \leq q(z) \leq z + \Delta$ dans la portée.⁹

Attention : point de doctrine, et un problème ouvert

Aucune estimation de stabilité de ce document n'utilise la constante de Lipschitz. Celle-ci ne sert qu'au caractère bien posé, c'est-à-dire à l'existence et à l'unicité des solutions ; les bornes, elles, ne dépendent que de (M, Δ) . C'est pourquoi on peut, en simulation, utiliser le vrai escalier sans état d'âme, et c'est ce que font les codes du dépôt compagnon.

Il ne faut pas pour autant considérer la question comme réglée. Avec un escalier exact et une loi de backstepping construite *sur l'état quantifié*, le second membre du système en boucle fermée est discontinu en l'état, et le caractère bien posé du problème reste ouvert en dimension infinie : c'est le premier des problèmes de la section B.4. En dimension finie,

9. Source : Figure reproduite de [26, Fig. 1], préprint librement accessible [arXiv:2404.11194](https://arxiv.org/abs/2404.11194), avec l'aimable autorisation des auteurs.

on dispose au moins des solutions de Filippov et de Krasovskii, étudiées pour les systèmes quantifiés par Ceragioli et De Persis [9] et, du point de vue algorithmique, par Ferrante, Gouaisbaut et Tarbouriech [14].

1.7.6 Exercices

Exercice 1.1. Montrer que le quantificateur uniforme (1.4) vérifie (P2) avec $\Delta = h/2$, et que la constante $M - \Delta$ y est optimale.

Exercice 1.2. Soit q scalaire uniforme de pas h , et q^ℓ sa version composante par composante sur $\mathbb{R}^\ell$. Calculer les meilleures constantes Δ pour la norme euclidienne, la norme sup et la norme 1. Commenter la dépendance en ℓ .

Exercice 1.3. On considère q_μ avec $M = 6$, $\Delta = 0,125$ et $\mu = 0,5$. Quelle est la portée effective ? La résolution effective ? Combien de niveaux le quantificateur utilise-t-il ? Ce nombre dépend-il de μ ?

Exercice 1.4 (★). Montrer que si q vérifie (P1) et (P2) avec (M, Δ) et $\Delta \geq M$, alors (P2) est vide de contenu. En déduire pourquoi l'hypothèse $M > \Delta$ est indispensable, et interpréter en nombre de bits.

1.8 Ce que la quantification fait à une boucle fermée

Ce chapitre est volontairement élémentaire : tout y est calculé à la main sur un système scalaire. C'est pourtant là que se trouvent les trois idées qui structurent l'ensemble du document.

1.8.1 Un exemple que l'on peut faire à la main

Considérons le système instable le plus simple qui soit :

$$\dot{x} = ax + u, \quad a > 0, \quad x \in \mathbb{R}. \quad (1.7)$$

Sans quantification, $u = -kx$ avec $k > a$ donne $\dot{x} = -(k - a)x$: convergence exponentielle vers 0. Supposons maintenant que le contrôleur ne dispose que de $q_\mu(x)$ et applique

$$u = -k q_\mu(x).$$

En posant $e := q_\mu(x) - x$, la boucle fermée s'écrit

$$\dot{x} = -(k - a)x - k e. \quad (1.8)$$

Tout est dans cette écriture : **la quantification est une perturbation additive, mais dont l'amplitude dépend de la région où se trouve l'état.**

1.8.1.1 Régime non saturé : la bande ultime

Tant que $|x| \leq M\mu$, on a $|e| \leq \Delta\mu$. Alors

$$\frac{d}{dt} \frac{x^2}{2} = -(k - a)x^2 - kxe \leq -(k - a)x^2 + k\Delta\mu |x| = -|x| \left[(k - a)|x| - k\Delta\mu \right].$$

Donc $|x|$ décroît strictement dès que

$$|x| > r(\mu) := \frac{k}{k - a} \Delta\mu. \quad (1.9)$$

On obtient une *stabilité pratique* : toute trajectoire partant de $|x(0)| \leq M\mu$ entre en temps fini dans la bande $|x| \leq r(\mu)$ et n'en ressort plus. Elle n'atteint jamais 0 : elle y *broute*.

Intuition : le rayon ultime a une structure universelle

$$r = \underbrace{\frac{k}{k-a}}_{\text{gain de la boucle nominale}} \times \underbrace{\Delta\mu}_{\text{erreur du capteur}}.$$


Cette structure, « gain du nominal $\times$ erreur », se retrouvera à l'identique en dimension finie (avec $\gamma = 2\|PBK\|/\lambda_{\min}(Q)$) et en dimension infinie (avec les constantes M_1, M_2, M_3, M_0). Toute la difficulté technique du cours consiste à *calculer ce gain* dans des cadres de plus en plus compliqués.

1.8.1.2 Régime saturé : la divergence

Supposons maintenant $|x| > M\mu$ et, pour fixer les idées, $x > 0$ grand. Le quantificateur sature : $q_\mu(x) \approx M\mu$, donc $u \approx -kM\mu$ est *constante*, et

$$\dot{x} \approx ax - kM\mu.$$

Dès que $x > kM\mu/a$, on a $\dot{x} > 0$: l'état **diverge exponentiellement**. La commande est saturée et ne peut plus suivre.

**1.8.1.3 Le dilemme, en une inégalité**

Pour que la stratégie « μ fixé » fonctionne, il faut simultanément :

$$\underbrace{|x(0)| \leq M\mu}_{\text{pas de saturation}} \quad \text{et} \quad \underbrace{\frac{k}{k-a}\Delta\mu}_{\text{précision finale}} \text{ petit.}$$

La première demande μ *grand*, la seconde μ *petit*. Comme Δ/M est fixé par le matériel, aucun μ constant ne satisfait les deux *pour toute condition initiale*. D'où :

Principe fondamental.

Le seul degré de liberté restant est *le temps* : faire varier μ au cours du temps.

1.8.2 Pourquoi aucune loi statique ne peut faire mieux

Le résultat de cette section est, sous une forme plus générale, celui de Delchamps [2] : avec un quantificateur uniforme fixe et un système linéaire instable, aucun retour d'état statique ne rend l'origine asymptotiquement stable, et les trajectoires peuvent même devenir chaotiques.

Le lecteur pressé peut sauter cette section ; elle explique cependant pourquoi la stratégie hybride n'est pas une astuce mais une *nécessité*.

Proposition 1.10 (obstruction élémentaire). *Considérons $\dot{x} = f(x, u)$ avec f continue, et une loi de commande statique $u = \kappa(q(x))$ où q est un quantificateur à alphabet fini $\mathcal{Q}$ et κ une fonction quelconque. Supposons que la cellule $\mathcal{R}_0 \ni 0$ soit d'intérieur non vide et que $f(x, \kappa(q_0)) \neq 0$ pour un $x \in \mathcal{R}_0$. Alors l'origine n'est pas asymptotiquement stable : il existe un voisinage de 0 dans lequel aucune trajectoire ne converge vers 0.*

Idée de la preuve. Sur $\mathcal{R}_0$ la commande est constante, égale à $\kappa(q_0)$. La dynamique y est donc $\dot{x} = f(x, \kappa(q_0))$, autonome et indépendante de la mesure. Si ce champ ne s'annule pas identiquement près de 0, il pousse l'état hors d'un voisinage de l'origine ou l'y maintient à distance non nulle, selon son signe. Dans les deux cas on ne peut pas avoir $x(t) \rightarrow 0$ pour toute condition initiale voisine. $\square$

Remarque 1.11 (les deux échappatoires). Il n'y a que deux façons de contourner la proposition 1.10.

1. **Cellules qui s'accumulent en 0** (quantificateur logarithmique) : alors $\mathcal{Q}$ est infini, le débit binaire aussi.
 2. **Quantificateur dynamique** (à mémoire) : les cellules bougent au cours du temps. C'est la voie du *zoom*, avec un alphabet *fini* à chaque instant. C'est la voie de ce cours.
- Cette dichotomie est classique ; voir [4, 6].

1.8.3 Voir les trois régimes

Code

`scalar_quantized_demo.py`, dépôt https://github.com/Flo3221/codes_mini_cours_quantification. Une trentaine de lignes : intégration par Runge-Kutta d'ordre quatre, quantificateur uniforme saturé, trois valeurs de μ .

Reprenons (1.7) avec $a = 1$, $k = 3$, $M = 5$, $\Delta = M/50$ et $x_0 = 8$, et faisons varier la seule quantité que l'on peut régler, μ .




FIGURE 1.12 : Les trois régimes d'une boucle scalaire quantifiée à μ figé. Avec $\mu = 0,4$, la portée effective vaut $M\mu = 2$ alors que $x_0 = 8$: le quantificateur sature, la commande plafonne à $-kM\mu = -6$, elle ne compense plus $ax = 8$ et l'état diverge. Avec $\mu = 4$, la portée $M\mu = 20$ englobe largement l'état, mais la résolution effective $\Delta\mu = 0,4$ est grossière et l'état se stabilise dans une bande de rayon 0,6. Avec $\mu = 1$, le compromis est meilleur, et la bande tombe à 0,15.

En pratique : ce que la figure prouve, et ce qu'elle ne prouve pas

Elle confirme la formule du rayon ultime $r(\mu) = \frac{k}{k-a}\Delta\mu$: pour $\mu = 4$ et $\mu = 1$, les valeurs finales mesurées sont 0,40 et 0,10, à comparer aux bornes 0,60 et 0,15. Elle montre aussi qu'*aucun* μ figé ne convient : le diminuer réduit la bande mais rapproche du régime divergent,

l'augmenter sécurise mais dégrade la précision. C'est exactement le dilemme que la stratégie hybride de la section 2.3 va résoudre, en faisant varier μ dans le temps au lieu de le choisir une fois pour toutes.

1.8.4 Trois messages à emporter

1. **Hors saturation**, la quantification est une perturbation bornée par $\Delta\mu$: on obtient une convergence vers une bande de rayon (gain nominal) $\times \Delta\mu$. C'est de la *stabilité pratique*.
2. **En saturation**, la quantification détruit l'information et le système peut *diverger*. C'est un phénomène qualitativement différent, et c'est lui qui interdit les résultats *globaux* naïfs.
3. **La sortie**, c'est de rendre μ dynamique : grand d'abord (pour capturer, en exploitant (P2) pour *détecter* la capture), petit ensuite (pour converger). Il reste alors à s'assurer que l'on ne réduit pas μ *plus vite* que l'état ne décroît, sinon on re-sature. C'est le rôle du couple (T, Ω) .

Exercice 1.5. Reprendre (1.7) avec $a = 1$, $k = 3$, $M = 5$, $\Delta = 0,1$, $\mu = 1$. Calculer $r(\mu)$. À partir de quelle condition initiale la boucle diverge-t-elle ? Vérifier numériquement.

Exercice 1.6. Montrer que, dans (1.8), si $\mu(t) = \mu_0 e^{-\beta t}$ avec $0 < \beta < k - a$ et si l'on reste hors saturation, alors $x(t) \rightarrow 0$. Que se passe-t-il si $\beta > k - a$? Interpréter : on a réduit la portée plus vite que l'état ne décroît.

1.9 Feuille de route

Le document tient en trois chapitres et une annexe.

1. **Chapitre 1, ce chapitre-ci.** Pourquoi la quantification est un vrai problème. On y définit proprement un quantificateur (section 1.7), ses deux paramètres M et Δ , la famille à zoom q_μ , puis on calcule à la main, sur un exemple scalaire, les dégâts qu'une résolution fixe provoque en boucle fermée (section 1.8). On montre aussi *pourquoi* aucune loi statique ne peut faire mieux.
2. **Chapitre 2 : la dimension finie.** La théorie complète pour $\dot{x} = Ax + Bu$, en suivant la ligne de démonstration ouverte par Brockett et Liberzon [4, 6] : stabilité pratique à zoom figé, les deux ellipsoïdes emboîtés, la loi hybride à deux phases et la stabilité asymptotique globale. Avec un exemple numérique entièrement traité, chiffres et figures compris (section 2.4), puis les variantes entrée quantifiée, sortie quantifiée et condition de secteur.
3. **Chapitre 3 : les EDP hyperboliques.** Le passage à la dimension infinie, en deux temps. D'abord la stabilisation frontière d'une EDP de transport dont les mesures et la commande sont quantifiées, d'après Bekiaris-Liberis [24] (section 3.2). Ensuite le cas où s'ajoute un retard d'entrée, d'après Koudohode et Bekiaris-Liberis [26] (section 3.3). Chaque résultat est traité d'un seul tenant : modèle, loi, théorème, preuve, simulation.
4. **Annexes : pour aller plus loin.** L'annexe A rassemble la boîte à outils de dimension infinie (EDP de transport, backstepping frontière, ISS, petit gain, pont avec les équations à retard) : elle est utilisée par le chapitre 3 mais peut se lire séparément. L'annexe B contient les extensions et les questions ouvertes : observateurs sous mesure quantifiée, systèmes 2×2 et commande événementielle, robustesse, problèmes ouverts, et pour finir le théorème du débit minimal. Les annexes C à G regroupent les rappels d'analyse, les corrigés, le glossaire, les codes et les crédits d'illustration.

En pratique : le chemin le plus court

Un lecteur pressé qui veut comprendre *l'idée* et rien d'autre peut lire la section 1.6, la section 1.8, puis le théorème 2.15 et sa figure. Cela fait une douzaine de pages et contient tout le mécanisme ; le reste en donne les constantes et l'extension à la dimension infinie.

Chapitre 2

La quantification en dimension finie

Ce chapitre traite entièrement le cas $\dot{x} = Ax + Bu$. Il suit la ligne de démonstration ouverte par Brockett et Liberzon [4] puis généralisée par Liberzon [6] : ce sont les articles fondateurs du domaine, et leur façon de raisonner (deux régions invariantes emboîtées, un temps de séjour explicite, une commutation de l'échelle) est exactement celle que l'on transportera en dimension infinie au chapitre 3. On l'expose ici lentement, en détaillant chaque étape.

2.1 Boîte à outils : Lyapunov, ISS, comparaison

Ce chapitre rassemble, sans démonstration longue, les outils utilisés dans toute le chapitre. Le lecteur qui les connaît peut le sauter ; il y trouvera néanmoins les *conventions de constantes* utilisées ensuite.

2.1.1 Lyapunov quadratique pour un système linéaire

Théorème 2.1 (équation de Lyapunov). *Soit $A_c \in \mathbb{R}^{n \times n}$. Les assertions suivantes sont équivalentes :*

1. A_c est Hurwitz (toutes ses valeurs propres sont de partie réelle < 0) ;
2. pour toute $Q = Q^\top \succ 0$, il existe une unique $P = P^\top \succ 0$ telle que

$$A_c^\top P + P A_c = -Q. \quad (2.1)$$

De plus $P = \int_0^\infty e^{A_c^\top s} Q e^{A_c s} ds$.

On pose alors $V(x) = x^\top P x$ et l'on dispose des *inégalités de Rayleigh*

$$\lambda_{\min}(P) \|x\|^2 \leq V(x) \leq \lambda_{\max}(P) \|x\|^2. \quad (2.2)$$

Le rapport

$$\kappa_P := \sqrt{\frac{\lambda_{\max}(P)}{\lambda_{\min}(P)}} \geq 1 \quad (2.3)$$

mesure l'*excentricité* des ellipsoïdes de niveau de V . Il apparaîtra partout : c'est le prix payé pour remplacer des boules par des ellipsoïdes.

En pratique : choisir Q

Prendre $Q = I$ est le choix par défaut. On peut faire mieux : maximiser $\lambda_{\min}(Q) / \|PBK\|$ (ou minimiser κ_P) est un problème LMI, donc numériquement facile. Un bon conditionnement de P améliore *directement* la condition sur Δ/M (voir théorème 2.15).

2.1.2 Stabilité entrée-état

La notion qui suit, introduite par Sontag [32] et caractérisée dans [33], est l'outil central de tout ce cours. On en trouvera un exposé complet dans [34, ch. 4.9].

Définition 2.2 (ISS). Le système $\dot{x} = f(x, d)$ est ISS s'il existe $\beta \in \mathcal{KL}$ et $\gamma \in \mathcal{K}_\infty$ tels que pour toute entrée d mesurable bornée et toute condition initiale,

$$\|x(t)\| \leq \beta(\|x(0)\|, t) + \gamma\left(\sup_{0 \leq s \leq t} \|d(s)\|\right).$$

Rappel : classes $\mathcal{K}$, $\mathcal{K}_\infty$, $\mathcal{KL}$

$\alpha \in \mathcal{K}$ si $\alpha : \mathbb{R}_+ \rightarrow \mathbb{R}_+$ est continue, strictement croissante, $\alpha(0) = 0$; $\mathcal{K}_\infty$ si de plus $\alpha(s) \rightarrow \infty$. $\beta \in \mathcal{KL}$ si $\beta(\cdot, t) \in \mathcal{K}$ pour tout t et $\beta(s, t) \downarrow 0$ quand $t \rightarrow \infty$.

Pour un système linéaire $\dot{x} = A_c x + B d$ avec A_c Hurwitz, on a la forme explicite : il existe $M_\sigma \geq 1$ et $\sigma > 0$ tels que

$$\|e^{A_c t}\| \leq M_\sigma e^{-\sigma t}, \quad (2.4)$$

d'où, par la formule de variation de la constante,

$$|x(t)| \leq M_\sigma e^{-\sigma(t-t_0)} |x(t_0)| + \frac{M_\sigma}{\sigma} \|B\| \sup_{t_0 \leq s \leq t} |d(s)|. \quad (2.5)$$

Le couple (M_σ, σ) est le *seul* ingrédient dont on aura besoin.

Intuition : à quoi sert l'ISS ici ?

Toute cette théorie consiste à écrire

$$\text{boucle fermée quantifiée} = \text{boucle fermée nominale} + \text{perturbation } d$$

puis à dire : la boucle nominale est ISS, et d est petite (car $\leq \Delta\mu$). Il ne reste plus qu'à fermer la boucle entre « d petite parce que l'état est petit » et « l'état petit parce que d est petite » : c'est l'argument de *petit gain*.

2.1.3 Lemme de comparaison et Grönwall

Lemme 2.3 (Grönwall différentiel). Si $\dot{v}(t) \leq \alpha v(t) + \beta(t)$ avec $v \geq 0$, alors $v(t) \leq e^{\alpha(t-t_0)} v(t_0) + \int_{t_0}^t e^{\alpha(t-s)} \beta(s) ds$.

Lemme 2.4 (décroissance exponentielle d'une fonction de Lyapunov). Si $\dot{V} \leq -\alpha V$ sur un intervalle $[t_0, t_1]$, alors $V(t) \leq e^{-\alpha(t-t_0)} V(t_0)$ sur cet intervalle. En particulier, pour passer de $V(t_0) = V_0$ à $V \leq V_1 < V_0$ il suffit d'attendre

$$T \geq \frac{1}{\alpha} \ln \frac{V_0}{V_1}. \quad (2.6)$$

Cette formule anodine (2.6) est la clé du calcul explicite du *temps de séjour* T à la section 2.3 : c'est elle qui transforme « en temps fini » en « en au plus T secondes », ce qui rend la loi implémentable.

2.2 Retour d'état quantifié à zoom figé : stabilité pratique

2.2.1 Le modèle et la loi de commande

On considère le système linéaire

$$\dot{x} = Ax + Bu, \quad x \in \mathbb{R}^n, u \in \mathbb{R}^m, \quad (2.7)$$

avec (A, B) stabilisable : il existe K tel que $A + BK$ soit Hurwitz. On fixe $Q \succ 0$ et $P \succ 0$ solution de (2.1) avec $A_c = A + BK$, et $V(x) = x^\top Px$.

Le contrôleur ne mesure pas x mais $q_\mu(x)$. Il applique la loi dite de *certitude équivalente* (*certainty equivalence*), qui est celle retenue dans toute la littérature sur le sujet depuis [4] :

$$u = K q_\mu(x). \quad (2.8)$$

Intuition : certitude équivalente

« Je fais comme si la mesure était exacte. » C'est le réflexe naturel, et il est *presque* correct : en posant $e(x) := q_\mu(x) - x$,

$$\dot{x} = (A + BK)x + BK e(x). \quad (2.9)$$

La boucle fermée est donc **la boucle nominale perturbée par BKe** . Tout le travail consiste à contrôler e .

On introduit la constante de gain

$$\gamma := \frac{2 \|PBK\|}{\lambda_{\min}(Q)} \quad (2.10)$$

et le conditionnement κ_P de (2.3).

2.2.2 Décroissance de V hors saturation

Lemme 2.5 (borne fondamentale). *Supposons $\mu > 0$ constant et $\|x\| \leq M\mu$ (pas de saturation). Alors, le long de (2.9),*

$$\dot{V}(x) \leq -\lambda_{\min}(Q) \|x\| (\|x\| - \gamma\Delta\mu). \quad (2.11)$$

En particulier $\dot{V} < 0$ dès que $\|x\| > \gamma\Delta\mu$.

Démonstration. En dérivant V le long de (2.9) :

$$\dot{V} = x^\top [(A + BK)^\top P + P(A + BK)]x + 2x^\top PBK e = -x^\top Qx + 2x^\top PBK e.$$

On majore $-x^\top Qx \leq -\lambda_{\min}(Q) \|x\|^2$ et $2x^\top PBK e \leq 2 \|PBK\| \|x\| \|e\|$. Hors saturation, $\|e\| \leq \Delta\mu$ (proposition 1.8), d'où

$$\dot{V} \leq -\lambda_{\min}(Q) \|x\|^2 + 2 \|PBK\| \Delta\mu \|x\| = -\lambda_{\min}(Q) \|x\| \left(\|x\| - \frac{2\|PBK\|}{\lambda_{\min}(Q)} \Delta\mu \right). \quad \square$$

Remarque 2.6 (homogénéité). Noter que (2.11) est *homogène* : μ n'apparaît que via le produit $\Delta\mu$. Cela signifie que le problème est *invariant d'échelle* : c'est cette invariance qui rendra le temps de séjour T indépendant de μ (théorème 2.9), fait remarquable et extrêmement utile en pratique.

2.2.3 Les deux ellipsoïdes emboîtés

L'ingrédient géométrique du schéma est le suivant : on encadre la « zone sûre » par deux ellipsoïdes de niveau de V .

Définition 2.7. Pour $\mu > 0$ et un paramètre de marge $\varepsilon > 0$, on pose

$$\mathcal{R}_1(\mu) := \{x : V(x) \leq \lambda_{\min}(P)M^2\mu^2\}, \quad (2.12)$$

$$\mathcal{R}_2(\mu) := \{x : V(x) \leq \lambda_{\max}(P)\gamma^2\Delta^2(1+\varepsilon)^2\mu^2\}. \quad (2.13)$$

Lemme 2.8 (encadrement par des boules). *On a*

$$\mathcal{R}_1(\mu) \subset \{\|x\| \leq M\mu\}, \quad \{\|x\| \leq \gamma\Delta(1+\varepsilon)\mu\} \subset \mathcal{R}_2(\mu).$$

Démonstration. Si $V(x) \leq \lambda_{\min}(P)M^2\mu^2$ alors $\lambda_{\min}(P)\|x\|^2 \leq V(x) \leq \lambda_{\min}(P)M^2\mu^2$, donc $\|x\| \leq M\mu$. Si $\|x\| \leq \gamma\Delta(1+\varepsilon)\mu$ alors $V(x) \leq \lambda_{\max}(P)\|x\|^2 \leq \lambda_{\max}(P)\gamma^2\Delta^2(1+\varepsilon)^2\mu^2$. $\square$

Ainsi $\mathcal{R}_1$ garantit l'absence de saturation, et $\mathcal{R}_2$ contient la bande ultime. Pour que le schéma ait un sens il faut que le second soit *strictement inclus* dans le premier.

Condition d'emboîtement

L'inclusion $\mathcal{R}_2(\mu) \subset \mathcal{R}_1(\mu)$ équivaut à

$$\lambda_{\max}(P)\gamma^2\Delta^2(1+\varepsilon)^2 \leq \lambda_{\min}(P)M^2,$$

c'est-à-dire, en prenant la racine carrée (les deux membres sont des carrés!),

$$\boxed{\frac{M}{\Delta} \geq \kappa_P \gamma (1+\varepsilon), \quad \kappa_P = \sqrt{\lambda_{\max}(P)/\lambda_{\min}(P)}}. \quad (2.14)$$

Noter que (2.14) est *homogène* : les deux membres sont sans dimension. C'est le test de cohérence évoqué à la section B.5 ; une condition qui comparerait Δ à M^2 serait nécessairement fautive. La lecture est immédiate : **le nombre de niveaux M/Δ doit dépasser le gain γ de la boucle, corrigé par l'excentricité κ_P des ellipsoïdes et par la marge $(1+\varepsilon)$.**




FIGURE 2.1 : Les deux ellipsoïdes. $\mathcal{R}_1$ est la zone sans saturation, $\mathcal{R}_2$ la zone atteinte en temps fini. Les cercles pointillés sont les boules inscrite/circonscrite ; l'écart entre ellipses et cercles est mesuré par κ_P .

2.2.4 Invariance et contraction en temps *explicitement* borné

Le résultat suivant est la version quantitative du lemme d'invariance de [4, Lemme 1] : on y calcule explicitement le temps de séjour, au lieu de se contenter d'un « en temps fini ». C'est cette valeur explicite qui servira à régler la période de commutation.

Théorème 2.9 (invariance et contraction, μ figé). *Supposons (2.14) satisfaite avec inégalité stricte, et $\mu > 0$ constant. Posons*

$$\alpha := \frac{\varepsilon}{1 + \varepsilon} \cdot \frac{\lambda_{\min}(Q)}{\lambda_{\max}(P)} > 0, \quad \Omega := \frac{\kappa_P \gamma \Delta (1 + \varepsilon)}{M} \in (0, 1), \quad (2.15)$$

$$T := \frac{2}{\alpha} \ln \frac{1}{\Omega}. \quad (2.16)$$

Alors, le long de (2.9) :

1. $\mathcal{R}_1(\mu)$ et $\mathcal{R}_2(\mu)$ sont positivement invariants ;
2. toute trajectoire issue de $\mathcal{R}_1(\mu)$ appartient à $\mathcal{R}_2(\mu)$ pour tout $t \geq T$;
3. $\mathcal{R}_2(\mu) \subset \mathcal{R}_1(\Omega\mu)$.

En particulier T ne dépend **pas** de μ .

Démonstration. (i) *Décroissance sur la couronne.* Soit $x \in \mathcal{R}_1(\mu) \setminus \text{int } \mathcal{R}_2(\mu)$. Par le lemme 2.8, $\|x\| \leq M\mu$: le lemme 2.5 s'applique. De plus $V(x) > \lambda_{\max}(P)\gamma^2\Delta^2(1 + \varepsilon)^2\mu^2$ entraîne, via $V(x) \leq \lambda_{\max}(P)\|x\|^2$,

$$\|x\| > \gamma\Delta(1 + \varepsilon)\mu \implies \|x\| - \gamma\Delta\mu > \frac{\varepsilon}{1 + \varepsilon} \|x\|.$$

En reportant dans (2.11) :

$$\dot{V} \leq -\lambda_{\min}(Q) \frac{\varepsilon}{1 + \varepsilon} \|x\|^2 \leq -\frac{\varepsilon}{1 + \varepsilon} \frac{\lambda_{\min}(Q)}{\lambda_{\max}(P)} V = -\alpha V.$$

(ii) *Invariance.* Sur la frontière de $\mathcal{R}_1(\mu)$ on a $\dot{V} \leq -\alpha V < 0$: le champ rentre, donc $\mathcal{R}_1(\mu)$ est invariant. Même argument sur $\partial\mathcal{R}_2(\mu)$.

(iii) *Temps de traversée.* Tant que la trajectoire reste dans la couronne, $V(t) \leq e^{-\alpha t} V(0) \leq e^{-\alpha t} \lambda_{\min}(P) M^2 \mu^2$. On atteint le niveau $\lambda_{\max}(P)\gamma^2\Delta^2(1 + \varepsilon)^2\mu^2$ au plus tard lorsque

$$e^{-\alpha t} \lambda_{\min}(P) M^2 \mu^2 = \lambda_{\max}(P)\gamma^2\Delta^2(1 + \varepsilon)^2\mu^2,$$

soit, en utilisant $\Omega = \kappa_P \gamma \Delta (1 + \varepsilon) / M$,

$$t = \frac{1}{\alpha} \ln \frac{\lambda_{\min}(P) M^2}{\lambda_{\max}(P) \gamma^2 \Delta^2 (1 + \varepsilon)^2} = \frac{1}{\alpha} \ln \frac{1}{\Omega^2} = T.$$

Les μ^2 se simplifient : c'est là qu'apparaît l'invariance d'échelle.

(iv) *Emboîtement décalé.* $x \in \mathcal{R}_2(\mu)$ signifie $V(x) \leq \lambda_{\max}(P)\gamma^2\Delta^2(1 + \varepsilon)^2\mu^2 = \lambda_{\min}(P)M^2(\kappa_P\gamma\Delta(1 + \varepsilon)/M)^2\mu^2 = \lambda_{\min}(P)M^2(\Omega\mu)^2$, c'est-à-dire $x \in \mathcal{R}_1(\Omega\mu)$. $\square$

La démonstration originale, pas à pas

Le théorème 2.9 ci-dessus est une réécriture du lemme 1 de Liberzon [6, §3.1], lui-même issu de [4]. Comme l'énoncé original est court au point d'être elliptique, et que c'est le modèle que l'on suivra ensuite en dimension infinie, il vaut la peine de le refaire lentement, en explicitant chaque passage. Le lecteur débutant est invité à faire cette section avec un papier ; il n'y a rien d'autre à savoir ensuite.

Étape 0 : ce que l'on cherche. On veut montrer que, à μ figé, l'état ne peut pas s'échapper et finit par entrer dans une petite zone, *en un temps que l'on sait calculer*. La difficulté est qu'on ne peut rien dire hors de la portée : la seule zone où l'on contrôle quoi que ce soit est $\{\|x\| \leq M\mu\}$. Il faut donc que la « zone d'arrivée » soit strictement à l'intérieur de la « zone de départ », et que la zone de départ soit elle-même dans la portée. Trois emboîtements, donc, et c'est précisément ce qu'organise le lemme 2.8 :

$$\underbrace{\{\|x\| \leq \gamma\Delta(1+\varepsilon)\mu\}}_{B_2} \subset \mathcal{R}_2(\mu) \subset \mathcal{R}_1(\mu) \subset \underbrace{\{\|x\| \leq M\mu\}}_{B_1}.$$

Les deux inclusions extrêmes sont gratuites (c'est l'inégalité de Rayleigh $\lambda_{\min}(P) \|x\|^2 \leq V(x) \leq \lambda_{\max}(P) \|x\|^2$) ; celle du milieu est *exactement* l'hypothèse (2.14). C'est la figure 2 de [6, §3.1].

Étape 1 : la dérivée de V , sans rien cacher. Partons de la boucle fermée (2.9). Le calcul de $\dot{V}$ se fait en trois lignes, mais chacune mérite d'être justifiée.

$$\begin{aligned} \dot{V} &= \dot{x}^\top P x + x^\top P \dot{x} && (P \text{ symétrique}) \\ &= x^\top [(A+BK)^\top P + P(A+BK)]x + 2x^\top PBK e && (\text{on développe, } e = q_\mu(x) - x) \\ &= -x^\top Q x + 2x^\top PBK e && (\text{équation de Lyapunov (2.1)}). \end{aligned}$$

Le premier terme est le « bon » terme, celui de la boucle nominale ; le second est tout le mal que fait la quantification. On le majore par Cauchy-Schwarz : $2x^\top PBK e \leq 2\|PBK\| \|x\| \|e\|$. Ici, et seulement ici, intervient la propriété (P1) : tant que $\|x\| \leq M\mu$, on a $\|e\| \leq \Delta\mu$. D'où

$$\dot{V} \leq -\lambda_{\min}(Q) \|x\|^2 + 2\|PBK\| \Delta\mu \|x\| = -\lambda_{\min}(Q) \|x\| (\|x\| - \gamma\Delta\mu),$$

avec $\gamma = 2\|PBK\|/\lambda_{\min}(Q)$ comme en (2.10). C'est (2.11), et c'est l'inégalité (11) de [6, §3.1].

Intuition : lire cette inégalité

Elle dit une chose et une seule : *il y a un rayon critique $\gamma\Delta\mu$* . Au-delà, V décroît ; en deçà, on ne sait plus rien. Le rayon critique est proportionnel à $\Delta\mu$, c'est-à-dire à la résolution effective. Toute la stratégie du zoom consiste à faire tendre ce rayon vers zéro en faisant tendre μ vers zéro, mais sans jamais sortir de $M\mu$.

Étape 2 : la couronne, et la marge ε . Liberzon n'utilise pas directement l'inégalité ci-dessus, mais sa version « avec marge » : on se restreint à la couronne

$$\gamma\Delta(1+\varepsilon)\mu \leq \|x\| \leq M\mu,$$

sur laquelle $\|x\| - \gamma\Delta\mu \geq \frac{\varepsilon}{1+\varepsilon} \|x\|$. Pourquoi introduire ε ? Parce que sans marge, $\dot{V}$ pourrait tendre vers zéro en approchant le rayon critique, et le temps de traversée serait infini. La marge ε achète une vitesse de décroissance *strictement* négative, donc un temps fini. C'est le seul rôle de ce paramètre, et c'est pourquoi il apparaît partout ensuite : ε est le prix d'un temps de séjour calculable.

Étape 3 : le temps de séjour, version originale. Sur la couronne, on majore $\dot{V}$ non pas par $-\alpha V$ mais par une *constante* négative, ce qui est plus élémentaire et donne la formule de [6, éq. (12)]. En effet, sur la couronne,

$$\dot{V} \leq -\lambda_{\min}(Q) \|x\| \cdot \frac{\varepsilon}{1+\varepsilon} \|x\| \leq -\lambda_{\min}(Q) \gamma\Delta(1+\varepsilon)\mu \cdot \gamma\Delta\varepsilon\mu =: -c_\star < 0,$$

où l'on a simplement utilisé $\|x\| \geq \gamma\Delta(1+\varepsilon)\mu$ dans le premier facteur et $\frac{\varepsilon}{1+\varepsilon}\|x\| \geq \gamma\Delta\varepsilon\mu$ dans le second. Comme V décroît au moins à la vitesse $c_\star$, partant du niveau $\lambda_{\min}(P)M^2\mu^2$ et devant atteindre le niveau $\lambda_{\max}(P)\gamma^2\Delta^2(1+\varepsilon)^2\mu^2$, on traverse en au plus

$$T_{\text{BL}} := \frac{\lambda_{\min}(P)M^2 - \lambda_{\max}(P)\gamma^2\Delta^2(1+\varepsilon)^2}{\lambda_{\min}(Q)\gamma^2\Delta^2\varepsilon(1+\varepsilon)}. \quad (2.17)$$

Les μ^2 se simplifient entre numérateur et dénominateur : **le temps de séjour ne dépend pas de μ** . C'est le fait remarquable sur lequel repose toute la suite, et il tient à l'homogénéité de degré 2 de V .

Remarque 2.10 (deux bornes, la même idée). La borne T de (2.16) et la borne T_{BL} de (2.17) sont toutes deux valides ; la première vient d'une décroissance exponentielle ($\dot{V} \leq -\alpha V$), la seconde d'une décroissance linéaire ($\dot{V} \leq -c_\star$). La seconde est celle de l'article original, la première est en général meilleure quand M/Δ est grand, car la décroissance exponentielle exploite le fait que $\dot{V}$ est bien plus négatif au début de la traversée qu'à la fin. En pratique on prendra $T = \min\{T_{\text{BL}}, \frac{2}{\alpha} \ln \frac{1}{\Omega}\}$; le code compagnon calcule les deux et retient la plus petite.

Étape 4 : le facteur de contraction. Il reste à voir pourquoi la zone d'arrivée à l'échelle μ est exactement la zone de départ à l'échelle $\Omega\mu$. C'est un calcul d'une ligne, mais c'est le cœur du mécanisme :

$$\mathcal{R}_2(\mu) = \{V \leq \lambda_{\max}(P)\gamma^2\Delta^2(1+\varepsilon)^2\mu^2\} = \left\{V \leq \lambda_{\min}(P)M^2 \underbrace{\left(\frac{\kappa_P\gamma\Delta(1+\varepsilon)}{M}\right)^2}_{=\Omega^2} \mu^2\right\} = \mathcal{R}_1(\Omega\mu).$$

C'est le « Λ » de [6, §3.1], et $\Omega < 1$ est *équivalent* à la condition d'emboîtement (2.14). Autrement dit : **il y a contraction si et seulement si les deux ellipsoïdes sont strictement emboîtés**. On ne peut pas faire plus serré.

Attention : ce que la preuve n'utilise jamais

Elle n'utilise ni la forme des cellules de quantification, ni leur nombre, ni la régularité de q , ni aucune hypothèse statistique sur l'erreur. Seulement (P1) à l'étape 1 et, pour la phase 1, (P2). C'est pour cela que le même raisonnement se transporte tel quel aux quantificateurs à cellules quelconques [6, §2], puis en dimension infinie (chapitre 3), où V devient une norme sup et l'inégalité différentielle une estimation ISS.

Le mécanisme, en une image

$$x \in \mathcal{R}_1(\mu) \xrightarrow{\text{on attend } T} x \in \mathcal{R}_2(\mu) \xrightarrow{\text{(iii)}} x \in \mathcal{R}_1(\Omega\mu) \xrightarrow{\mu \leftarrow \Omega\mu} \text{on recommence.}$$

À chaque tour, μ est multiplié par $\Omega < 1$ et l'état reste confiné dans un ensemble qui rétrécit du même facteur. Comme T est indépendant de μ , *tous les tours durent la même chose* : la convergence est **exponentielle**, de taux $\ln(1/\Omega)/T$.

2.2.5 Corollaire : stabilité pratique à μ figé

C'est le meilleur résultat accessible sans commutation. Pour les EDP, l'analogie est établi par Tanwani, Prieur et Tarbouriech [22], qui obtiennent des bornes ultimes explicites par une fonctionnelle de Lyapunov.

Corollaire 2.11. *Sous (2.14) et pour μ constant, toute trajectoire issue de $\mathcal{R}_1(\mu)$ vérifie*

$$\limsup_{t \rightarrow \infty} \|x(t)\| \leq \kappa_P \gamma \Delta (1 + \varepsilon) \mu = \Omega M \mu.$$

Démonstration. Immédiat : $x(t) \in \mathcal{R}_2(\mu)$ pour $t \geq T$, et $\mathcal{R}_2(\mu) \subset \{\|x\| \leq \kappa_P \gamma \Delta (1 + \varepsilon) \mu\}$ par (2.2). $\square$

C'est *exactement* le phénomène observé sur le thermostat du chapitre 1 : convergence vers une bande proportionnelle à la résolution, pas vers zéro.

2.3 La stratégie hybride : stabilité asymptotique globale

2.3.1 Vue d'ensemble

La stratégie exposée dans ce chapitre est celle de Brockett et Liberzon [4], généralisée aux systèmes non linéaires par Liberzon [6]. On la présente ici avec des constantes explicites, de façon à pouvoir la transporter telle quelle en dimension infinie.

L'idée est maintenant limpide : on enchaîne

- **Phase 1** ($u \equiv 0$, $\mu \uparrow$) : on augmente la portée jusqu'à *capturer* l'état, c'est-à-dire jusqu'à savoir, avec la seule information quantifiée, que $x \in \mathcal{R}_1(\mu)$;
- **Phase 2** ($u = Kq_\mu(x)$, $\mu \downarrow$ par paliers Ω toutes les T secondes) : on applique le théorème 2.9 en boucle.




FIGURE 2.2 : L'automate hybride à deux états.

2.3.2 L'événement de capture est-il détectable ?

C'est le point délicat, et c'est là que (P2) intervient. Le contrôleur ne voit que $q_\mu(x)$; il doit décider s'il peut passer en phase 2. On pose

$$\vartheta := \frac{1}{\kappa_P} \in (0, 1] \quad (2.18)$$

et l'on définit l'**événement de capture**

$$\mathcal{E}(t) : \quad \|q_\mu(x(t))\| \leq (\vartheta M - \Delta) \mu(t). \quad (2.19)$$

Lemme 2.12 (l'événement est sûr et atteignable). *Supposons $\vartheta M > 2\Delta$, c'est-à-dire*

$$\frac{M}{\Delta} > 2\kappa_P. \quad (2.20)$$

Alors :

1. (sûreté) Si $\mathcal{E}(t)$ est vrai, alors $x(t) \in \mathcal{R}_1(\mu(t))$.
2. (atteignabilité) Si $\|x(t)\| \leq (\vartheta M - 2\Delta) \mu(t)$, alors $\mathcal{E}(t)$ est vrai.

Démonstration. (1) Supposons d'abord, par l'absurde, $\|x\| > M\mu$. Alors (P2) (proposition 1.8) donne $\|q_\mu(x)\| > (M - \Delta)\mu \geq (\vartheta M - \Delta)\mu$ puisque $\vartheta \leq 1$: contradiction avec $\mathcal{E}$. Donc $\|x\| \leq M\mu$ et l'on peut appliquer (P1) :

$$\|x\| \leq \|q_\mu(x)\| + \|q_\mu(x) - x\| \leq (\vartheta M - \Delta)\mu + \Delta\mu = \vartheta M\mu.$$

Alors $V(x) \leq \lambda_{\max}(P)\vartheta^2 M^2 \mu^2 = \lambda_{\max}(P) \frac{\lambda_{\min}(P)}{\lambda_{\max}(P)} M^2 \mu^2 = \lambda_{\min}(P) M^2 \mu^2$, donc $x \in \mathcal{R}_1(\mu)$.

(2) Si $\|x\| \leq (\vartheta M - 2\Delta)\mu \leq M\mu$, (P1) donne $\|q_\mu(x)\| \leq \|x\| + \Delta\mu \leq (\vartheta M - \Delta)\mu$. □

Intuition : pourquoi $\vartheta = 1/\kappa_P$?

Parce que l'on veut conclure sur un *ellipsoïde* ($\mathcal{R}_1$) à partir d'une information sur une *norme* (une boule). Le facteur κ_P est exactement le prix de cette conversion. Si $P = I$ (par exemple si $A + BK$ est normale et $Q = I$), alors $\kappa_P = 1$, $\vartheta = 1$: pas de perte.

2.3.3 Phase 1 : capture en temps fini

En phase 1 on impose $u \equiv 0$; le système $\dot{x} = Ax$ peut croître, mais au plus exponentiellement :

$$\|x(t)\| \leq e^{\|A\|t} \|x(0)\|. \quad (2.21)$$

On fait croître μ *plus vite* que cette borne, par paliers : on fixe $\tau > 0$ (période de mise à jour) et $c > 1$ (facteur), et

$$\mu(t) = \mu_0 c^{\lfloor t/\tau \rfloor}, \quad \text{avec} \quad \beta := \frac{\ln c}{\tau} - \|A\| > 0. \quad (2.22)$$

Lemme 2.13 (capture). *Sous (2.20) et (2.22), l'événement $\mathcal{E}$ est vrai au plus tard à l'instant*

$$t_1^* \leq \frac{1}{\beta} \left[\ln c + \left(\ln \frac{\|x(0)\|}{(\vartheta M - 2\Delta)\mu_0} \right)_+ \right], \quad (2.23)$$

où $(\cdot)_+ = \max\{\cdot, 0\}$. À cet instant, $x(t_1^*) \in \mathcal{R}_1(\mu(t_1^*))$.

Démonstration. Comme $\lfloor t/\tau \rfloor > t/\tau - 1$, on a $\mu(t) \geq \mu_0 c^{t/\tau - 1}$. D'après (2.21), la condition suffisante $\|x(t)\| \leq (\vartheta M - 2\Delta)\mu(t)$ du lemme 2.12(2) est impliquée par

$$e^{\|A\|t} \|x(0)\| \leq (\vartheta M - 2\Delta)\mu_0 c^{t/\tau - 1},$$

soit, en passant au logarithme,

$$\ln \frac{\|x(0)\|}{(\vartheta M - 2\Delta)\mu_0} + \ln c \leq t \left(\frac{\ln c}{\tau} - \|A\| \right) = \beta t.$$

D'où (2.23). La conclusion sur $\mathcal{R}_1$ vient du lemme 2.12(1). □

Remarque 2.14 (dépendance logarithmique). t_1^* croît comme $\ln \|x(0)\|$. C'est cette dépendance logarithmique qui produira, dans les estimations finales, un *overshoot* polynomial en la condition initiale (une puissance de $\|x_0\|$) plutôt qu'une constante multiplicative : on retrouvera exactement ce phénomène en dimension infinie, cf. (3.15) et (3.62).

Attention : ne pas confondre « détecter » et « connaître »

Le contrôleur ne *connaît* pas $\|x(0)\|$, ni t_1^* : il *teste* l'inégalité (2.19), qui ne fait intervenir que des quantités qu'il possède ($q_\mu(x)$ et μ). Le lemme 2.13 dit seulement que ce test finit par réussir. C'est toute la beauté de (P2).

2.3.4 Théorème principal en dimension finie

Théorème 2.15 (stabilisation globale asymptotique par quantification dynamique). *Soit (A, B) stabilisable, K tel que $A + BK$ soit Hurwitz, P, Q comme en (2.1), γ et κ_P définis par (2.10) et (2.3). Supposons que le quantificateur satisfasse*

$$\boxed{\frac{M}{\Delta} > \max \{ \kappa_P \gamma (1 + \varepsilon), 2\kappa_P \}} \quad (2.24)$$

pour un $\varepsilon > 0$. Définissons α, Ω, T par (2.15) et (2.16), ϑ par (2.18), et la loi hybride

$$u(t) = \begin{cases} 0, & t \leq t_1^*, \\ K q_{\mu(t)}(x(t)), & t > t_1^*, \end{cases} \quad \mu(t) = \begin{cases} \mu_0 c^{\lfloor t/\tau \rfloor}, & t \leq t_1^*, \\ \Omega^{\lfloor (t-t_1^*)/T \rfloor} \mu(t_1^*), & t > t_1^*, \end{cases} \quad (2.25)$$

où t_1^* est le premier instant où (2.19) est vraie et où c, τ vérifient (2.22). Alors la boucle fermée est **globalement asymptotiquement stable** : pour toute condition initiale, $x(t) \rightarrow 0$, avec l'estimation explicite, pour $t \geq t_1^*$,

$$\|x(t)\| \leq \frac{M\mu(t_1^*)}{\Omega} \exp\left(-\frac{\ln(1/\Omega)}{T} (t - t_1^*)\right). \quad (2.26)$$

De plus le taux garanti vaut

$$\frac{\ln(1/\Omega)}{T} = \frac{\alpha}{2} = \frac{\varepsilon}{2(1+\varepsilon)} \cdot \frac{\lambda_{\min}(Q)}{\lambda_{\max}(P)}. \quad (2.27)$$

Démonstration. Étape 1 (capture). Par le lemme 2.13, $t_1^* < \infty$ et $x(t_1^*) \in \mathcal{R}_1(\mu'_0)$ avec $\mu'_0 := \mu(t_1^*)$.

Étape 2 (récurrence). Posons $t_k := t_1^* + kT$ et $\mu_k := \Omega^k \mu'_0$. Montrons par récurrence que $x(t_k) \in \mathcal{R}_1(\mu_k)$. C'est vrai pour $k = 0$. Supposons-le vrai au rang k . Sur $[t_k, t_{k+1})$, $\mu \equiv \mu_k$ est constant, donc le théorème 2.9 s'applique : $\mathcal{R}_1(\mu_k)$ est invariant (donc pas de saturation sur tout l'intervalle, ce qui légitime a posteriori l'usage de (P1)), et $x(t_{k+1}) = x(t_k + T) \in \mathcal{R}_2(\mu_k) \subset \mathcal{R}_1(\Omega\mu_k) = \mathcal{R}_1(\mu_{k+1})$.

Étape 3 (estimation entre les instants de commutation). Pour $t \in [t_k, t_{k+1})$, l'invariance donne $x(t) \in \mathcal{R}_1(\mu_k)$, donc $\|x(t)\| \leq M\mu_k = M\Omega^k \mu'_0$. Comme $k > \frac{t-t_1^*}{T} - 1$ et $\Omega < 1$,

$$\|x(t)\| \leq M\mu'_0 \Omega^{\frac{t-t_1^*}{T}-1} = \frac{M\mu'_0}{\Omega} e^{-\frac{\ln(1/\Omega)}{T}(t-t_1^*)},$$

ce qui est (2.26). Enfin (2.27) résulte de $T = \frac{2}{\alpha} \ln \frac{1}{\Omega}$. $\square$

Remarque 2.16 (un fait contre-intuitif mais important). D'après (2.27), **le taux de convergence garanti ne dépend pas du nombre de bits** ! Augmenter M/Δ diminue Ω (meilleure contraction par palier) mais allonge T dans la même proportion. Ce que gagnent les bits supplémentaires, c'est la *marge* ε que l'on peut se permettre : d'après (2.24), $\varepsilon < \frac{M}{\kappa_P \gamma \Delta} - 1$, et le taux $\frac{\varepsilon}{2(1+\varepsilon)} \frac{\lambda_{\min}(Q)}{\lambda_{\max}(P)}$ croît avec ε jusqu'à la limite $\frac{\lambda_{\min}(Q)}{2\lambda_{\max}(P)}$. Autrement dit :

*plus on a de bits, plus on peut être agressif ;
mais on ne dépassera jamais la moitié du taux de Lyapunov nominal.*

2.3.5 Recette de dimensionnement

Recette : concevoir une boucle quantifiée en dimension finie

1. Choisir K (placement de pôles, LQR...) tel que $A + BK$ soit Hurwitz.
2. Choisir $Q \succ 0$ (par défaut $Q = I$), résoudre (2.1) pour P .
3. Calculer $\lambda_{\min}(P)$, $\lambda_{\max}(P)$, κ_P , puis $\gamma = 2 \|PBK\| / \lambda_{\min}(Q)$.
4. Vérifier le budget matériel : $M/\Delta = 2^N$ pour un ADC N bits. Contrôler que $M/\Delta > 2\kappa_P$ et $\varepsilon_{\max} := \frac{M}{\kappa_P \gamma \Delta} - 1 > 0$.
5. Choisir $\varepsilon \in (0, \varepsilon_{\max})$: proche de $\varepsilon_{\max}$ pour un taux rapide, plus petit pour un T court et une marge de robustesse.
6. Calculer Ω , α , T par (2.15) et (2.16).
7. Choisir τ et c pour la phase 1 avec $\ln c > \|A\| \tau$ (par exemple $c = e^{2\|A\|\tau}$).
8. Implémenter le test (2.19) avec $\vartheta = 1/\kappa_P$.

2.4 Exemple numérique complet

Cette section fait le tour complet d'un cas concret : on part des matrices, on calcule toutes les constantes des théorèmes précédents, on lit ce qu'elles imposent, on choisit un réglage, et on regarde ce que donne la simulation. Rien n'est laissé à l'appréciation ; tous les nombres et toutes les figures qui suivent sont produits par le code compagnon `quantized_state_feedback.py` et `make_tradeoff_fig.py` (annexe F).

Les données

Prenons un double intégrateur instabilisé, exemple standard de la littérature :

$$A = \begin{pmatrix} 0 & 1 \\ 2 & 0 \end{pmatrix}, \quad B = \begin{pmatrix} 0 \\ 1 \end{pmatrix}, \quad K = \begin{pmatrix} -5 & -4 \end{pmatrix}, \quad Q = I.$$

Le système en boucle ouverte est instable (valeurs propres $\pm\sqrt{2}$) ; $A + BK$ a pour valeurs propres -1 et -3 . La résolution de (2.1) donne

$$P = \begin{pmatrix} 7/6 & 1/6 \\ 1/6 & 1/6 \end{pmatrix}, \quad \lambda_{\min}(P) = 0,1396, \quad \lambda_{\max}(P) = 1,1937,$$

d'où

$$\kappa_P = 2,924, \quad \|PBK\| = 1,509, \quad \gamma = 3,018, \quad \kappa_P \gamma = 8,826.$$

Ce que le quantificateur doit fournir

Avec le quantificateur des notes ($M = 6$, pas $h = 0,25$, donc $\Delta = h/2 = 0,125$, soit $M/\Delta = 48$, l'équivalent d'environ 5,6 bits) :

- condition de capture (2.20) : $48 > 2 \times 2,924 = 5,85$ ✓
- condition d'emboîtement (2.14) : $48 > 8,826(1+\varepsilon)$, donc marge maximale $\varepsilon_{\max} = 48/8,826 - 1 = 4,44$.

Autrement dit, 5,6 bits suffisent très largement ici. On verra au chapitre 3 que la même condition, en dimension infinie et avec un retard, en réclame une vingtaine : c'est tout l'écart entre les deux mondes.

Le compromis de réglage

Le seul degré de liberté restant est la marge ε . La table ci-dessous donne, pour chaque valeur, le facteur de contraction Ω , le taux α , les deux bornes de temps de séjour (celle de l'article original (2.17) et la borne exponentielle (2.16)) et le taux de convergence garanti $\ln(1/\Omega)/T$.

ε	Ω	α	T_{BL} (s)	T_{exp} (s)	taux garanti	commentaire
0,5	0,276	0,279	43,5	9,23	0,140	très prudent, T long
1	0,368	0,419	15,3	4,78	0,209	
2	0,552	0,558	4,09	2,13	0,279	bon compromis
3	0,736	0,628	1,35	0,98	0,314	réglage retenu
4	0,919	0,670	0,27	0,25	0,335	marge très faible
4,44	$\rightarrow 1$	0,683	$\rightarrow 0$	$\rightarrow 0$	0,341	limite, non admissible




FIGURE 2.3 : Le contenu de la table, en continu. À gauche, le facteur de contraction Ω croît linéairement avec la marge : plus on est agressif, moins on gagne à chaque palier. Au milieu, les deux bornes de temps de séjour ; la borne exponentielle (2.16) est partout meilleure que la borne linéaire (2.17) de l'article original, d'un facteur 4 environ pour les petites marges, et les deux se rejoignent près de $\varepsilon_{\max}$. À droite, le taux garanti $\ln(1/\Omega)/T$: il croît avec ε , mais très platement au-delà de $\varepsilon = 3$. **Lecture pratique** : on gagne presque tout entre $\varepsilon = 0$ et $\varepsilon = 3$, et presque rien ensuite, alors que le risque augmente. D'où le choix $\varepsilon = 3$. Trait pointillé noir : $\varepsilon = 3$; trait pointillé rouge : $\varepsilon_{\max} = 4,44$, valeur interdite.

En pratique : la théorie retrouve le réglage empirique

Un réglage que l'on trouve couramment en pratique, choisi à la main, est $\Omega \approx 0,7$ avec un temps de séjour de l'ordre de la seconde. La ligne $\varepsilon = 3$ de la table donne $\Omega = 0,736$ et $T = 0,98$ s : la formule certifie donc presque exactement ce que l'intuition suggère. Point de méthode important : les constantes de ce type de preuve sont conservatrices, mais pas absurdement, à condition de choisir la marge ε de façon agressive. Encore faut-il disposer des formules explicites pour pouvoir le faire.

La simulation

On simule

$$\dot{x} = \begin{pmatrix} 0 & 1 \\ 2 & 0 \end{pmatrix} x + \begin{pmatrix} 0 \\ 1 \end{pmatrix} u, \quad x(0) = (4, -3), \quad u = K q_{\mu}(x),$$

avec $M = 6$, $\Delta = 0,125$, dans trois configurations :

1. $\mu \equiv 0,05$ figé (portée $M\mu = 0,3$, très inférieure à $\|x(0)\| = 5$) : le quantificateur sature, la commande est bloquée à une valeur trop faible, **le système diverge** ;
2. $\mu \equiv 3$ figé (portée 18, mais résolution $\Delta\mu = 0,375$) : pas de saturation, mais l'état stagne dans une bande de taille $\approx 0,3$: **stabilité pratique seulement**, exactement le corollaire 2.11 ;

3. **loi hybride** du théorème 2.15 avec le réglage $\varepsilon = 3$ ci-dessus : phase 1 jusqu'à $t_1^* = 1,11$ s (l'état croît en boucle ouverte, c'est normal et c'est le prix de la capture), puis contraction géométrique. L'état tend vers 0.




FIGURE 2.4 : Les trois scénarios, en échelle logarithmique. Données produites par le code du §2.4.




FIGURE 2.5 : La variable de zoom : montée géométrique en phase 1 (paliers de durée $\tau = 0,1$ s, facteur $c = e^{2\|A\|\tau}$), puis descente géométrique en phase 2 (paliers de durée $T = 0,98$ s, facteur $\Omega = 0,735$).

Comment lire ces courbes

- **La croissance initiale de la courbe bleue n'est pas un bug.** En phase 1 la commande est nulle : le système, instable, s'éloigne. On paie la capture. C'est le prix à payer pour un résultat *global* : on ne suppose rien sur $x(0)$.
- $\mu(t)$ et $\|x(t)\|$ **décroissent de façon synchronisée** en phase 2. C'est la signature d'un schéma correctement réglé : si μ descendait plus vite que l'état, on re-saturerait ; s'il descendait moins vite, on perdrait en précision sans raison.
- **Le pic de commande est le vrai coût caché.** La figure 2.6 montre $|u| \approx 45$ à l'instant de capture, alors que le régime permanent demande une commande minuscule. Un actionneur réel saturerait. C'est l'argument le plus fort en faveur d'un μ_0 bien choisi : plus la phase 1 est longue, plus le pic est haut.




FIGURE 2.6 : La même loi hybride, vue de plus près. *En haut* : les deux composantes de l'état et la portée effective $M\mu/\Omega$ (pointillés), qui les encadre à tout instant après la capture, c'est la traduction graphique de l'invariance des ellipsoïdes. *Au milieu* : la variable de zoom en échelle logarithmique ; les deux pentes opposées sont les deux phases, et le sommet est l'instant de capture $t_1^* = 1,11$ s. *En bas* : la commande, identiquement nulle pendant la phase 1, on ne commande rien tant qu'on ne sait pas où l'on est, puis constante par morceaux, avec un pic initial important au moment où la boucle se ferme sur un état qui a eu le temps de croître. Figure produite par `quantized_state_feedback.py`.

- **La borne certifiée est conservatrice.** Le taux garanti est $\ln(1/\Omega)/T = 0,314 \text{ s}^{-1}$; le taux observé est bien plus rapide. C'est habituel : les constantes de Lyapunov majorent le pire cas sur toute l'ellipse.

En pratique : expériences à faire soi-même

1. Diminuer M/Δ jusqu'à violer (2.24) : observer la perte de convergence.
2. Diviser T par 4 (mise à jour trop rapide) : on re-sature, la trajectoire diverge. C'est le mécanisme d'échec le plus fréquent en pratique.
3. Ajouter un bruit de mesure d'amplitude η : constater que l'état converge vers une bande de taille $\sim \gamma\eta$ et que μ ne doit plus descendre en dessous de η/Δ (voir §B.3.1).
4. Refaire toute la table avec $Q = \text{diag}(1, 10)$: le rapport $\kappa_P\gamma$ diminue-t-il ? En déduire une heuristique de choix de Q .

Code

quantized_state_feedback.py et make_tradeoff_fig.py, dépôt https://github.com/Flo3221/codes_mini_cours_quantification.

Le script reproduit les trois scénarios et recalcule toutes les constantes certifiées κ_P , γ , Ω , T à partir de (A, B, K, Q) : intégration de (2.7) par Runge-Kutta d'ordre quatre, quantificateur uniforme saturé appliqué composante par composante, automate à deux phases codé par un simple drapeau. Modifier le système revient à changer trois lignes de données ; les formules, elles, sont exactement celles du théorème 2.15.

Exercice 2.1 (*). Montrer que $\gamma \geq 2 \|PBK\| / \lambda_{\max}(Q)$ et que le produit $\kappa_P\gamma$ est invariant par changement d'échelle $x \mapsto cx$. Pourquoi est-ce rassurant ?

Exercice 2.2. Écrire l'automate hybride de la figure 2.2 sous la forme (C, F, D, G) du formalisme de [35] (flux, saut) et identifier le temps de séjour minimal.

2.5 Variantes : entrée quantifiée, sortie quantifiée, secteur

2.5.1 Quantification de l'entrée

Supposons maintenant l'état parfaitement mesuré, mais l'actionneur quantifié :

$$u = q_\mu(Kx), \quad \dot{x} = Ax + Bu = (A + BK)x + B \underbrace{(q_\mu(Kx) - Kx)}_{=:d(t)}. \quad (2.28)$$

Lemme 2.17. Si $\|Kx\| \leq M\mu$, alors $\|d\| \leq \Delta\mu$ et

$$\dot{V} \leq -\lambda_{\min}(Q) \|x\|^2 + 2 \|PB\| \Delta\mu \|x\|.$$

Toutes les conclusions de la section 2.2 valent avec

$$\gamma_{in} := \frac{2 \|PB\|}{\lambda_{\min}(Q)}$$

à la place de γ , et la portée s'exprime sur Kx et non sur x .

Intuition : pourquoi le cas « entrée » est plus simple

Deux raisons.

1. Le gain vaut $\|PB\|$ au lieu de $\|PBK\|$: on ne paie pas le gain de retour K . Comme

$\|PBK\| \leq \|PB\| \|K\|$, on a $\gamma_{\text{in}} \leq \gamma$: la condition sur Δ/M est *moins* exigeante.

2. L'événement de capture porte sur Kx , qui est *connu exactement* (l'état n'est pas quantifié) : la détection est triviale, on n'a même plus besoin de (P2).

On retrouvera *exactement* ces deux phénomènes en dimension infinie : la condition du théorème sur l'entrée quantifiée (théorème 3.11) est plus permissive que celle sur les mesures quantifiées (théorème 3.4).


Attention : la saturation d'actionneur, elle, est physique

Une différence *qualitative* mérite d'être signalée. Quand la mesure sature, on perd de l'information mais on peut toujours agir. Quand l'*actionneur* sature, on perd la *puissance* : pour un système exponentiellement instable, il existe alors un domaine d'attraction fini, indépassable, même sans quantification. Les résultats globaux de ce chapitre supposent donc implicitement que $M\mu$ peut être rendu grand, c'est-à-dire que l'actionneur n'a pas de limite d'amplitude propre, seulement une limite de *résolution*.

2.5.2 Quantification de sortie et observateur

C'est le cas le plus réaliste : on mesure $y = Cx \in \mathbb{R}^p$, quantifiée.

2.5.2.1 Architecture



On prend L tel que $A - LC$ soit Hurwitz (possible si (C, A) est détectable) et

$$\dot{\hat{x}} = A\hat{x} + Bu + L(q_\mu(y) - C\hat{x}), \quad (2.29)$$

$$u = K\hat{x}. \quad (2.30)$$

2.5.2.2 Analyse

Posons $\tilde{x} := x - \hat{x}$ (erreur d'observation) et $e_y := q_\mu(y) - y$. Alors

$$\dot{\tilde{x}} = (A + BK)\tilde{x} - BK\tilde{x}, \quad (2.31)$$

$$\dot{\tilde{x}} = (A - LC)\tilde{x} - L e_y. \quad (2.32)$$

C'est une *cascade* : l'erreur d'observation perturbe la boucle de commande, mais pas l'inverse. On dispose de $P_c, P_o \succ 0$ avec $(A + BK)^\top P_c + P_c(A + BK) = -Q_c$ et $(A - LC)^\top P_o + P_o(A - LC) = -Q_o$.

Proposition 2.18 (stabilité pratique en retour de sortie). *Posons $W(x, \tilde{x}) = x^\top P_c x + m \tilde{x}^\top P_o \tilde{x}$ avec $m > 0$ assez grand. Si $\|y\| \leq M\mu$, alors il existe $\alpha_o > 0$ et $\gamma_o > 0$ (explicitement calculables à partir de P_c, P_o, Q_c, Q_o, K, L) tels que*

$$\dot{W} \leq -\alpha_o W \quad \text{dès que} \quad \|(x, \tilde{x})\| \geq \gamma_o \Delta\mu.$$

Esquisse. $\dot{W} \leq -\lambda_{\min}(Q_c) \|x\|^2 + 2 \|P_c B K\| \|x\| \|\tilde{x}\| - m \lambda_{\min}(Q_o) \|\tilde{x}\|^2 + 2m \|P_o L\| \|\tilde{x}\| \Delta\mu$. La forme quadratique en $(\|x\|, \|\tilde{x}\|)$ est définie négative dès que $m \lambda_{\min}(Q_c) \lambda_{\min}(Q_o) > \|P_c B K\|^2$, ce qui fixe m . On conclut comme au lemme 2.5. $\square$

2.5.2.3 La vraie difficulté : détecter la capture

Attention : ce qui change par rapport au retour d'état

En retour d'état, l'événement (2.19) garantissait $x \in \mathcal{R}_1(\mu)$. En retour de sortie, l'inégalité $\|q_\mu(y)\| \leq (\vartheta M - \Delta)\mu$ ne borne que Cx , pas x : les directions non observables *instantanément* échappent au test. Il faut donc utiliser l'observabilité sur une *fenêtre* de temps.

Recette : capture en retour de sortie

On suppose (C, A) observable, de sorte que le grammien $\mathcal{O}_{T_o} = \int_0^{T_o} e^{A^\top s} C^\top C e^{As} ds$ est inversible pour $T_o > 0$. En boucle ouverte ($u = 0$),

$$x(0) = \mathcal{O}_{T_o}^{-1} \int_0^{T_o} e^{A^\top s} C^\top y(s) ds,$$

donc $\|x(0)\| \leq \|\mathcal{O}_{T_o}^{-1}\| c_{T_o} \sup_{[0, T_o]} \|y\|$ avec $c_{T_o} = \int_0^{T_o} \|e^{A^\top s} C^\top\| ds$. On remplace alors l'événement ponctuel par :

$$\mathcal{E}_{\text{out}} : \sup_{s \in [t - T_o, t]} \|q_\mu(y(s))\| \leq (\vartheta_{\text{out}} M - \Delta)\mu(t),$$

avec ϑ_{out} ajusté de manière à absorber la constante $\|\mathcal{O}_{T_o}^{-1}\| c_{T_o}$. Le reste de la preuve est inchangé.

Théorème 2.19 (énoncé, sans preuve détaillée). *Si (A, B) est stabilisable, (C, A) observable, et si Δ/M est assez petit (condition analogue à (2.24) avec $\gamma_o, \kappa_{P_c}, \kappa_{P_o}$ et la constante d'observabilité), alors la loi hybride associée à (2.29) et (2.30) rend l'origine du système augmenté $(x, \tilde{x})$ globalement asymptotiquement stable.*

Le lecteur trouvera un traitement complet du retour de sortie quantifié dans [6]. On reprendra la même architecture en dimension infinie au section B.1.

2.5.3 L'autre école : quantificateur logarithmique et condition de secteur

Il existe une approche concurrente, très élégante, qu'il faut connaître pour lire la littérature.

Idée. On renonce à l'alphabet fini et l'on utilise un quantificateur *logarithmique* de densité $\rho \in (0, 1)$: $\mathcal{Q} = \{\pm \rho^k u_0\} \cup \{0\}$. Un tel quantificateur vérifie une *condition de secteur* :

$$q(z) = (1 + \delta(z))z, \quad |\delta(z)| \leq \delta_{\max} = \frac{1 - \rho}{1 + \rho}. \quad (2.33)$$

La boucle fermée $\dot{x} = (A + BK)x + BK\delta(x)x$ devient alors un système *incertain* avec incertitude bornée en norme, traitable par LMI ou H_∞ .

Théorème 2.20 (Elia-Mitter, Fu-Xie, forme informelle). *Pour un système linéaire à une entrée, il existe un quantificateur logarithmique le plus grossier possible (« coarsest ») qui stabilise quadratiquement ; sa densité optimale est déterminée par les valeurs propres instables de A :*

$$\rho^* = \frac{\prod_i |\lambda_i^u| - 1}{\prod_i |\lambda_i^u| + 1} \quad (\text{cas discret}).$$

Voir [5, 8].

	Zoom (ce cours)	Logarithmique
Alphabet	fini à chaque instant	infini (accumule en 0)
Débit binaire	fini	infini au sens strict
Contrôleur	dynamique (hybride)	statique
Résultat	stabilité asymptotique <i>globale</i>	stabilité quadratique
Outil	Lyapunov + invariance + temps de séjour	condition de secteur, LMI
Extension EDP	<i>oui</i> (sections 3 et 3)	difficile en norme sup

Chapitre 3

Quantification pour les EDP : cas hyperbolique

Tout ce qui précède se passait en dimension finie. Ce chapitre fait le saut. Il est organisé autour de deux résultats, traités chacun d'un seul tenant :

- la **section 3.2** traite la stabilisation frontière d'une EDP de transport dont les mesures (ou la commande) sont quantifiées. Elle suit intégralement Bekiaris-Liberis [24] : loi de commande, constantes de réglage, événement de capture, théorème, preuve, simulations.
- la **section 3.3** ajoute un retard d'entrée. Elle suit intégralement Koudohode et Bekiaris-Liberis [26] : reformulation du retard en EDP de transport, prédicteur quantifié, commande commutée, théorème principal, preuve, et le diagnostic (instructif) de l'écart entre le réglage certifié et le réglage praticable.

En pratique : ce qu'il faut avoir sous la main

Ce chapitre utilise une boîte à outils de dimension infinie : solution explicite de l'EDP de transport, backstepping frontière et transformation de Volterra, stabilité entrée-état en norme sup, normes pondérées, lemme de petit gain, et le dictionnaire entre EDP de transport et équations à retard. Tout cela est rassemblé, démontré et illustré à l'**annexe A**. La section 3.1 ci-dessous en donne le strict nécessaire, en une page, de façon à ce que le chapitre puisse se lire d'abord et l'annexe ensuite.

3.1 Le cadre en une page

Le système. On considère une EDP de transport scalaire du premier ordre, couplée à une commande frontière :

$$u_t(x, t) = u_x(x, t) + g(x) u(D, t) + \int_x^D \bar{g}(x, y) u(y, t) dy, \quad x \in [0, D], \quad t \geq 0, \quad (3.1)$$

$$u(D, t) = U(t), \quad (3.2)$$

d'état $u(\cdot, t) \in L^\infty(0, D)$ et de commande $U(t) \in \mathbb{R}$. Les termes en g et $\bar{g}$ rendent la boucle ouverte instable ; sans eux, l'état serait purgé en temps D et il n'y aurait rien à faire.

Pourquoi la norme sup. Parce que la quantification est une contrainte d'*amplitude* : elle s'exprime point par point, et $\|q_\mu(u) - u\|_\infty \leq \Delta\mu$ n'a pas d'équivalent commode en L^2 sans contrôler des dérivées spatiales. C'est l'argument explicite de [24], et c'est aussi ce qui rend tout ce chapitre plus proche des équations à retard que de l'analyse hilbertienne habituelle.

Le backstepping, en trois lignes. On cherche une transformation de Volterra inversible

$$w(x, t) = u(x, t) - \int_x^D k(x, y) u(y, t) dy$$

qui envoie (3.1) et (3.2) sur le système cible $w_t = w_x$, $w(D, t) = 0$, dont l'état est identiquement nul après D secondes. La loi nominale correspondante est

$$U_{\text{nom}}(t) = \int_0^D k(D, y) u(y, t) dy, \quad (3.3)$$

et l'équivalence des normes entre u et w se chiffre par deux constantes M_1, M_2 :

$$M_2 \|u\|_\infty \leq \|w\|_\infty \leq M_1 \|u\|_\infty.$$

Une troisième constante, M_3 , majore le gain du contrôleur nominal : $|U_{\text{nom}}(t)| \leq M_3 \|u(t)\|_\infty$. Ces trois constantes sont calculées explicitement à la section A.2.7, et le cas $\bar{g} \equiv 0$, g constante, qui donne un noyau en forme close, est traité à la section A.2.4.

Ce qui change par rapport à la dimension finie. Trois choses, et il faut les avoir en tête dès maintenant.

1. **Il n'y a plus de fonction de Lyapunov quadratique.** À la place, on établit des *estimations de solutions* et on ferme la boucle par un argument de **petit gain**. La condition d'emboîtement (2.14) du chapitre 2 devient une condition de petit gain, de même nature mais avec d'autres constantes.
2. **La quantification agit sur une fonction, pas sur un vecteur.** Quantifier $u(\cdot, t)$ signifie quantifier *en chaque point* x , puis intégrer : $\int_0^D k(D, y) q_\mu(u(y, t)) dy$. C'est le cas « mesures quantifiées ». Quantifier *après* l'intégrale, $q_\mu(\int_0^D k(D, y) u(y, t) dy)$, est un problème *différent* : c'est le cas « entrée quantifiée ». Les deux sont traités, et ils ne se déduisent pas l'un de l'autre.
3. **L'événement de capture porte sur une norme sup.** Le contrôleur teste $\|q_\mu(u(\cdot, t))\|_\infty \leq \text{seuil} \times \mu(t)$: c'est toujours (P2) qui garantit que ce test est fiable, mais il faut maintenant qu'il le soit *uniformément en* x .

Intuition : le fil ne se rompt jamais

Le lecteur qui a compris le chapitre 2 a compris l'essentiel de celui-ci. La structure est identique : une phase 1 en boucle ouverte où μ croît jusqu'à ce qu'on *sache* que l'état est dans la portée ; une phase 2 en boucle fermée où μ décroît par paliers de facteur Ω toutes les T secondes ; une condition sur M/Δ qui dit que la contraction l'emporte sur l'erreur. Seules les constantes changent, et elles deviennent nettement plus grosses.

3.2 Stabilisation frontière sous quantification, d'après Bekiaris-Liberis

Cette section entière suit [24]. Elle est volontairement traitée *d'un seul tenant* (loi, constantes, événement, théorème, preuve, variante « entrée », simulations) parce que c'est le contenu d'un seul article et qu'il n'y a aucune raison de le fragmenter. Les constantes ont été *re-dérivées* de façon auto-contenue à partir des lemmes de l'annexe A, ce qui donne des valeurs légèrement différentes de celles de l'article ; on discute l'écart à la remarque 3.10.

En pratique : plan de la section

1. la loi de commande quantifiée et les constantes de réglage ;
2. l'événement de capture, et pourquoi il est détectable ;
3. la loi de mise à jour de μ ;
4. le théorème de stabilité asymptotique globale et sa preuve en trois étapes ;
5. la variante « entrée quantifiée », qui est un autre théorème ;
6. les simulations, y compris les deux contre-exemples à μ figé.

3.2.1 La loi hybride sous quantification des mesures

On reprend le système (A.3) et (A.4), la transformation de backstepping de la section A.2, et l'on suppose désormais que l'état spatial $u(\cdot, t)$ n'est disponible qu'à travers sa version quantifiée. Le contenu de cette section suit [24] ; les constantes ont été *re-dérivées* de façon auto-contenue à partir des lemmes de la section A.3, ce qui donne des valeurs légèrement différentes de celles de l'article (voir la remarque 3.10).

3.2.1.1 La loi de commande

La loi ci-dessous et la stratégie de commutation qui l'accompagne sont celles de Bekiaris-Liberis [24, éq. (12) à (13)] ; on en donne ici une dérivation complète des constantes.

$$U(t) = \begin{cases} 0, & 0 \leq t \leq t_1^*, \\ \int_0^D k(D, x) q_\mu(u(x, t)) dx, & t > t_1^*, \end{cases} \quad (3.4)$$

où $q_\mu(u(x, t)) = \mu(t) q(u(x, t)/\mu(t))$ est appliqué *point par point* en x , et où μ suit la stratégie à deux phases.

Intuition : ce que l'on fait, littéralement

On remplace, dans la formule nominale (A.12), l'état par sa version quantifiée : c'est encore de la *certitude équivalente*. Le résultat est que la condition au bord du système cible n'est plus nulle mais égale à l'erreur de quantification intégrée :

$$w(D, t) = U(t) - \int_0^D k(D, x) u(x, t) dx = \int_0^D k(D, x) [q_\mu(u(x, t)) - u(x, t)] dx =: d(t). \quad (3.5)$$

La quantification devient une perturbation frontière. Le système cible est $w_t = w_x$, $w(D, t) = d(t)$: exactement le cadre du lemme A.11.

Lemme 3.1 (taille de la perturbation). *Si $\|u(\cdot, t)\|_\infty \leq M\mu(t)$ (pas de saturation), alors*

$$|d(t)| \leq M_3 \Delta \mu(t). \quad (3.6)$$

Démonstration. Par (P1) appliquée en chaque x (proposition 1.8), $|q_\mu(u(x, t)) - u(x, t)| \leq \Delta \mu$. Donc $|d(t)| \leq \int_0^D |k(D, x)| \Delta \mu dx \leq D \sup_x |k(D, x)| \Delta \mu = M_3 \Delta \mu$. $\square$

3.2.1.2 Les constantes de réglage

On choisit deux paramètres libres : $\lambda > 0$ (marge de petit gain) et $\nu \in (0, 1)$ (fraction du taux de décroissance exploitée). On pose alors, successivement :

$$\delta := \frac{\nu \ln(1 + \lambda)}{D} \quad (\text{taux de la norme pondérée}), \quad (3.7)$$

$$1 + M_0 := \frac{(1 + \lambda)^\nu}{1 - (1 + \lambda)^{\nu-1}} \quad (\text{overshoot de la boucle petit gain}), \quad (3.8)$$

$$\Omega := \frac{(1 + \lambda)(1 + M_0)^2 M_3 \Delta}{M_2 M} \quad (\text{facteur de contraction par palier}), \quad (3.9)$$

$$T := \frac{D}{\nu \ln(1 + \lambda)} \ln \frac{1 + M_0}{\Omega} \quad (\text{temps de séjour}), \quad (3.10)$$

$$\vartheta := \frac{M_2}{M_1(1 + M_0)} \in (0, 1] \quad (\text{marge de l'événement de capture}). \quad (3.11)$$

Remarque 3.2 (d'où sortent ces formules?). Elles ne sont pas parachutées : chacune est *exactement* ce qu'exige une étape de la preuve de la section 3.2.2.

- δ : le taux que l'on veut lire dans la norme pondérée. Le facteur $e^{\delta D} = (1 + \lambda)^\nu$ est le gain de l'estimation ISS (A.19).
- M_0 : le résultat de la fermeture petit gain (lemme A.17) avec un gain de boucle $(1 + \lambda)^{\nu-1} < 1$: c'est là que sert $\nu < 1$.
- Ω : choisi pour que $|d| \leq \frac{1}{1+\lambda} \|w\|_\infty$ dans la bande utile.
- T : choisi pour que la contraction compense l'overshoot $(1 + M_0)$.
- ϑ : choisi pour que la capture entraîne $\|w(\cdot, t_1^*)\|_\infty \leq \frac{M_2 M \mu}{1 + M_0}$, l'hypothèse d'entrée du lemme de contraction.

3.2.1.3 L'événement de capture (détectable !)

$$\mathcal{E}(t) : \quad |q_\mu(u(x, t))| \leq (\vartheta M - \Delta) \mu(t) \quad \forall x \in [0, D]. \quad (3.12)$$

Lemme 3.3 (sûreté et atteignabilité de l'événement). *Supposons $\vartheta M > 2\Delta$. Alors :*

1. si $\mathcal{E}(t)$ est vrai, alors $\|u(\cdot, t)\|_\infty \leq \vartheta M \mu(t)$, et donc $\|w(\cdot, t)\|_\infty \leq \frac{M_2 M \mu(t)}{1 + M_0}$;
2. si $\|u(\cdot, t)\|_\infty \leq (\vartheta M - 2\Delta) \mu(t)$, alors $\mathcal{E}(t)$ est vrai.

Démonstration. (1) Fixons x . Si l'on avait $|u(x, t)| > M \mu$, la propriété (P2) donnerait $|q_\mu(u(x, t))| > (M - \Delta) \mu \geq (\vartheta M - \Delta) \mu$ (car $\vartheta \leq 1$), contredisant $\mathcal{E}$. Donc $|u(x, t)| \leq M \mu$ et (P1) s'applique :

$$|u(x, t)| \leq |q_\mu(u(x, t))| + \Delta \mu \leq \vartheta M \mu.$$

En prenant le sup en x , puis en utilisant $\|w\|_\infty \leq M_1 \|u\|_\infty$ (proposition A.8) et $\vartheta = \frac{M_2}{M_1(1 + M_0)}$:

$$\|w\|_\infty \leq M_1 \vartheta M \mu = \frac{M_2 M \mu}{1 + M_0}.$$

(2) $|u(x, t)| \leq (\vartheta M - 2\Delta) \mu \leq M \mu$ donc (P1) donne $|q_\mu(u(x, t))| \leq |u(x, t)| + \Delta \mu \leq (\vartheta M - \Delta) \mu$. $\square$


Attention : c'est le point le plus subtil du sujet

Le test (3.12) ne fait intervenir que $q_\mu(u(\cdot, t))$ et μ : il est *implémentable*. Pourtant, il permet de conclure sur la quantité *non mesurée* $\|u(\cdot, t)\|_\infty$. C'est (P2), et elle seule, qui rend cela possible. Retirez (P2) et toute la construction s'effondre : on ne saurait jamais quand arrêter d'augmenter μ .

3.2.1.4 La loi de mise à jour de μ

$$\mu(t) = \begin{cases} \mu_0 c^{\lfloor t/\tau \rfloor}, & 0 \leq t \leq t_1^* \quad (\text{phase 1, } \frac{\ln c}{\tau} > \bar{M}_1), \\ \mu(t_1^*), & t_1^* < t \leq t_1^* + T, \\ \Omega \mu(t_1^* + (i-1)T), & t_1^* + (i-1)T < t \leq t_1^* + iT, \quad i \geq 2. \end{cases} \quad (3.13)$$

Ici $\bar{M}_1 = M_3/(DM_2)$ est le taux de croissance en boucle ouverte (lemme A.19) et t_1^* est le premier instant où $\mathcal{E}$ est vrai.



En pratique : une remarque d'implémentation souvent oubliée

Pendant le *premier* palier de la phase 2 ($i = 1$), μ reste *constant* : on ne réduit pas immédiatement. C'est indispensable : il faut d'abord laisser au système le temps T de contracter. Réduire μ dès la capture est l'erreur d'implémentation numéro un, et elle provoque une re-saturation immédiate.

3.2.2 Le théorème de stabilité et sa preuve

3.2.2.1 Énoncé

Théorème 3.4 (stabilisation globale sous mesures quantifiées). *Considérons (A.3) et (A.4) en boucle fermée par (3.4) et (3.13), avec les constantes (3.7) et (3.11). Si le quantificateur satisfait*

$$\frac{\Delta}{M} < \frac{M_2}{(1+M_0) \max \{(1+\lambda)(1+M_0)M_3, 2M_1\}}, \quad (3.14)$$

alors, pour toute donnée initiale $u_0 \in L^\infty([0, D]; \mathbb{R})$, la solution existe, est unique et globale, et

$$\|u(\cdot, t)\|_\infty \leq \gamma_* \|u_0\|_\infty^p \exp\left(-\frac{\ln(1/\Omega)}{T} t\right), \quad t \geq 0, \quad (3.15)$$

pour des constantes $\gamma_* > 0$ et $p \geq 1$ explicites. En particulier $\|u(\cdot, t)\|_\infty \rightarrow 0$: le système est **globalement asymptotiquement stable**.

Lemme 3.5 (la condition (3.14) fait ce qu'on attend d'elle). (3.14) implique $\Omega < 1$ et $\vartheta M > 2\Delta$.

Démonstration. Le membre de droite de (3.14) est $\leq \frac{M_2}{(1+\lambda)(1+M_0)^2 M_3}$, ce qui donne exactement $\Omega < 1$ par (3.9). Il est aussi $\leq \frac{M_2}{2M_1(1+M_0)} = \frac{\vartheta}{2}$, d'où $2\Delta < \vartheta M$. $\square$

Remarque 3.6 (lecture de la condition). Δ/M est le budget matériel (2^{-N} pour N bits) et le membre de droite ne dépend que de la *physique* ($D, g, \bar{g}$ via M_1, M_2, M_3) et du *réglage* (λ, ν via M_0). La condition dit donc :

il faut assez de bits pour que le gain de la boucle (quantification $\rightarrow$ perturbation frontière $\rightarrow$ état $\rightarrow$ quantification) soit strictement inférieur à 1.

3.2.2.2 Étape 1 : la capture

Lemme 3.7 (capture en temps fini). *Sous (3.14) et avec la loi (3.13) en phase 1, il existe*

$$t_1^* \leq \frac{1}{\beta} \left[\ln c + \left(\ln \frac{C \|u_0\|_\infty}{(\vartheta M - 2\Delta)\mu_0} \right)_+ \right], \quad \beta := \frac{\ln c}{\tau} - \bar{M}_1 > 0, \quad (3.16)$$

tel que $\mathcal{E}(t_1^*)$ soit vrai. À cet instant,

$$\|w(\cdot, t_1^*)\|_\infty \leq \frac{M_2 M \mu(t_1^*)}{1 + M_0}. \quad (3.17)$$

Démonstration. En phase 1 la commande est nulle. Par le lemme A.19, $\|u(\cdot, t)\|_\infty \leq C e^{\bar{M}_1 t} \|u_0\|_\infty$. Par ailleurs $\mu(t) \geq \mu_0 c^{t/\tau-1}$. La condition suffisante du lemme 3.3(2), $\|u(\cdot, t)\|_\infty \leq (\vartheta M - 2\Delta)\mu(t)$, est donc impliquée par

$$C e^{\bar{M}_1 t} \|u_0\|_\infty \leq (\vartheta M - 2\Delta)\mu_0 c^{t/\tau-1},$$

soit $\ln \frac{C \|u_0\|_\infty}{(\vartheta M - 2\Delta)\mu_0} + \ln c \leq \beta t$: d'où (3.16) (le seuil $\vartheta M - 2\Delta$ est positif par le lemme 3.5). L'inégalité (3.17) est la conclusion du lemme 3.3(1). $\square$

3.2.2.3 Étape 2 : contraction sur une fenêtre de durée T

C'est le cœur technique.

Lemme 3.8 (contraction). *Soit $\mu > 0$ constant sur $(t_1^*, t_1^* + T]$ et supposons*

$$\|w(\cdot, t_1^*)\|_\infty \leq \frac{M_2 M \mu}{1 + M_0}. \quad (3.18)$$

Alors, sous (3.14), pour tout $t \in (t_1^*, t_1^* + T]$:

$$\|u(\cdot, t)\|_\infty \leq M\mu \quad (\text{pas de saturation}), \quad (3.19)$$

$$\|w(\cdot, t)\|_\infty \leq \max \left\{ (1 + M_0) e^{-\delta(t-t_1^*)} \|w(\cdot, t_1^*)\|_\infty, \frac{\Omega M_2 M \mu}{1 + M_0} \right\}, \quad (3.20)$$

et en particulier

$$\|w(\cdot, t_1^* + T)\|_\infty \leq \Omega \frac{M_2 M \mu}{1 + M_0} = \frac{M_2 M (\Omega \mu)}{1 + M_0}. \quad (3.21)$$

Démonstration. Fixons $t > t_1^*$ et travaillons sur $[t_1^*, t]$ avec les normes pondérées (A.17) de paramètre δ .

(a) Hypothèse de bande. Supposons d'abord que

$$\|w(\cdot, s)\|_\infty \geq \frac{\Omega M_2 M \mu}{(1 + M_0)^2} \quad \text{pour tout } s \in [t_1^*, t]. \quad (3.22)$$

(b) La perturbation est petite. Tant que $\|u(\cdot, s)\|_\infty \leq M\mu$, le lemme 3.1 donne $|d(s)| \leq M_3 \Delta \mu$. Avec (3.22) et la définition (3.9) de Ω :

$$|d(s)| \leq M_3 \Delta \mu = \frac{(1 + M_0)^2 M_3 \Delta}{\Omega M_2 M} \cdot \frac{\Omega M_2 M \mu}{(1 + M_0)^2} \leq \frac{1}{1 + \lambda} \|w(\cdot, s)\|_\infty.$$

Donc $|d|_{[t_1^*, t]} \leq \frac{1}{1 + \lambda} \|w\|_{[t_1^*, t]}$.

(c) Fermeture petit gain. Le corollaire A.12 avec $\nu_{\text{poids}} = \delta$ (donc $e^{\delta D} = (1 + \lambda)^\nu$) donne

$$\|w\|_{[t_1^*, t]} \leq (1 + \lambda)^\nu \left(\|w(\cdot, t_1^*)\|_\infty + |d|_{[t_1^*, t]} \right) \leq (1 + \lambda)^\nu \|w(\cdot, t_1^*)\|_\infty + (1 + \lambda)^{\nu-1} \|w\|_{[t_1^*, t]}.$$

Comme $\nu < 1$, on a $(1 + \lambda)^{\nu-1} < 1$: le lemme A.17 s'applique et

$$\|w\|_{[t_1^*, t]} \leq \frac{(1 + \lambda)^\nu}{1 - (1 + \lambda)^{\nu-1}} \|w(\cdot, t_1^*)\|_\infty = (1 + M_0) \|w(\cdot, t_1^*)\|_\infty, \quad (3.23)$$

par la définition (3.8) de M_0 . En revenant à la norme non pondérée :

$$\|w(\cdot, t)\|_\infty \leq (1 + M_0) e^{-\delta(t-t_1^*)} \|w(\cdot, t_1^*)\|_\infty. \quad (3.24)$$

(d) Cohérence : pas de saturation. De (3.24), (3.18) et $\|u\|_\infty \leq M_2^{-1} \|w\|_\infty$ (proposition A.8) :

$$\|u(\cdot, t)\|_\infty \leq \frac{(1 + M_0)}{M_2} \|w(\cdot, t_1^*)\|_\infty \leq \frac{(1 + M_0)}{M_2} \cdot \frac{M_2 M \mu}{1 + M_0} = M \mu.$$

C'est (3.19) : l'hypothèse de non-saturation utilisée en (b) est donc *auto-cohérente* (argument de continuation standard : l'ensemble des t où elle est vraie est ouvert, fermé et non vide dans la fenêtre).

(e) Valeur en $t_1^* + T$. Par (3.10), $e^{-\delta T} = \Omega/(1 + M_0)$, d'où

$$\|w(\cdot, t_1^* + T)\|_\infty \leq (1 + M_0) \frac{\Omega}{1 + M_0} \|w(\cdot, t_1^*)\|_\infty = \Omega \|w(\cdot, t_1^*)\|_\infty \leq \frac{\Omega M_2 M \mu}{1 + M_0}.$$

(f) Si la bande (3.22) est violée. Soit t_b le premier instant où $\|w(\cdot, t_b)\|_\infty < \frac{\Omega M_2 M \mu}{(1 + M_0)^2}$. Après t_b , deux cas : ou bien la solution reste sous ce seuil (et alors (3.20) est trivialement vraie), ou bien elle repasse au-dessus à un instant $t_\#$, et l'analyse (a) à (e) s'applique à partir de $t_\#$ en remplaçant t_1^* par $t_\#$; comme $\|w(\cdot, t_\#)\|_\infty = \frac{\Omega M_2 M \mu}{(1 + M_0)^2}$ par continuité, on obtient

$$\|w(\cdot, t)\|_\infty \leq (1 + M_0) \|w(\cdot, t_\#)\|_\infty = \frac{\Omega M_2 M \mu}{1 + M_0} \quad \text{pour } t \geq t_\#.$$

Dans tous les cas, (3.20) et (3.21) sont établies. $\square$

Intuition : relire la preuve en trois phrases

1. La quantification devient une perturbation frontière d , bornée par $M_3 \Delta \mu$.
2. Tant que l'état n'est pas *trop petit* (bande), cette borne s'exprime comme une fraction $\frac{1}{1+\lambda}$ de l'état lui-même : c'est une *boucle*, pas une perturbation exogène.
3. L'ISS du transport (gain $e^{\delta D} = (1 + \lambda)^\nu$) et le petit gain $((1 + \lambda)^{\nu-1} < 1)$ ferment la boucle et donnent une décroissance exponentielle de taux δ , jusqu'au plancher fixé par μ . On abaisse alors μ et on recommence.

3.2.2.4 Étape 3 : assemblage

Preuve du théorème 3.4. (i) Le lemme 3.7 fournit $t_1^* < \infty$ et (3.17), c'est-à-dire exactement l'hypothèse (3.18) du lemme 3.8 avec $\mu = \mu(t_1^*) =: \mu_\star$.

(ii) Récurrence. Posons $t_i := t_1^* + (i - 1)T$ et $\mu_i := \Omega^{i-1} \mu_\star$. Supposons $\|w(\cdot, t_i)\|_\infty \leq \frac{M_2 M \mu_i}{1 + M_0}$. Sur $(t_i, t_{i+1}]$, μ est constant égal à μ_i (loi (3.13)), donc le lemme 3.8 donne $\|w(\cdot, t_{i+1})\|_\infty \leq \frac{M_2 M (\Omega \mu_i)}{1 + M_0} = \frac{M_2 M \mu_{i+1}}{1 + M_0}$: la propriété se propage.

(iii) Entre deux instants de commutation, (3.20) et $\|u\|_\infty \leq M_2^{-1} \|w\|_\infty$ donnent $\|u(\cdot, t)\|_\infty \leq M \mu_i \leq M \mu_\star \Omega^{i-1}$, soit

$$\|u(\cdot, t)\|_\infty \leq \frac{M \mu_\star}{\Omega} \Omega^{\frac{t-t_1^*}{T}} = \frac{M \mu_\star}{\Omega} e^{-\frac{\ln(1/\Omega)}{T}(t-t_1^*)}.$$

(iv) Reste à exprimer $\mu_\star$ et $e^{\frac{\ln(1/\Omega)}{T}t_1^\star}$ en fonction de $\|u_0\|_\infty$. D'après (3.13), $\mu_\star \leq c\mu_0 e^{\frac{\ln c}{\tau}t_1^\star}$, et d'après (3.16), $e^{t_1^\star} \leq (C\|u_0\|_\infty / ((\vartheta M - 2\Delta)\mu_0) \cdot c)^{1/\beta}$. En combinant, on obtient (3.15) avec un exposant

$$p = \frac{1}{\beta} \left(\frac{\ln c}{\tau} + \frac{\ln(1/\Omega)}{T} \right) + 1$$

et une constante $\gamma_\star$ explicite. Enfin, sur $[0, t_1^\star]$, la borne de croissance du lemme A.19 est absorbée dans $\gamma_\star$. $\square$

Remarque 3.9 (pourquoi une *puissance* de la condition initiale?). Parce que $t_1^\star$ dépend logarithmiquement de $\|u_0\|_\infty$ (lemme 3.7) et que l'estimation finale contient $e^{\text{cste} \cdot t_1^\star}$. On obtient donc une majoration en $\|u_0\|_\infty^p$ et non en $\|u_0\|_\infty$: la stabilité est *asymptotique globale*, mais pas *exponentielle globale* au sens strict. C'est le prix intrinsèque de la phase de capture, et c'est un phénomène structurel du zooming, déjà présent en dimension finie.

Remarque 3.10 (correspondance avec les notations de la littérature). Le lecteur qui ouvrira [24] y trouvera les mêmes objets sous une écriture légèrement différente, qu'il est utile de savoir traduire. L'article pose directement

$$\Omega = \frac{(1+\lambda)^{1+\nu} \Delta M_3}{M_2 M}, \quad T = -\frac{D \ln \Omega}{\nu \ln(1+\lambda)}, \quad \bar{M}_1 = \frac{M_3}{DM_2},$$

et le seuil de capture $\frac{M_2 M}{(1+\lambda)^\nu M_1} - \Delta$ [24, éq. (14) à (18)]. La correspondance avec nos formules (3.9), (3.10), (3.11) est

$$(1+\lambda)^\nu \longleftrightarrow (1+M_0)^2.$$

La différence tient à la manière de refermer la boucle : l'article invoque l'estimation de mémoire évanescence de [18, Théorème 2.1], qui fournit d'emblée le facteur $(1+\lambda)^\nu$, alors que nous explicitons le dépassement M_0 produit par le lemme de petit gain A.17. Les deux voies mènent au même énoncé qualitatif ; la nôtre a l'avantage que toutes les constantes se calculent à la main à partir de M_1, M_2, M_3 et du couple (λ, ν) , sans avoir à ouvrir une référence extérieure, ce qui est précisément l'objet d'un cours.

3.2.2.5 Application numérique

Reprenons $D = 1$, $g = 1,25$, $\bar{g} \equiv 0$, d'où (exemple A.10) $M_1 = 5,363$, $M_2 = 0,4444$, $M_3 = 4,363$.

N (bits)	Δ/M	λ	ν	M_0	Ω	T (taux)
7	1/128	3,05	0,09	0,576	0,771	5,68 (0,046)
8	1/256	4,13	0,16	0,740	0,595	4,10 (0,127)
10	1/1024	6,48	0,27	1,236	0,359	3,37 (0,304)

(les (λ, ν) sont ceux qui *maximisent le taux garanti* à budget de bits fixé). Le seuil d'admissibilité est ici $\Delta/M < 0,0141$, soit $M/\Delta > 71$: il faut au moins 7 bits.

En pratique : la théorie est suffisante, pas nécessaire

Les simulations de [24] utilisent $\Delta = M/40$ ($\approx 5,3$ bits) et convergent parfaitement, alors que notre condition suffisante demande 7 bits. Il n'y a pas de contradiction : (3.14) est une condition *suffisante*, obtenue par des majorations de type pire cas. En pratique on dimensionne avec la formule, puis on *réduit* les marges en simulation.

3.2.3 Quantification de l'entrée

3.2.3.1 La loi de commande

On suppose maintenant l'état $u(\cdot, t)$ parfaitement mesuré, mais l'actionneur quantifié :

$$U(t) = \begin{cases} 0, & 0 \leq t \leq \bar{t}_1^*, \\ \mu(t) q \left(\frac{1}{\mu(t)} \int_0^D k(D, x) u(x, t) dx \right) = q_\mu(U_{\text{nom}}(t)), & t > \bar{t}_1^*. \end{cases} \quad (3.25)$$

La condition au bord du système cible devient

$$w(D, t) = U(t) - U_{\text{nom}}(t) = q_\mu(U_{\text{nom}}(t)) - U_{\text{nom}}(t) =: \bar{d}(t), \quad (3.26)$$

et si $|U_{\text{nom}}(t)| \leq M\mu(t)$ alors $|\bar{d}(t)| \leq \Delta\mu(t)$.

Intuition : la différence, en une ligne

mesures quantifiées : $|d| \leq M_3\Delta\mu$ contre entrée quantifiée : $|\bar{d}| \leq \Delta\mu$.

On économise le facteur M_3 : la quantification n'est appliquée qu'une fois, à la sortie du contrôleur, au lieu d'être appliquée à l'état puis amplifiée par le noyau. C'est exactement le phénomène observé en dimension finie au §2.5.1 ($\|PB\|$ contre $\|PBK\|$).

3.2.3.2 L'événement de capture, version « entrée »

Comme u est mesuré exactement, l'événement porte directement sur l'état :

$$\bar{\mathcal{E}}(t) : \|u(\cdot, t)\|_\infty \leq \frac{M_2 M}{M_1(1 + M_0) M_3} \mu(t). \quad (3.27)$$

Aucune propriété (P2) n'est nécessaire ici : le test est trivialement implémentable. Le facteur M_3 au dénominateur garantit $|U_{\text{nom}}(t)| \leq M_3 \|u(\cdot, t)\|_\infty \leq M\mu(t)$, c'est-à-dire l'absence de saturation de l'entrée.

3.2.3.3 Le théorème

Théorème 3.11 (stabilisation globale sous entrée quantifiée). Avec $\bar{\Omega} := \frac{(1+\lambda)(1+M_0)^2\Delta}{M_2M}$ (c'est-à-dire Ω/M_3) et $\bar{T}$ défini comme en (3.10) avec $\bar{\Omega}$, si

$$\frac{\Delta}{M} < \frac{M_2}{(1 + \lambda)(1 + M_0)^2}, \quad (3.28)$$

alors la loi (3.25) avec la mise à jour (3.13) (où Ω est remplacé par $\bar{\Omega}$) rend le système globalement asymptotiquement stable, avec une estimation analogue à (3.15).

Schéma. Identique à celle du théorème 3.4, en remplaçant partout $M_3\Delta\mu$ par $\Delta\mu$ dans le lemme 3.1, et en utilisant (3.27) pour la capture (la phase 1 est inchangée). Le facteur M_1 disparaît de la condition car on n'a pas besoin de remonter de la mesure quantifiée à l'état. $\square$

Remarque 3.12 (laquelle des deux conditions est la plus permissive?). Comparons (3.14) et (3.28). Comme $M_3 < M_1$ (proposition A.9) et $(1 + M_0) \geq 1$, on a

$$\frac{M_2}{(1 + \lambda)(1 + M_0)^2} \geq \frac{M_2}{(1 + M_0) \max\{(1 + \lambda)(1 + M_0)M_3, 2M_1\}} \quad \text{dès que } M_3 \geq 1.$$

Autrement dit, sauf gain de commande très faible, **la quantification d'entrée est moins exigeante en bits que la quantification des mesures**. Sur l'exemple numérique : le seuil passe de $\Delta/M < 0,0141$ à $\Delta/M < 0,062$, soit d'environ 7 bits à 5 bits.

Exercice 3.1. Vérifier ce dernier calcul numérique en optimisant (λ, ν) .

Exercice 3.2 (*). Traiter le cas où *les deux* (mesures et entrée) sont quantifiées, avec le même μ . Montrer que la perturbation frontière devient $|d| \leq (1 + M_3)\Delta\mu$ et écrire la condition correspondante.

3.2.4 Simulation de l'EDP quantifiée

3.2.4.1 Ce que l'on simule

Le cas test est celui de [24, §5], avec les mêmes paramètres physiques, ce qui permet de comparer directement.

$$u_t(x, t) = u_x(x, t) + g u(0, t), \quad x \in [0, 1], \quad u(1, t) = U(t), \quad g = 1,25,$$

avec $u_0(x) = 3 + 2 \sin(2\pi x)$, un quantificateur uniforme saturant de portée $M = 2$ et de résolution $\Delta = M/256$, soit 8 bits pour un convertisseur uniforme, et la loi hybride (3.4), (3.13) avec $\lambda = 4,13$, $\nu = 0,16$, d'où

$$M_0 = 0,740, \quad \Omega = 0,595, \quad T = 4,10, \quad \vartheta = 0,0476, \quad \text{taux garanti} = 0,127.$$

Le schéma numérique est un décentrement amont (*upwind*) avec $\text{CFL} = \Delta t / \Delta x = 0,5$, $N = 400$ mailles.




FIGURE 3.1 : Norme sup de l'état et variable de zoom. La décroissance des deux courbes est *synchronisée* : c'est la signature du schéma. Les remontées en dents de scie de $\|u\|_\infty$ entre deux mises à jour proviennent de l'instabilité interne, que l'erreur de quantification $\Delta\mu$ ne compense qu'imparfaitement ; chaque division de μ par Ω les rabote.

3.2.4.2 Les trois observations à faire

1. μ devient très grand à la capture (≈ 130 ici) alors que $\|u_0\|_\infty = 5$. C'est le facteur $\vartheta = 0,0476$: l'événement exige $\|u\|_\infty \leq \vartheta M\mu$, soit $\mu \gtrsim \|u\|_\infty / 0,095$. Conséquence pratique : le quantificateur doit encaisser une plage $M\mu \approx 260$ à cet instant. Si l'électronique ne le permet pas, il faut améliorer ϑ , donc M_0 , donc le réglage (λ, ν) , ou accepter une garantie seulement locale.




FIGURE 3.2 : Commande frontière appliquée. Le pic initial correspond à l'entrée en phase 2 ; ensuite U reste petite, ce qui est cohérent avec $|U| \leq M_3 \|u\|_\infty + M_3 \Delta\mu$.

2. **La convergence observée est plus rapide que la garantie.** La théorie promet $e^{-0,127t}$; on observe environ $e^{-0,17t}$.
3. **Le motif en dents de scie est normal et informatif.** Il montre que l'on est à la limite : entre deux mises à jour, l'erreur $\Delta\mu$ est juste assez petite pour que le bilan sur une période soit négatif. Si l'on augmentait T , les dents grandiraient ; si on le réduisait trop, on re-saturerait.

En pratique : expériences suggérées

1. Fixer $\mu \equiv 0,1$ (petit) : observer la saturation puis la divergence.
2. Fixer $\mu \equiv 100$ (grand) : observer le plateau à $\|u\|_\infty \sim \Delta\mu M_3 / (\dots)$, sans convergence.
3. Passer à la quantification d'entrée (remplacer la ligne du contrôleur par `U = mu * q_scalar(np.trapezoid(kD * u, xs) / mu)`) et constater que l'on peut descendre à 5 bits.
4. Remplacer l'*upwind* par Lax-Friedrichs et vérifier que les conclusions ne changent pas (mais que la diffusion numérique lisse les dents de scie. Attention à ne pas confondre effet numérique et effet physique!).

3.2.4.3 Les figures de l'article original

Les simulations ci-dessus sont des reproductions indépendantes. Il vaut la peine de regarder aussi les figures de l'article lui-même, d'abord parce qu'elles sont la référence, ensuite parce que l'article présente deux *contre-exemples* que l'on n'a pas refaits ici et qui valent tous les discours sur l'utilité du zoom.




FIGURE 3.3 : **La loi hybride fonctionne.** À gauche, la norme sup $\|u(t)\|_\infty$ de l'état en boucle fermée (trait plein) et le signal de commutation $\mu(t) \frac{MM_2}{M_1(1+\lambda)^\nu}$ (tirets) : on lit directement la structure en deux phases, la montée initiale pendant la capture puis la descente par paliers. À droite, l'état $u(x, t)$ sur tout le domaine. Paramètres : $D = 1$, $\bar{g} \equiv 0$, $g = 1,25$, $M = 2$, $\Delta = M/40$, $\lambda = \nu = \frac{3}{4}$, $\Omega = 0,65$, $T = 1,01$, $\mu_0 = 1$; la capture est détectée à $t_1^* = 0,14$.¹

1. *Source* : Figure reproduite de [24, Fig. 2], © 2020 l'auteur, diffusée sous licence Creative Commons Attribution 4.0 International (<http://creativecommons.org/licenses/by/4.0/>) ; dépôt institutionnel de l'Université technique de Crète, <https://dias.library.tuc.gr/view/88732>.




FIGURE 3.4 : **Ce qui se passe si l'on ne bouge pas μ** , avec la même loi de backstepping et le même quantificateur. *En haut*, $\mu = 0,5$ figé : la condition initiale $u(x, 0) = 10$ est hors de la portée $M\mu = 1$, le quantificateur sature, et l'état part à l'infini. *En bas*, $\mu = 100$ figé : la portée est largement suffisante, il n'y a plus de divergence (c'est la propriété ISS du contrôleur nominal vis-à-vis d'une perturbation frontière) mais l'erreur de quantification $\Delta\mu$ est énorme et le système s'installe dans ce qui ressemble à un *cycle limite* : la commande s'annule quand l'état entre dans la zone morte, l'état recroît en boucle ouverte, le quantificateur redevient non nul, et ainsi de suite. Les deux modes d'échec annoncés à la section 1.6, en une page.²




FIGURE 3.5 : **Entrée quantifiée**, c'est-à-dire le théorème 3.11 plutôt que le théorème 3.4 : ici c'est la valeur scalaire U_{nom} qui est arrondie, et non le profil $u(\cdot, t)$. Mêmes paramètres que la figure 3.3 à ceci près que $M_1 = 1 + ge^g$ et $M_2 = \frac{1}{1+g}$. On retrouve la même signature globale (pic initial, puis convergence) avec un transitoire un peu plus court, cohérent avec le fait qu'une seule quantité scalaire est quantifiée au lieu d'un profil entier.³

2. Source : Figures reproduites de [24, Fig. 3 et 4], licence CC BY 4.0.

En pratique : à retenir des deux contre-exemples

Ils disent une chose que les théorèmes ne disent pas aussi bien : *les deux échecs ne se ressemblent pas*. Le premier est spectaculaire et immédiat, la norme explose, on ne peut pas le rater. Le second est sournois : le système a l'air stable, la norme reste bornée, et si l'on ne regarde pas assez longtemps on peut conclure que « ça marche ». C'est le mode d'échec le plus fréquent sur un banc réel, et il ne se diagnostique qu'en regardant la norme *en échelle logarithmique* sur un temps long.

3.2.4.4 Reproduire ces figures**Code**

transport_quantized_control.py, dépôt https://github.com/Flo3221/codes_mini_cours_quantification.

Le script contient la simulation. L'EDP est discrétisée par un schéma décentré amont avec $\text{CFL} = \Delta t / \Delta x = 0,5$ et 400 mailles ; l'intégrale $\int_0^D k(D, x) q_\mu(u) dx$ est évaluée par la méthode des trapèzes à chaque pas de temps. Bekiaris-Liberis emploie pour sa part un schéma de Lax-Friedrichs [24, §5] ; les conclusions qualitatives sont identiques, la diffusion numérique de Lax-Friedrichs lissant seulement davantage les discontinuités de la commande.

Attention : pièges numériques classiques

- **CFL** : avec l'*upwind*, $\Delta t \leq \Delta x$ est obligatoire. Au-delà, le schéma explose et l'on croit à tort à une instabilité du système.
- **Diffusion numérique** : l'*upwind* est d'ordre 1 et lisse les discontinuités. Comme la sortie du quantificateur est en escalier, la commande U est discontinue en temps : un maillage trop grossier « invente » de la régularité et rend le schéma trop optimiste.
- **Quantifier après avoir intégré, ou l'inverse ?** Ce n'est *pas* la même chose : $\int k q_\mu(u)$ (mesures quantifiées) et $q_\mu(\int k u)$ (entrée quantifiée) sont deux problèmes distincts, régis par les théorèmes 3.4 et 3.11 respectivement.
- **μ ne doit jamais atteindre 0 numériquement** : on divise par μ . Prévoir un plancher $\mu_{\min}$ (voir §B.3.1).

3.3 Retard d'entrée et quantification simultanés, d'après Koudohode et Bekiaris-Liberis

Cette section entière suit [26], dont le préprint est librement accessible (arXiv:2404.11194). Comme la précédente, elle est traitée d'un seul tenant. Le lecteur qui souhaite le cas non linéaire consultera [28] pour les champs globalement lipschitziens et les EDP de réaction-diffusion, et [29] pour le cas semi-global.

Intuition : pourquoi ce cas mérite son propre traitement

On pourrait croire qu'un retard d'entrée n'est qu'une EDP de transport de plus, et donc que la section 3.2 suffit. C'est faux pour une raison précise : le prédicteur. Pour compenser un retard D , la loi nominale doit prédire l'état D secondes à l'avance, et cette prédiction fait intervenir *tout l'historique de la commande*, qui est elle-même quantifiée. La quantification entre donc deux fois dans la même formule, et l'erreur qu'elle produit est propagée par

l'intégrale du prédicteur. C'est ce qui fait exploser les constantes, et c'est pourquoi le nombre de bits certifié passe d'une poignée à une vingtaine.

En pratique : plan de la section

1. la reformulation du retard en EDP de transport, et la loi nominale de type prédicteur ;
2. ce que l'on quantifie exactement, et la loi commutée ;
3. la perturbation frontière engendrée par la quantification ;
4. le théorème principal et sa démonstration en trois étapes ;
5. la variante « entrée quantifiée » ;
6. les simulations, et le diagnostic de l'écart entre le réglage certifié et le réglage praticable.

3.3.1 Un retard d'entrée *est* une EDP de transport

3.3.1.1 Le système et sa reformulation

Toute cette section suit [26]. Le lecteur qui souhaite le cas non linéaire consultera [28] pour les champs de vecteurs globalement lipschitziens et [29] pour le cas semi-global.

Considérons une EDO linéaire commandée avec un retard constant $D > 0$ sur l'entrée :

$$\dot{X}(t) = AX(t) + BU(t - D), \quad X(t) \in \mathbb{R}^n, U(t) \in \mathbb{R}. \quad (3.29)$$

Le truc standard

Posons, pour $x \in [0, D]$,

$$u(x, t) := U(t + x - D).$$

Alors $u_t = U'(t + x - D) = u_x$, $u(D, t) = U(t)$ et $u(0, t) = U(t - D)$. Le système (3.29) devient la **cascade EDO-EDP**

$$\dot{X}(t) = AX(t) + B u(0, t), \quad (3.30)$$

$$u_t(x, t) = u_x(x, t), \quad x \in [0, D], \quad (3.31)$$

$$u(D, t) = U(t). \quad (3.32)$$

Intuition : lire la cascade

L'EDP est un *tapis roulant* : on dépose la commande en $x = D$, elle met D secondes à atteindre $x = 0$ où elle est enfin livrée à l'EDO. L'état de l'EDP est donc l'*historique de commande en transit*. C'est pourquoi l'espace d'état naturel est

$$\mathbb{R}^n \times L^\infty([0, D]; \mathbb{R}), \quad \|(X, u)\| := |X| + \|u\|_\infty.$$

Toute la subtilité des systèmes à retard vient de ce que cet espace est de dimension infinie.

3.3.1.2 La loi nominale : predictor feedback

Sans retard, on prendrait $U = KX$ avec $A + BK$ Hurwitz. Avec le retard, la commande décidée à t n'agit qu'à $t + D$: il faut donc la calculer à partir de l'état *futur*.

La réduction de (3.29) à un problème sans retard remonte à Artstein et Smith ; l'écriture par backstepping que nous suivons est celle de Krstic [17, ch. 2].

Proposition 3.13 (formule du prédicteur). *Pour (3.30) et (3.32),*

$$X(t+D) = e^{AD}X(t) + \int_0^D e^{A(D-y)}B u(y,t) dy =: \mathcal{P}(X(t), u(\cdot, t)). \quad (3.33)$$

Démonstration. La formule de variation de la constante sur $[t, t+D]$ donne $X(t+D) = e^{AD}X(t) + \int_t^{t+D} e^{A(t+D-s)}BU(s-D)ds$. Le changement de variable $y = s - t$ et $u(y, t) = U(t + y - D)$ donne (3.33). $\square$

La loi nominale est alors

$$U_{\text{nom}}(t) = K \mathcal{P}(X(t), u(\cdot, t)) = Ke^{AD}X(t) + K \int_0^D e^{A(D-y)}B u(y, t) dy. \quad (3.34)$$

Remarque 3.14 (c'est bien du backstepping). Comparez (3.34) à (A.12) : dans les deux cas, la commande est une *intégrale de l'état contre un noyau*, plus (ici) un terme en X . La théorie de la section A.2 et celle du prédicteur sont la même théorie ; c'est la lecture proposée par Krstic [17].

3.3.1.3 La transformation de backstepping et le système cible

Théorème 3.15 (transformation). *Posons*

$$w(x, t) = u(x, t) - K \int_0^x e^{A(x-y)}B u(y, t) dy - Ke^{Ax}X(t), \quad (3.35)$$

$$u(x, t) = w(x, t) + K \int_0^x e^{(A+BK)(x-y)}B w(y, t) dy + Ke^{(A+BK)x}X(t). \quad (3.36)$$

Alors (3.30) et (3.32) devient

$$\dot{X}(t) = (A + BK)X(t) + B w(0, t), \quad (3.37)$$

$$w_t(x, t) = w_x(x, t), \quad (3.38)$$

$$w(D, t) = U(t) - U_{\text{nom}}(t). \quad (3.39)$$

Intuition : ce qu'il faut retenir de la preuve ci-dessous

Elle ne contient aucune idée cachée : on dérive la transformation une fois en temps, une fois en espace, et l'on constate que les deux résultats coïncident. Toute la construction tient dans le choix du noyau $e^{A(x-y)}B$, qui est exactement le noyau du prédicteur (3.33). Un lecteur qui accepte le théorème peut passer directement à la proposition 3.16 ; celui qui veut apprendre la méthode a intérêt à refaire le calcul lui-même, l'intégration par parties étant le seul point technique.

Démonstration. *Dynamique de w .* En dérivant (3.35) en temps et en utilisant $u_t = u_x$ puis une intégration par parties

$$\int_0^x e^{A(x-y)}B u_y(y, t) dy = Bu(x, t) - e^{Ax}Bu(0, t) + A \int_0^x e^{A(x-y)}Bu(y, t) dy,$$

il vient, avec $\dot{X} = AX + Bu(0, t)$:

$$w_t = u_x - KBu(x, t) + Ke^{Ax}Bu(0, t) - KA \int_0^x e^{A(x-y)}Bu dy - Ke^{Ax}AX - Ke^{Ax}Bu(0, t),$$

soit $w_t = u_x - KBu(x, t) - KA \int_0^x e^{A(x-y)}Bu dy - KAe^{Ax}X$. En dérivant (3.35) en espace : $w_x = u_x - KBu(x, t) - KA \int_0^x e^{A(x-y)}Bu dy - KAe^{Ax}X$. Les deux expressions coïncident : $w_t = w_x$.

Condition en $x = 0$. $w(0, t) = u(0, t) - KX(t)$, donc $u(0, t) = w(0, t) + KX(t)$ et (3.30) devient (3.37).

Condition en $x = D$. $w(D, t) = U(t) - K \int_0^D e^{A(D-y)} B u dy - K e^{AD} X = U(t) - U_{\text{nom}}(t)$.

Inversibilité. (3.36) se vérifie par substitution directe ; c'est aussi une conséquence générale du caractère de Volterra (section A.2). $\square$

Intuition : le système cible en une phrase

X obéit à la *boucle fermée idéale* $\dot{X} = (A + BK)X$, perturbée par $w(0, t)$; et w est un transport pur alimenté à la frontière par l'erreur de commande $U - U_{\text{nom}}$. Donc :

si l'on applique exactement U_{nom} , alors $w(D, t) = 0$, l'EDP se vide en temps D , et l'EDO devient exponentiellement stable. Tout défaut de commande (quantification !) entre par $w(D, t)$.

3.3.1.4 Les constantes M_1, M_2, M_3

Proposition 3.16. Avec $\|(X, u)\| = |X| + \|u\|_\infty$ et $\|(X, w)\| = |X| + \|w\|_\infty$:

$$M_2 \|(X, u)\| \leq \|(X, w)\| \leq M_1 \|(X, u)\|, \quad (3.40)$$

avec

$$M_1 = 1 + |K| e^{|A|D} \max\{1, D|B|\}, \quad (3.41)$$

$$M_2 = \frac{1}{1 + |K| e^{|A+BK|D} \max\{1, D|B|\}}. \quad (3.42)$$

On pose de plus

$$M_3 := |K| e^{|A|D} (1 + |B| D), \quad \text{de sorte que} \quad |U_{\text{nom}}(t)| \leq M_3 \|(X(t), u(\cdot, t))\|. \quad (3.43)$$

Démonstration. De (3.35), $|w(x, t)| \leq \|u\|_\infty + |K| e^{|A|D} |B| D \|u\|_\infty + |K| e^{|A|D} |X|$, d'où $|X| + \|w\|_\infty \leq (1 + |K| e^{|A|D} \max\{1, D|B|\}) (|X| + \|u\|_\infty)$. Symétriquement avec (3.36). Enfin (3.43) se lit directement sur (3.34). $\square$

En pratique : ordres de grandeur

Toutes ces constantes contiennent $e^{|A|D}$: elles explosent exponentiellement avec le retard. Conséquence concrète et importante :

le nombre de bits nécessaire croît (au moins) linéairement avec $|A| D$, c'est-à-dire avec le produit « instabilité $\times$ retard ».

C'est cohérent avec le théorème du débit minimal : pendant le retard, l'incertitude est multipliée par $e^{|A|D}$ sans qu'on puisse agir ; il faut donc $|A| D / \ln 2$ bits supplémentaires rien que pour compenser le transit.

3.3.2 Quantificateur dynamique et commande commutée

3.3.2.1 Ce que l'on quantifie

On suppose ici que tout l'état (X, u) n'est disponible que quantifié :

$$q_\mu(X, u) = \left(q_{1,\mu}(X), q_{2,\mu}(u) \right) = \left(\mu q_1\left(\frac{X}{\mu}\right), \mu q_2\left(\frac{u}{\mu}\right) \right), \quad (3.44)$$

où q_1 agit sur $\mathbb{R}^n$ et q_2 sur $L^\infty([0, D])$ point par point.

Remarque 3.17 (quantifier l'historique de commande ?). Quantifier $u(\cdot, t)$ peut surprendre puisque u est l'historique de la commande, donc en principe connu du contrôleur. Deux situations le justifient : (i) le contrôleur ne connaît que ce qu'il a effectivement *envoyé* à travers un canal quantifié, pas ce qui a été appliqué ; (ii) dans une cascade EDO-EDP physique (échangeur, canal, forage), u est un vrai état distribué mesuré par des capteurs. Dans le cas (i), on peut aussi ne quantifier que X : tout ce qui suit s'applique *a fortiori*.

Les propriétés requises sont (P1) à (P3) écrites dans la norme produit :

$$(P1) \quad \|(X, u)\| \leq M \Rightarrow \|(q_1(X) - X, q_2(u) - u)\| \leq \Delta, \quad (3.45)$$

$$(P2) \quad \|(X, u)\| > M \Rightarrow \|(q_1(X), q_2(u))\| > M - \Delta, \quad (3.46)$$

$$(P3) \quad \|(X, u)\| \leq \widehat{M} \Rightarrow q_1(X) = 0 \text{ et } q_2(u) = 0. \quad (3.47)$$

3.3.2.2 La loi commutée

On définit d'abord le *prédicteur quantifié*

$$\mathcal{P}_\mu(X, u) := e^{AD} q_{1,\mu}(X) + \int_0^D e^{A(D-y)} B q_{2,\mu}(u(y)) dy, \quad (3.48)$$

puis

$$U(t) = \begin{cases} 0, & 0 \leq t \leq t_1^*, \\ K \mathcal{P}_{\mu(t)}(X(t), u(\cdot, t)), & t > t_1^*. \end{cases} \quad (3.49)$$

Attention : pourquoi couper la commande en phase 1 ?

Si l'état initial est hors de portée, les mesures quantifiées sont *écrêtées* : elles ne disent plus rien, sinon « c'est grand ». Une commande construite dessus est au mieux inutile, au pire déstabilisante, d'autant que son effet n'arrivera qu'avec D secondes de retard. On préfère donc *ne rien faire* et augmenter μ jusqu'à voir l'état. C'est contre-intuitif mais c'est ce qui rend le résultat *global*.

3.3.2.3 La perturbation frontière engendrée par la quantification

En reportant (3.49) dans (3.39) :

$$w(D, t) = d(t) := K e^{AD} \mu \left[q_1\left(\frac{X}{\mu}\right) - \frac{X}{\mu} \right] + K \int_0^D e^{A(D-y)} B \mu \left[q_2\left(\frac{u(y, t)}{\mu}\right) - \frac{u(y, t)}{\mu} \right] dy. \quad (3.50)$$

Lemme 3.18. Si $\|(X(t), u(\cdot, t))\| \leq M\mu(t)$, alors

$$|d(t)| \leq M_3 \Delta \mu(t). \quad (3.51)$$

Démonstration. On majore séparément les deux contributions :

$$\begin{aligned} |d| &\leq \left| K e^{AD} \right| \mu \left| q_1\left(\frac{X}{\mu}\right) - \frac{X}{\mu} \right| + D \sup_y \left| K e^{A(D-y)} B \right| \mu \left\| q_2\left(\frac{u}{\mu}\right) - \frac{u}{\mu} \right\|_\infty \\ &\leq M_3 \mu \|(q_1 - \text{id}, q_2 - \text{id})\| \leq M_3 \Delta \mu, \end{aligned}$$

par (P1) et la définition (3.43) de M_3 . □

3.3.2.4 Les constantes et la stratégie de commutation

On se donne :

- (M_σ, σ) tels que $\|e^{(A+BK)t}\| \leq M_\sigma e^{-\sigma t}$ (existe car $A + BK$ est Hurwitz) ;
- une **marge de petit gain** $\lambda > 0$;
- un **taux de décroissance** $\delta \in (0, \sigma)$.

On pose alors

$$\varphi := \frac{e^{\delta D}}{1 + \lambda} \left(1 + \frac{M_\sigma |B|}{\sigma - \delta} \right), \quad (3.52)$$

$$1 + M_0 := \frac{\max \{M_\sigma, (1 + \lambda)\varphi\}}{1 - \varphi}, \quad (3.53)$$

$$\vartheta := \frac{M_2}{M_1(1 + M_0)}, \quad (3.54)$$

$$\Omega := (1 + \lambda)(1 + M_0)^2 \frac{M_3 \Delta}{M_2 M}, \quad (3.55)$$

$$T := \frac{1}{\delta} \ln \frac{1 + M_0}{\Omega}. \quad (3.56)$$

Intuition : à quoi correspond φ ?

φ est le **gain de boucle** du schéma. Décomposons-le :

- $\frac{1}{1+\lambda}$: ce que l'on *gagne* en imposant que l'erreur de quantification reste une fraction $\frac{1}{1+\lambda}$ de l'état (c'est le rôle de Ω et de la « bande » ci-après) ;
- $e^{\delta D}$: ce que l'on *perd* en exigeant une décroissance au taux δ à travers un transport de longueur D (le prix du retard) ;
- $1 + \frac{M_\sigma |B|}{\sigma - \delta}$: ce que l'on *perd* en refermant par l'EDO : le 1 est le chemin direct « erreur $\rightarrow w$ », le second terme le chemin « $w \rightarrow X \rightarrow$ erreur ».

La condition $\varphi < 1$ est exactement la condition de petit gain du lemme A.17, et $1 + M_0$ est l'*overshoot* $\frac{1}{1-\varphi}$ qui en résulte.

Proposition 3.19 (il suffit de prendre λ assez grand). *Si*

$$\lambda > \frac{M_\sigma |B|}{\sigma}, \quad (3.57)$$

alors il existe $\delta \in (0, \sigma)$ tel que $\varphi < 1$. Réciproquement, plus λ est grand, plus φ est petit et plus M_0 est proche de $\max\{M_\sigma, 1\} - 1$; mais plus Ω est grand (cf. (3.55)), donc plus la convergence certifiée est lente. Le réglage de λ est le compromis central du schéma.

Démonstration. $\delta \mapsto \varphi(\delta)$ est continue croissante sur $[0, \sigma)$ et $\varphi(0) = \frac{1}{1+\lambda} \left(1 + \frac{M_\sigma |B|}{\sigma} \right)$, qui est < 1 précisément sous (3.57). Par continuité, $\varphi(\delta) < 1$ pour $\delta > 0$ assez petit. $\square$

En pratique : recette de réglage

1. Calculer M_1, M_2, M_3 par (3.41) et (3.43).
2. Calculer (M_σ, σ) pour $A + BK$ (par exemple par une équation de Lyapunov : $\sigma = \lambda_{\min}(Q)/(2\lambda_{\max}(P))$, $M_\sigma = \kappa_P$).
3. Choisir $\lambda > M_\sigma |B|/\sigma$, puis δ petit ; en déduire φ, M_0, ϑ .
4. Vérifier la condition en bits (3.61) ci-dessous ; si elle échoue, augmenter M/Δ (plus de bits) ou rejouer les étapes 3 à 4 avec un autre (λ, δ) .
5. Calculer Ω et T : le taux certifié est $\frac{1}{T} \ln \frac{1}{\Omega}$.

3.3.2.5 L'événement et la loi de μ

$$\mathcal{E}(t) : \left\| q_{\mu(t)}(X(t), u(\cdot, t)) \right\| \leq (\vartheta M - \Delta) \mu(t), \quad (3.58)$$

c'est-à-dire, explicitement, $|\mu q_1(\frac{X}{\mu})| + \|\mu q_2(\frac{u}{\mu})\|_{\infty} \leq (\vartheta M - \Delta) \mu$.

Soit $\tau > 0$ un pas d'échantillonnage arbitraire et $\mu_0 > 0$ arbitraire. On définit t_1^* comme le premier instant de la grille $\{j\tau\}_{j \geq 1}$ où $\mathcal{E}$ est satisfait, et

$$\mu(t) = \begin{cases} \mathcal{M}_1 e^{2|A|j\tau} \mu_0, & t \in [(j-1)\tau, j\tau), \quad 1 \leq j, \quad t < t_1^*, \\ \Omega^{i-1} \mu(t_1^*), & t \in (t_1^* + (i-1)T, t_1^* + iT], \quad i \geq 1, \end{cases} \quad (3.59)$$

avec $\mathcal{M}_1 := 1 + D|B|$ (et, si $A = 0$, on remplace $|A|$ par n'importe quelle constante > 0).

Intuition : pourquoi $e^{2|A|j\tau}$?

En phase 1 la commande est coupée, et on va voir (lemme 3.21) que l'état croît au plus comme $\mathcal{M}_1 e^{|A|t}$. En faisant croître μ comme $e^{2|A|t}$, on est *sûr* de rattraper l'état : le rapport $\|(X, u)\| / \mu$ décroît comme $e^{-|A|t}$. Le facteur 2 n'a rien de magique : n'importe quel facteur > 1 convient.

3.3.3 Le théorème principal et sa démonstration

3.3.3.1 Énoncé

Théorème 3.20 (stabilisation globale sous quantification et retard). *Considérons (3.30) et (3.32) avec (A, B) stabilisable, K tel que $A + BK$ soit Hurwitz, un quantificateur vérifiant (P1) à (P3), la loi (3.49) et la stratégie (3.59). Supposons*

$$\lambda > \frac{M_{\sigma}|B|}{\sigma}, \quad \delta \in (0, \sigma) \text{ tel que } \varphi < 1, \quad (3.60)$$

et la **condition en résolution**

$$\frac{\Delta}{M} < \frac{M_2}{(1 + M_0) \max \{(1 + \lambda)(1 + M_0)M_3, 2M_1\}}. \quad (3.61)$$

Alors, pour toute condition initiale $(X_0, u_0) \in \mathbb{R}^n \times L^{\infty}(0, D)$ et tout $\mu_0 > 0$:

- (i) l'instant de capture t_1^* est **fini** ;
- (ii) le quantificateur ne sature jamais pour $t > t_1^*$, c'est-à-dire $\|(X(t), u(\cdot, t))\| \leq M\mu(t)$;
- (iii) on a l'estimation exponentielle

$$|X(t)| + \|u(\cdot, t)\|_{\infty} \leq \frac{M\mu(t_1^*)}{\Omega} e^{-\frac{1}{T} \ln \frac{1}{\Omega} (t - t_1^*)}, \quad t \geq t_1^*, \quad (3.62)$$

et $\mu(t) \rightarrow 0$; en particulier l'origine est globalement asymptotiquement stable et l'énergie de commande tend vers zéro.

Intuition : lire la condition ()

Le membre de droite ne dépend *que* du système et du réglage ; le membre de gauche

$\Delta/M = 2^{-N}$ ne dépend que du nombre de bits N . La condition dit donc :

$$N > \log_2 \frac{(1 + M_0) \max\{(1 + \lambda)(1 + M_0)M_3, 2M_1\}}{M_2}.$$

Les deux termes du max ont des rôles distincts :

- $(1 + \lambda)(1 + M_0)M_3$ garantit $\Omega < 1$, c'est-à-dire que la phase 2 contracte vraiment ;
- $2M_1$ garantit $\vartheta M - 2\Delta > 0$, c'est-à-dire que l'événement de capture est atteignable (phase 1).

Autrement dit : assez de bits pour voir l'état, et assez de bits pour le réduire.

Recette : plan de la démonstration, à lire avant les preuves

La démonstration se décompose en trois briques indépendantes, et c'est cette décomposition, plus que les calculs, qu'il faut retenir.

1. **La phase 1 se termine.** Commande coupée, l'état croît au plus exponentiellement ; μ croît plus vite ; donc le rapport état/portée tend vers zéro et l'événement finit par se déclencher. C'est le *lemme de zoom*.
2. **La phase 2 contracte.** À μ figé, la quantification devient une perturbation frontière dont on montre qu'elle est une *fraction* de l'état lui-même. On referme alors par petit gain et l'on obtient une décroissance de taux δ pendant T secondes.
3. **Récurrence.** On divise μ par Ω et l'on recommence.

Un lecteur pressé peut se contenter de ce plan et des énoncés, et revenir aux preuves plus tard.

3.3.3.2 Étape 1 : la phase 1 se termine (lemme de zoom)

Lemme 3.21 (croissance en boucle ouverte). *Sur $[0, t_1^*)$, où $U \equiv 0$, on a*

$$\|(X(t), u(\cdot, t))\| \leq \mathcal{M}_1 e^{|A|t} \|(X_0, u_0)\|, \quad \mathcal{M}_1 = 1 + D|B|. \quad (3.63)$$

Démonstration. Comme $u(D, t) = U(t) = 0$, la méthode des caractéristiques donne $u(x, t) = u_0(x + t)$ si $x + t \leq D$ et $u(x, t) = 0$ sinon ; donc $\|u(\cdot, t)\|_\infty \leq \|u_0\|_\infty$ (et $u \equiv 0$ pour $t \geq D$). Ensuite

$$|X(t)| \leq e^{|A|t} |X_0| + \int_0^t e^{|A|(t-s)} |B| |u(0, s)| \, ds \leq e^{|A|t} (|X_0| + |B| \min\{t, D\} \|u_0\|_\infty),$$

car $u(0, s) = u_0(s)$ pour $s \leq D$ et 0 ensuite. En additionnant, $|X(t)| + \|u(\cdot, t)\|_\infty \leq e^{|A|t} (1 + D|B|)(|X_0| + \|u_0\|_\infty)$. $\square$

Lemme 3.22 (capture en temps fini). *Sous (3.61), il existe $j \in \mathbb{N}$ fini tel que $\mathcal{E}(j\tau)$ est vrai. De plus, à l'instant t_1^* :*

$$\|(X(t_1^*), u(\cdot, t_1^*))\| \leq \vartheta M \mu_\star, \quad \text{donc} \quad \|(X(t_1^*), w(\cdot, t_1^*))\| \leq \frac{M_2 M \mu_\star}{1 + M_0}, \quad (3.64)$$

où $\mu_\star := \mu(t_1^*)$.

Démonstration. (a) L'événement finit par se produire. La condition (3.61) implique $\Delta < \frac{M_2 M}{2M_1(1+M_0)} = \frac{1}{2}\vartheta M$, donc $\vartheta M - 2\Delta > 0$. Supposons par l'absurde que $\mathcal{E}(j\tau)$ soit faux pour tout j . Si l'on avait $\|(X, u)(j\tau)\| \leq (\vartheta M - 2\Delta)\mu(j\tau)$, alors comme $\vartheta M - 2\Delta < M$ la propriété (P1) donnerait

$$\|q_\mu(X, u)\| \leq \|(X, u)\| + \Delta\mu \leq (\vartheta M - \Delta)\mu,$$

c'est-à-dire $\mathcal{E}(j\tau)$: contradiction. Donc pour tout j

$$\|(X, u)(j\tau)\| > (\vartheta M - 2\Delta) \mu(j\tau) = (\vartheta M - 2\Delta) \mathcal{M}_1 e^{2|A|j\tau} \mu_0.$$

Mais le lemme 3.21 donne $\|(X, u)(j\tau)\| \leq \mathcal{M}_1 e^{|A|j\tau} \|(X_0, u_0)\|$. En combinant :

$$e^{|A|j\tau} < \frac{\|(X_0, u_0)\|}{(\vartheta M - 2\Delta) \mu_0} \quad \text{pour tout } j,$$

ce qui est absurde puisque le membre de gauche tend vers $+\infty$.

(b) *Ce que l'événement garantit.* Notons $z = (X, u)(t_1^*)$ et $\mu = \mu_*$. Si l'on avait $\|z\| > M\mu$, la propriété (P2) donnerait $\|q_\mu(z)\| > (M - \Delta)\mu \geq (\vartheta M - \Delta)\mu$ (car $\vartheta \leq 1$), contredisant $\mathcal{E}$. Donc $\|z\| \leq M\mu$, et (P1) s'applique :

$$\|z\| \leq \|q_\mu(z)\| + \Delta\mu \leq (\vartheta M - \Delta)\mu + \Delta\mu = \vartheta M\mu.$$

Enfin (3.40) et (3.54) donnent $\|(X, w)\| \leq M_1 \vartheta M\mu = \frac{M_2 M\mu}{1 + M_0}$. □

Attention : où sert exactement chaque propriété

(P1) sert *deux fois* : pour déclencher l'événement (a) et pour majorer l'erreur une fois capturé (b). (P2) sert *une seule fois*, mais elle est indispensable : sans elle, une mesure écrêtée petite pourrait faire croire à tort que l'état est petit. C'est le scénario catastrophe évoqué au section 1.7. (P3) ne sert pas ici : elle sert seulement à garantir $U(t) = 0$ quand l'état est exactement à l'origine, donc à obtenir un point d'équilibre.

3.3.3.3 Étape 2 : la phase 2 contracte

Lemme 3.23 (ISS de la cascade cible en normes pondérées). *Soit (X, w) solution de (3.37) et (3.39) avec $w(D, t) = d(t)$ sur $[t_0, t]$, et soit $\delta \in (0, \sigma)$. Alors, avec les normes pondérées (A.17) de paramètre δ ,*

$$\|(X, w)\|_{[t_0, t]} \leq \max\{M_\sigma, e^{\delta D}(1 + g_B)\} \|(X, w)(t_0)\| + e^{\delta D}(1 + g_B) |d|_{[t_0, t]}, \quad (3.65)$$

où $g_B := \frac{M_\sigma |B|}{\sigma - \delta}$, pourvu que le membre de droite soit fini.

Démonstration. Le corollaire A.12 appliqué à $w_t = w_x$, $w(D, t) = d$, avec $\nu = \delta$:

$$\|w\|_{[t_0, t]} \leq e^{\delta D} (\|w(\cdot, t_0)\|_\infty + |d|_{[t_0, t]}). \quad (3.66)$$

Le lemme A.14 appliqué à $\dot{X} = (A + BK)X + Bw(0, t)$, en notant $|w(0, s)| \leq \|w(\cdot, s)\|_\infty$:

$$|X|_{[t_0, t]} \leq M_\sigma |X(t_0)| + g_B \|w\|_{[t_0, t]}. \quad (3.67)$$

En additionnant (3.66) et (3.67) et en majorant $\|w(\cdot, t_0)\|_\infty \leq \|(X, w)(t_0)\|$, $|X(t_0)| \leq \|(X, w)(t_0)\|$, on obtient (3.65). □

Lemme 3.24 (contraction sur une période). *Soit $\mu > 0$ constant sur $(t_0, t_0 + T]$ et supposons*

$$\|(X, w)(t_0)\| \leq \frac{M_2 M\mu}{1 + M_0}. \quad (3.68)$$

Alors, sous (3.60) et (3.61), pour tout $t \in (t_0, t_0 + T]$:

$$\|(X, u)(t)\| \leq M\mu \quad (\text{pas de saturation}), \quad (3.69)$$

$$\|(X, w)(t)\| \leq \max \left\{ (1 + M_0)e^{-\delta(t-t_0)} \|(X, w)(t_0)\|, \frac{\Omega M_2 M\mu}{1 + M_0} \right\}, \quad (3.70)$$

et en particulier $\|(X, w)(t_0 + T)\| \leq \frac{M_2 M(\Omega\mu)}{1 + M_0}$.

Démonstration. (a) Hypothèse de bande. Supposons d'abord

$$\|(X, w)(s)\| \geq \frac{\Omega M_2 M\mu}{(1 + M_0)^2} \quad \text{pour tout } s \in [t_0, t]. \quad (3.71)$$

(b) La quantification devient une rétroaction, pas une perturbation. Tant que $\|(X, u)(s)\| \leq M\mu$, le lemme 3.18 donne $|d(s)| \leq M_3 \Delta\mu$. Or, par définition (3.55) de Ω ,

$$M_3 \Delta\mu = \frac{\Omega M_2 M\mu}{(1 + \lambda)(1 + M_0)^2} \stackrel{(3.71)}{\leq} \frac{1}{1 + \lambda} \|(X, w)(s)\|,$$

donc $|d|_{[t_0, t]} \leq \frac{1}{1 + \lambda} \|(X, w)\|_{[t_0, t]}$.

(c) Fermeture par petit gain. En reportant dans (3.66) et (3.67) :

$$\|w\| \leq e^{\delta D} \|w(\cdot, t_0)\|_\infty + \frac{e^{\delta D}}{1 + \lambda} (|X| + \|w\|), \quad |X| \leq M_\sigma |X(t_0)| + g_B \|w\|$$

(toutes les normes sur $[t_0, t]$). En substituant la seconde dans la première :

$$\left(1 - \underbrace{\frac{e^{\delta D}(1 + g_B)}{1 + \lambda}}_{=\varphi}\right) \|w\| \leq e^{\delta D} \|w(\cdot, t_0)\|_\infty + \frac{e^{\delta D} M_\sigma}{1 + \lambda} |X(t_0)|.$$

Comme $\varphi < 1$ (lemme A.17), on peut diviser ; en réinjectant dans $|X| \leq M_\sigma |X(t_0)| + g_B \|w\|$ et en sommant :

$$\|(X, w)\|_{[t_0, t]} \leq \frac{M_\sigma}{1 - \varphi} |X(t_0)| + \frac{(1 + \lambda)\varphi}{1 - \varphi} \|w(\cdot, t_0)\|_\infty \leq (1 + M_0) \|(X, w)(t_0)\|,$$

la dernière inégalité étant exactement la définition (3.53) de M_0 . En revenant à la norme non pondérée :

$$\|(X, w)(t)\| \leq (1 + M_0)e^{-\delta(t-t_0)} \|(X, w)(t_0)\|. \quad (3.72)$$

(d) Cohérence : pas de saturation. Par (3.40), (3.72) et (3.68) :

$$\|(X, u)(t)\| \leq \frac{1}{M_2} \|(X, w)(t)\| \leq \frac{1 + M_0}{M_2} \cdot \frac{M_2 M\mu}{1 + M_0} = M\mu.$$

L'hypothèse utilisée en (b) est donc auto-cohérente : par continuité, l'ensemble des t de la fenêtre où $\|(X, u)\| \leq M\mu$ est non vide, ouvert et fermé, donc égal à la fenêtre entière.

(e) Valeur finale. Par (3.56), $e^{-\delta T} = \Omega/(1 + M_0)$, d'où $\|(X, w)(t_0 + T)\| \leq \Omega \|(X, w)(t_0)\| \leq \frac{\Omega M_2 M\mu}{1 + M_0}$.

(f) Si la bande est violée. Soit $t_\#$ le premier instant où $\|(X, w)\| < \frac{\Omega M_2 M\mu}{(1 + M_0)^2}$. Ou bien la solution reste sous ce seuil jusqu'à $t_0 + T$, auquel cas (3.70) est vraie *a fortiori*, ou bien elle le retranscend en $t_\#$; par continuité $\|(X, w)(t_\#)\| = \frac{\Omega M_2 M\mu}{(1 + M_0)^2}$ et l'analyse (a) à (e) appliquée à partir de $t_\#$ donne $\|(X, w)(t)\| \leq (1 + M_0) \|(X, w)(t_\#)\| = \frac{\Omega M_2 M\mu}{1 + M_0}$. Dans tous les cas (3.70) est établie. $\square$

Intuition : la preuve précédente en trois phrases

1. La quantification se traduit par une perturbation d à la frontière du système cible, bornée par $M_3\Delta\mu$.
2. Tant que l'état n'est pas déjà minuscule, cette borne se réécrit comme une fraction $\frac{1}{1+\lambda}$ de l'état : ce n'est donc pas une perturbation extérieure, c'est une *boucle*.
3. Le transport et l'équation différentielle ordinaire ont chacun un gain entrée-état ; leur produit est $\varphi < 1$, la boucle se referme, et l'état décroît au taux δ jusqu'au plancher fixé par μ . On abaisse alors μ et l'on recommence.

3.3.3.4 Étape 3 : assemblage

Preuve du théorème 3.20. (i) est le lemme 3.22, qui fournit de surcroît (3.64), c'est-à-dire l'hypothèse (3.68) à $t_0 = t_1^*$, $\mu = \mu_*$.

(ii) Récurrence sur $i \geq 1$. Posons $t_i = t_1^* + (i-1)T$ et $\mu_i = \Omega^{i-1}\mu_*$, et supposons $\|(X, w)(t_i)\| \leq \frac{M_2 M \mu_i}{1+M_0}$. Sur $(t_i, t_{i+1}]$, $\mu \equiv \mu_i$ d'après (3.59) ; le lemme 3.24 donne $\|(X, u)(t)\| \leq M\mu_i$ (c'est (ii) du théorème) et $\|(X, w)(t_{i+1})\| \leq \frac{M_2 M \mu_{i+1}}{1+M_0}$: la propriété se propage.

(iii) Pour $t \in (t_i, t_{i+1}]$, $\|(X, u)(t)\| \leq M\mu_i = M\mu_*\Omega^{i-1}$. Comme $i-1 \geq \frac{t-t_1^*}{T} - 1$ et $\Omega < 1$,

$$\|(X, u)(t)\| \leq \frac{M\mu_*}{\Omega} \Omega^{\frac{t-t_1^*}{T}} = \frac{M\mu_*}{\Omega} e^{-\frac{1}{T} \ln \frac{1}{\Omega} (t-t_1^*)},$$

soit (3.62). Enfin $\mu(t) = \Omega^{i-1}\mu_* \rightarrow 0$ et $|U(t)| \leq M_3 \|(X, u)\| + M_3\Delta\mu \rightarrow 0$. $\square$

Remarque 3.25 (ce que le théorème ne dit pas). Il ne dit pas que la convergence est *uniforme* par rapport à $\|(X_0, u_0)\|$: t_1^* dépend de la condition initiale (et de μ_0). On a donc une stabilité asymptotique globale *sans* estimation de type $\mathcal{KL}$ uniforme ; c'est intrinsèque au schéma à deux phases. Il ne dit pas non plus que $\mu(t) \rightarrow 0$ est souhaitable en pratique : voir §B.3.1.

3.3.4 Variante : entrée quantifiée, retard connu**3.3.4.1 Le problème**

On suppose maintenant que (X, u) est *connu exactement* du contrôleur, mais que la commande transite par un canal quantifié :

$$U(t) = \begin{cases} 0, & t \leq t_1^*, \\ \mu(t) q\left(\frac{U_{\text{nom}}(t)}{\mu(t)}\right), & t > t_1^*, \end{cases} \quad U_{\text{nom}} = K\mathcal{P}(X, u). \quad (3.73)$$

C'est la situation d'un actionneur déporté commandé par bus numérique, très fréquente en pratique, et c'est aussi celle où le retard D est *causé* par le réseau qui quantifie.

3.3.4.2 Ce qui change (et ce qui ne change pas)

La perturbation frontière devient directement

$$\bar{d}(t) = w(D, t) = U(t) - U_{\text{nom}}(t) = \mu \left[q\left(\frac{U_{\text{nom}}}{\mu}\right) - \frac{U_{\text{nom}}}{\mu} \right], \quad \boxed{|\bar{d}(t)| \leq \Delta \mu(t)} \quad (3.74)$$

pourvu que $|U_{\text{nom}}(t)| \leq M\mu(t)$ (non-saturation). On économise donc le facteur M_3 dans la borne sur la perturbation, mais on le retrouve dans la condition de non-saturation, car c'est U_{nom} , et non l'état, qui doit tenir dans la fenêtre.

Recette : le nouvel invariant

On propage désormais

$$\|(X, w)(t_i)\| \leq \frac{M_2 M \mu_i}{(1 + M_0) M_3}, \quad (3.75)$$

qui garantit précisément $|U_{\text{nom}}| \leq M_3 \|(X, u)\| \leq \frac{M_3}{M_2} \|(X, w)\| \leq M\mu$ sur toute la période.

Comme l'état est mesuré exactement, **l'événement de commutation est directement calculable** :

$$\bar{\mathcal{E}}(t) : \quad |X(t)| + \|w(\cdot, t)\|_\infty \leq \frac{M_2 M \mu(t)}{(1 + M_0) M_3}, \quad (3.76)$$

et les propriétés (P2), (P3) du quantificateur ne sont plus nécessaires : seule (P1) sert.

Théorème 3.26 (entrée quantifiée). *Sous (3.60) et*

$$\frac{\Delta}{M} < \frac{M_2}{(1 + \lambda)(1 + M_0)^2 M_3}, \quad (3.77)$$

la loi (3.73) avec l'événement (3.76) et la loi de zoom (3.59) (où Ω est toujours donné par (3.55)) rend l'origine globalement asymptotiquement stable, avec l'estimation (3.62).

Esquisse. Identique à celle du théorème 3.20 en remplaçant partout l'invariant $\frac{M_2 M \mu}{1 + M_0}$ par (3.75) et la borne $M_3 \Delta \mu$ par $\Delta \mu$. La bande devient $\|(X, w)(s)\| \geq \frac{\Omega M_2 M \mu}{(1 + M_0)^2 M_3}$; alors

$$|\bar{d}| \leq \Delta \mu = \frac{\Omega M_2 M \mu}{(1 + \lambda)(1 + M_0)^2 M_3} \leq \frac{1}{1 + \lambda} \|(X, w)(s)\|,$$

et le petit gain se ferme exactement comme en (c). La phase 1 se termine sans condition supplémentaire puisque $\bar{\mathcal{E}}$ ne fait intervenir aucune mesure quantifiée : μ croît comme $e^{2|A|t}$ tandis que $\|(X, w)\|$ croît au plus comme $M_1 \mathcal{M}_1 e^{|A|t} \|(X_0, u_0)\|$. $\square$

En pratique : comparaison des deux conditions

$$\underbrace{\frac{M_2}{(1 + M_0) \max\{(1 + \lambda)(1 + M_0) M_3, 2M_1\}}}_{\text{état quantifié}} \quad \text{vs} \quad \underbrace{\frac{M_2}{(1 + \lambda)(1 + M_0)^2 M_3}}_{\text{entrée quantifiée}}.$$

Les deux expressions coïncident sur la première branche : *quantifier l'entrée ne coûte pas moins de bits pour contracter*. Ce que l'on gagne, c'est la disparition de la branche $2M_1$, c'est-à-dire du coût de la *détection* de la capture. En pratique cela représente typiquement 1 à 2 bits.

Attention : l'erreur à ne pas commettre

On lit parfois que « quantifier l'entrée est plus facile parce que la perturbation est bornée par $\Delta \mu$ au lieu de $M_3 \Delta \mu$ ». C'est vrai *terme à terme*, mais trompeur : l'invariant qu'il faut propager est M_3 fois plus serré (3.75). Les deux effets se compensent *exactement*. La leçon générale : on ne peut pas comparer deux bornes sans comparer aussi les ensembles invariants sur lesquels elles vivent.

3.3.5 Simulation du système à retard quantifié

3.3.5.1 Le banc d'essai

On reprend la structure d'exemple de [26, §5]. Pour un dispositif physique réel présentant simultanément retard et quantification de l'entrée, voir [25].

$$\dot{X} = \begin{pmatrix} 0 & 1 \\ 2 & 0 \end{pmatrix} X + \begin{pmatrix} 0 \\ 1 \end{pmatrix} U(t - D), \quad D = 0,2, \quad X_0 = (2, -1), \quad u_0 \equiv 0,$$

$K = (-4, 25, -3)$ (pôles doubles en $-1,5$), quantificateur uniforme saturant de portée $M = 4$, $\mu_0 = 0,05$, $\tau = 0,05$.

3.3.5.2 Le réglage certifié est inutilisable... et c'est instructif

Les formules de la section 3.3.3 donnent, pour ce système, $M_1 = 8,76$, $M_2 = 0,0819$, $M_3 = 9,31$, $M_\sigma = 2,56$, $\sigma = 0,398$, et l'optimisation de (λ, δ) conduit à :

Δ/M (bits)	$(N$	δ	λ	M_0	Ω	T (s)	taux certifié	ϑ
2^{-19}		0,034	23,3	11,1	0,774	80,6	0,0032	$7,7 \cdot 10^{-4}$
2^{-20}		0,076	26,3	12,6	0,549	42,2	0,0142	$6,9 \cdot 10^{-4}$
2^{-22}		0,144	33,2	16,1	0,272	28,7	0,0454	$5,5 \cdot 10^{-4}$
2^{-24}		0,195	41,5	20,2	0,130	26,2	0,0781	$4,4 \cdot 10^{-4}$

Attention : ne pas s'arrêter au chiffre

19 bits et un taux de $0,003 \text{ s}^{-1}$: la garantie est *correcte* mais très loin de ce que l'on observe. Trois sources de conservatisme, identifiables et hiérarchisables :

1. $\vartheta \sim 10^{-3}$ impose $\mu \sim 10^3 \|(X, u)\|$ à la capture : on exige de « voir » l'état avec une marge de 1000, alors qu'une marge de 2 suffit en pratique ;
2. les normes matricielles $(|K| e^{|A|D})$ remplacent $\|Ke^{AD}\|$, ce qui surestime M_1, M_3 d'un facteur 2 à 5 ;
3. le petit gain suppose le *pire* alignement de phase entre l'erreur de quantification et l'état, alors que l'erreur est en pratique équirépartie.

La bonne posture : utiliser les formules pour *savoir quels leviers existent* (§2.4) et la simulation pour *choisir les valeurs*.

3.3.5.3 Le réglage pratique

On garde la *structure* (deux phases, événement, μ constant par morceaux) et on relâche les constantes :

$$\vartheta_{\text{prat}} = 0,5, \quad \Omega = 0,7, \quad T = 0,8 \text{ s}, \quad N = 8 \text{ bits}.$$

3.3.5.4 Observations

1. **5 bits suffisent déjà** sur cet exemple (courbe verte) : la décroissance est un peu plus irrégulière, mais elle a lieu. On est à 14 bits de la garantie théorique.
2. **L'instant de capture ne dépend pas du nombre de bits** ici ($t_1^* = 0,96 \text{ s}$ dans les deux cas) : il est fixé par la vitesse de croissance de μ et par $\|(X_0, u_0)\|$, pas par Δ . C'est conforme au lemme 3.22.




FIGURE 3.6 : Norme de l'état étendu et variable de zoom. Le pic à t_1^* est *normal* : $\|(X, u)\|$ contient $\|u\|_\infty = \sup_{s \in [t-D, t]} |U(s)|$, c'est-à-dire la commande *en transit* ; le premier coup de commande (figure 3.7) est violent, donc la norme monte avant de descendre. La convergence est ensuite exponentielle.




FIGURE 3.7 : Commande. Nulle jusqu'à t_1^* , puis un transitoire bref et enfin une décroissance vers 0 : l'énergie de commande tend vers zéro, contrairement au cas d'un quantificateur fixe où elle « bavarde » indéfiniment.

3. **Le pic de $\|(X, u)\|$ à la capture** est le prix de la phase 1 : pendant qu'on ne commande pas, l'état diverge ($|A| = 2$), et il faut ensuite un gros coup de commande. Réduire μ_0 ou accélérer la croissance de μ raccourcit la phase 1 mais augmente le risque de capturer sur une mesure encore saturée.

En pratique : à essayer

1. Descendre à 3 bits : repérer le seuil expérimental exact.
2. Mettre $D = 0,5$ sans changer le reste : le pic explose. Puis recalculer le nombre de bits nécessaire.
3. Remplacer le prédicteur quantifié (3.48) par $K\mathcal{P}(q_\mu(X), u)$ (état quantifié, historique exact) : c'est le cas « mesure quantifiée seule », plus favorable.
4. Introduire une erreur de 10% sur D dans le prédicteur : observer la perte de robustesse. C'est le sujet ouvert du §B.3.3.

3.3.5.5 Les figures de l'article original

Là encore, il faut voir les figures de l'article [26], pour la même raison qu'à la section 3.2.4.3 : elles contiennent les deux contre-exemples à zoom figé, qui sont la meilleure justification de tout l'appareillage.




FIGURE 3.8 : **La loi à prédicteur commuté.** À gauche, la norme $|X(t)| + \|u(t)\|_\infty$ de l'état de la cascade EDO-EDP en boucle fermée (trait plein) et le signal de commutation $\mu(t)M\overline{M}$ (tirets) : la structure en escalier descendant de μ est visible, et la norme reste sous la borne à chaque instant. À droite, les deux composantes de l'état de l'EDO et le profil espace-temps $u(x, t)$ de l'état d'actionneur, le « contenu du tuyau » de longueur D qui représente le retard. Paramètres : $D = 1$, $M = 2$, $\Delta = M/100$, $\overline{M} = 0,6$, $\overline{M}_1 = 2$, $\Omega = 0,63$, $T = 2$, $\mu_0 = 1$.⁴

4. Source : Figures reproduites de [26, Fig. 2 et 3], préprint arXiv:2404.11194.




FIGURE 3.9 : Les mêmes deux modes d'échec qu'à la figure 3.4, cette fois sur la cascade avec retard, et sous la loi *nominale* (prédicteur non compensé). (a) Avec un μ figé trop petit, la portée est insuffisante, le quantificateur sature et la norme atteint 10^5 en dix secondes. (b) Avec un μ figé trop grand, il n'y a pas de divergence, mais la norme stagne autour de 5 à 10 au lieu de tendre vers zéro, avec des rebonds réguliers : c'est la stabilité pratique, et rien de plus. Noter que les deux graphiques n'ont pas la même échelle verticale, 10^5 à gauche, 70 à droite.⁵

3.3.5.6 Reproduire ces figures

Code

delay_quantized_predictor.py, dépôt https://github.com/Flo3221/codes_mini_cours_quantification. Code MATLAB d'origine de l'article : <https://github.com/Flo3221/quantizerp>.

Le script implémente la cascade. Le point délicat est la représentation de l'historique de commande : on stocke U sur une fenêtre glissante de longueur D dans un tampon circulaire, et l'intégrale du prédicteur (3.33) est évaluée par la méthode des trapèzes sur ce tampon. C'est là que se logent la plupart des erreurs d'implémentation des lois à prédicteur ; on consultera [20] pour une étude systématique des approximations numériques du prédicteur.

5. Source : Figures reproduites de [26, Fig. 4 et 6], préprint [arXiv:2404.11194](https://arxiv.org/abs/2404.11194).

Annexe A

Boîte à outils pour la dimension infinie

Cette annexe rassemble tout ce dont le chapitre 3 a besoin et qui n'appartient pas en propre au sujet de la quantification : l'EDP de transport et sa solution explicite, le backstepping frontière, la stabilité entrée-état en norme sup, les normes pondérées, le lemme de petit gain, et le dictionnaire entre EDP de transport et équations à retard. Elle est écrite pour pouvoir se lire d'une traite, indépendamment du reste.

A.1 L'EDP de transport : tout ce qu'il faut savoir

Intuition : pourquoi une EDP dans un cours sur la quantification ?

Pour deux raisons, et la seconde est une surprise agréable.

1. Beaucoup de systèmes physiques *sont* des EDP de transport : écoulements, trafic routier, convoyeurs, réseaux de canaux, échangeurs thermiques, forage pétrolier. . .
2. **Tout retard d'entrée constant est une EDP de transport** (section 3.3). Étudier le transport, c'est donc étudier les systèmes à retard, omniprésents dès qu'il y a un réseau. Or il y a *toujours* un réseau quand il y a de la quantification.

A.1.1 Le modèle et sa solution explicite

Soit $D > 0$. On considère, pour $x \in [0, D]$ et $t \geq 0$,

$$u_t(x, t) = u_x(x, t), \quad u(D, t) = U(t), \quad u(x, 0) = u_0(x). \quad (\text{A.1})$$

Attention : le signe compte

L'équation est $u_t = u_x$ (et non $u_t = -u_x$) : l'information se propage vers les x *décroissants*, donc de la frontière $x = D$ (où l'on agit) vers $x = 0$. C'est cohérent : la commande doit pouvoir influencer le système. Si l'on avait $u_t = -u_x$ avec commande en $x = D$, la commande n'aurait aucun effet : le système serait non commandable depuis ce bord.

Proposition A.1 (méthode des caractéristiques). *La solution de (A.1) est*

$$u(x, t) = \begin{cases} u_0(x+t), & x+t \leq D, \\ U(t+x-D), & x+t > D. \end{cases} \quad (\text{A.2})$$

Démonstration. Le long d'une courbe $s \mapsto (x(s), t(s)) = (x_0 - s, t_0 + s)$ on a $\frac{d}{ds}u(x(s), t(s)) = -u_x + u_t = 0$: u est constante le long des droites $x + t = \text{cste}$. Une telle droite issue de (x, t) rencontre soit l'axe $t = 0$ au point $x + t$ (si $x + t \leq D$), soit le bord $x = D$ à l'instant $t + x - D$. $\square$




FIGURE A.1 : Caractéristiques de $u_t = u_x$. Après $t = D$, la donnée initiale a entièrement quitté le domaine : seule la commande subsiste.

Corollaire A.2 (stabilité en temps fini). *Si $U \equiv 0$, alors $u(\cdot, t) \equiv 0$ pour tout $t \geq D$. De plus $\|u(\cdot, t)\|_\infty \leq \|u_0\|_\infty$ pour tout $t \geq 0$.*

C'est la propriété miraculeuse du transport : avec $U \equiv 0$ à la frontière d'entrée, l'état est purgé en temps fini D . On n'a même pas besoin de Lyapunov. Toute la stratégie de backstepping consistera à ramener un système compliqué à cette situation.

A.1.2 L'espace d'état L^∞ et pourquoi ce choix

On travaille dans $L^\infty([0, D]; \mathbb{R})$ avec $\|u\|_\infty = \text{ess sup}_{x \in [0, D]} |u(x)|$.

En pratique : trois raisons de préférer L^∞ à L^2 ici

1. **La quantification est une contrainte d'amplitude.** (P1) s'écrit $|q(z) - z| \leq \Delta$ point par point : c'est une borne L^∞ native. En L^2 , il faudrait intégrer, ce qui introduit des facteurs $\sqrt{D}$ et surtout ne contrôle pas la saturation en un point.
2. **La saturation est un phénomène ponctuel.** Un état de petite norme L^2 peut avoir un pic qui sature le quantificateur. La propriété (P2) serait alors inexploitable.
3. **Le transport est une isométrie en L^∞** (corollaire A.2) : les estimations sont sans constante parasite.

Le prix à payer : les outils hilbertiens (fonctionnelles de Lyapunov quadratiques, inégalités de Poincaré) ne sont plus disponibles. On les remplace par des *estimations ISS en norme sup*, section A.3.

A.1.3 Le modèle « strict-feedback »

La classe considérée ici est celle de [24, éq. (1) à (3)], elle-même issue des travaux de backstepping de Krstic et Smyshlyaev [16].

Le système réellement étudié dans la section 3 est

$$u_t(x, t) = u_x(x, t) + g(x) u(0, t) + \int_0^x \bar{g}(x, y) u(y, t) dy, \quad (\text{A.3})$$

$$u(D, t) = U(t), \quad (\text{A.4})$$

avec g et $\bar{g}$ continues.

Intuition : pourquoi ce système est-il instable ?

Le terme $g(x)u(0, t)$ est une *rétroaction interne* : la valeur au bord « aval » $x = 0$ est réinjectée dans tout le domaine. Imaginons $\bar{g} \equiv 0$ et g constante. Une perturbation arrivant en $x = 0$ est instantanément copiée (avec un gain g) dans tout le domaine, puis retransportée vers $x = 0$ en un temps D , où elle est de nouveau amplifiée. On a donc une *boucle de gain* $\sim g$ avec un retard D : si g est assez grand, le système explose. C'est l'analogie infini-dimensionnel d'un $\dot{X} = aX$ avec $a > 0$.

Exemple A.3 (le cas de la simulation). On prendra $D = 1$, $\bar{g} \equiv 0$, $g \equiv 1,25$. On vérifie numériquement (et analytiquement, exercice A.1) que la boucle ouverte $U \equiv 0$ est instable.

Exercice A.1. Avec $\bar{g} \equiv 0$, g constante et $U \equiv 0$, montrer en posant $\eta(t) := u(0, t)$ que η vérifie l'équation à retard $\eta(t) = g \int_{t-D}^t \eta(s) ds$ pour $t \geq D$, puis que les solutions de la forme $\eta(t) = e^{st}$ existent avec s racine de $s = g(1 - e^{-sD})$. Montrer qu'il existe une racine réelle $s > 0$ dès que $gD > 1$. Conclure pour $g = 1,25$, $D = 1$.

A.2 Backstepping frontière : construire le système cible

A.2.1 L'idée en une phrase

Le backstepping cherche un changement de variable $u \mapsto w$, inversible, tel que la dynamique compliquée de u devienne la dynamique triviale de w (le transport pur), la commande U servant à imposer la condition au bord $w(D, t) = 0$.

C'est exactement ce qu'on fait en dimension finie avec un changement de base mettant A sous forme de Jordan, à ceci près que la transformation est ici intégrale et non locale. La méthode est exposée en détail dans le livre de Krstic et Smyshlyaev [15, ch. 4] ; le cas hyperbolique du premier ordre qui nous occupe est traité dans [16].

A.2.2 La transformation de Volterra

On cherche

$$w(x, t) = u(x, t) - \int_0^x k(x, y) u(y, t) dy, \quad (\text{A.5})$$

$$u(x, t) = w(x, t) + \int_0^x \ell(x, y) w(y, t) dy. \quad (\text{A.6})$$

Remarque A.4 (pourquoi « triangulaire » ?). L'intégrale porte sur $[0, x]$ et non sur $[0, D]$: la valeur de w en x ne dépend que des valeurs de u « en amont ». C'est l'analogie d'une matrice triangulaire inférieure. Deux conséquences majeures :

- la transformation est *automatiquement inversible* (théorème de Volterra : $I - \mathcal{K}$ est inversible pour tout noyau borné, car $\mathcal{K}$ est quasi-nilpotent) ;
- elle préserve la structure causale, donc les conditions au bord en $x = 0$: $w(0, t) = u(0, t)$.

A.2.3 Les équations du noyau

Le calcul qui suit est classique ; on le refait entièrement parce que c'est le seul endroit du cours où la transformation de backstepping est construite plutôt qu'invoquée. Le résultat coïncide avec [16, éq. (6) à (8)].

Théorème A.5 (équations du noyau). *La transformation (A.5) envoie (A.3) sur*

$$w_t(x, t) = w_x(x, t) \quad (\text{A.7})$$

si et seulement si k satisfait, sur le triangle $\mathcal{T} = \{0 \leq y \leq x \leq D\}$,

$$k_x(x, y) + k_y(x, y) = -\bar{g}(x, y) + \int_y^x k(x, s) \bar{g}(s, y) ds, \quad (\text{A.8})$$

$$k(x, 0) = -g(x) + \int_0^x k(x, y) g(y) dy. \quad (\text{A.9})$$

La condition au bord transformée est alors

$$w(D, t) = U(t) - \int_0^D k(D, x) u(x, t) dx. \quad (\text{A.10})$$

Démonstration. Dérivons (A.5) en temps et remplaçons u_t par (A.3) :

$$w_t = u_x + g(x)u(0) + \int_0^x \bar{g}(x, y)u(y) dy - \int_0^x k(x, y) \left[u_y + g(y)u(0) + \int_0^y \bar{g}(y, s)u(s) ds \right] dy.$$

Une intégration par parties donne $\int_0^x k(x, y)u_y dy = k(x, x)u(x) - k(x, 0)u(0) - \int_0^x k_y(x, y)u(y) dy$, et l'échange de l'ordre d'intégration (théorème de Fubini) donne

$$\int_0^x k(x, y) \int_0^y \bar{g}(y, s)u(s) ds dy = \int_0^x \left(\int_s^x k(x, y) \bar{g}(y, s) dy \right) u(s) ds.$$

Par ailleurs, en dérivant (A.5) en espace, $w_x = u_x - k(x, x)u(x) - \int_0^x k_x(x, y)u(y) dy$. En soustrayant, l'identité $w_t = w_x$ équivaut à

$$\int_0^x \left[k_x + k_y + \bar{g}(x, y) - \int_y^x k(x, s) \bar{g}(s, y) ds \right] u(y) dy + u(0) \left[g(x) + k(x, 0) - \int_0^x k(x, y) g(y) dy \right] = 0.$$

Comme ceci doit valoir pour toute donnée u , les deux crochets s'annulent : c'est (A.8) et (A.9). Enfin (A.10) s'obtient en évaluant (A.5) en $x = D$. $\square$

Remarque A.6 (caractère bien posé du noyau). (A.8) et (A.9) est une EDP hyperbolique du premier ordre sur un triangle, avec donnée sur le bord $y = 0$. En intégrant le long des caractéristiques $x - y = \text{cte}$ on la transforme en une équation intégrale de Volterra à laquelle on applique la méthode des approximations successives ; on obtient l'existence, l'unicité et la continuité de k , avec la borne $|k(x, y)| \leq \bar{G}e^{\bar{G}D}$ où $\bar{G}$ majore $|g|$ et $D|\bar{g}|$. Voir [15] pour la théorie complète.

A.2.4 Le cas explicite $\bar{g} \equiv 0$, g constante

C'est le cas de toutes les simulations ; il est entièrement calculable, et c'est un excellent exercice.

Proposition A.7. *Si $\bar{g} \equiv 0$ et $g(x) \equiv g$ constante, alors*

$$k(x, y) = -g e^{g(x-y)}, \quad \ell(x, y) = -g. \quad (\text{A.11})$$

Démonstration. Noyau direct. (A.8) devient $k_x + k_y = 0$, donc $k(x, y) = \varphi(x - y)$ pour une fonction φ . La condition (A.9) s'écrit alors

$$\varphi(x) = -g + g \int_0^x \varphi(x - y) dy = -g + g \int_0^x \varphi(s) ds.$$

En dérivant : $\varphi'(x) = g\varphi(x)$ avec $\varphi(0) = -g$, d'où $\varphi(x) = -ge^{gx}$.

Noyau inverse. On cherche ℓ tel que (A.6) renvoie la dynamique cible sur (A.3). En procédant symétriquement (mêmes calculs, rôles échangés) on trouve les conditions $\ell_x + \ell_y = 0$ et $\ell(x, 0) = -g$, d'où $\ell \equiv -g$.

Vérification directe. On peut aussi vérifier que les deux transformations sont réciproques : pour $u = w + \int_0^x \ell w$, on calcule $w = u - \int_0^x k u$ en utilisant $\int_0^x e^{g(x-y)} dy = (e^{gx} - 1)/g$. $\square$

Exercice A.2. Effectuer cette vérification directe. (Indication : poser $W(x) = \int_0^x w(y) dy$ et tout exprimer en fonction de w et W .)

A.2.5 Contrôleur nominal et système cible

En annulant (A.10) on obtient le **contrôleur nominal** :

$$U_{\text{nom}}(t) = \int_0^D k(D, x) u(x, t) dx \quad (\text{A.12})$$

qui donne le système cible parfait

$$w_t = w_x, \quad w(D, t) = 0 \implies w(\cdot, t) \equiv 0 \text{ pour } t \geq D. \quad (\text{A.13})$$

Intuition : que fait physiquement U_{nom} ?

U_{nom} est une *moyenne pondérée de l'état sur tout le domaine* ; le poids $k(D, x) = -ge^{g(D-x)}$ donne plus d'importance aux points proches de $x = 0$ (la source de l'instabilité). Le contrôleur « anticipe » ce qui va lui revenir et l'annule à l'avance. C'est exactement l'idée d'un *prédicteur*, et ce n'est pas un hasard : on le verra explicitement au section 3.3.

A.2.6 Vérification numérique

Code

`transport_backstepping_demo.py`, dépôt https://github.com/Flo3221/codes_mini_cours_quantification. Schéma décentré amont, 400 mailles, CFL = 0,5 ; le noyau est calculé analytiquement.

Avant d'ajouter la quantification, il faut vérifier que la machinerie de ce chapitre fait bien ce qu'elle promet. Prenons $D = 1$, $g = 1,25$, donc $gD > 1$: la boucle ouverte est instable (exercice A.1). Comparons $U \equiv 0$ et le contrôleur nominal $U_{\text{nom}} = \int_0^D k(D, x)u dx$.

Intuition : pourquoi cette figure est rassurante

Elle valide séparément les deux ingrédients qui seront ensuite combinés : le noyau explicite $k(x, y) = -ge^{g(x-y)}$ est bien celui qui annule le terme non local, et le système cible se vide bien en temps D . Quand, au section 3.2, la convergence deviendra seulement exponentielle au lieu d'être en temps fini, on saura que la dégradation vient de la quantification et de rien d'autre.




FIGURE A.2 : Le contrôleur nominal fait exactement ce que la théorie annonce : l'état est annulé en temps fini $D = 1$, puis ce qui subsiste n'est plus que l'erreur d'arrondi machine, évacuée par paliers de durée D . En boucle ouverte, la norme croît comme e^{s^*t} avec $s^* \approx 0,67$, racine de $s = g(1 - e^{-sD})$.




FIGURE A.3 : La commande nominale correspondante. Elle est non nulle pendant exactement D secondes, le temps de purger le tuyau, puis rigoureusement nulle. C'est la signature du système cible $w_t = w_x$, $w(D, t) = 0$.

A.2.7 Équivalence des normes : les constantes M_1, M_2, M_3

Ces trois constantes vont apparaître dans *toutes* les conditions du cours. Il faut savoir les calculer.

Proposition A.8 (équivalence de normes). *Posons*

$$M_1 := 1 + D \max_{0 \leq y \leq x \leq D} |k(x, y)|, \quad M_2 := \frac{1}{1 + D \max_{0 \leq y \leq x \leq D} |\ell(x, y)|}. \quad (\text{A.14})$$

Alors, pour tout t ,

$$M_2 \|u(\cdot, t)\|_\infty \leq \|w(\cdot, t)\|_\infty \leq M_1 \|u(\cdot, t)\|_\infty. \quad (\text{A.15})$$

Démonstration. De (A.5), pour presque tout x , $|w(x)| \leq |u(x)| + \int_0^x |k(x, y)| |u(y)| dy \leq (1 + D \max |k|) \|u\|_\infty = M_1 \|u\|_\infty$. De même (A.6) donne $\|u\|_\infty \leq (1 + D \max |\ell|) \|w\|_\infty = M_2^{-1} \|w\|_\infty$. $\square$

On introduit enfin le gain du contrôleur nominal :

$$M_3 := D \sup_{0 \leq y \leq D} |k(D, y)|, \quad \text{de sorte que} \quad |U_{\text{nom}}(t)| \leq M_3 \|u(\cdot, t)\|_\infty. \quad (\text{A.16})$$

Proposition A.9. *On a toujours $M_3 < M_1$.*

Démonstration. $M_3 = D \sup_y |k(D, y)| \leq D \max_{\mathcal{T}} |k| = M_1 - 1 < M_1$. $\square$

Cette remarque anodine servira à montrer que la condition du théorème 3.4 implique automatiquement $\Omega < 1$ (lemme 3.5).

Exemple A.10 (valeurs numériques du cas $D = 1, g = 1,25$). Avec (A.11) : $\max |k| = ge^{gD} = 1,25 e^{1,25} = 4,363$ et $\max |\ell| = g = 1,25$, donc

$$M_1 = 1 + 4,363 = 5,363, \quad M_2 = \frac{1}{1 + 1,25} = 0,4444, \quad M_3 = 4,363.$$

On vérifie bien $M_3 < M_1$. Le rapport $M_2/M_1 = 0,0829$ est la quantité qui gouvernera la condition sur Δ/M : on a besoin d'environ $1/0,083 \approx 12$ niveaux au minimum, soit 4 bits.

En pratique : lecture des constantes


- M_1 mesure combien la transformation *amplifie* : c'est le prix de la « déscorrélation » des couplages instables.
- M_2 mesure combien l'inverse amplifie ; M_2 petit signifie que w petit n'implique u petit qu'avec une grosse constante.
- M_3 est le *gain de la commande* : une commande nominale de fort gain sature plus vite le quantificateur d'entrée.
- Tous croissent avec D et avec $|g|$: **plus le système est long et instable, plus il faut de bits**. C'est la traduction, ici, du théorème du débit minimal de la section B.6.

A.3 ISS, mémoire évanescence et petit gain

Ce chapitre contient les trois lemmes qui remplacent, en dimension infinie, le simple « $\dot{V} \leq -\alpha V$ » de la dimension finie. Ils sont *démontrés* ici, ce qui rend le document auto-contenu.

A.3.1 Le schéma général de l'analyse

Les estimations de ce chapitre sont les versions en norme sup des résultats de Karafyllis et Krstic [21, ch. 3 et 9]. On les redémontre dans le cas particulier du transport, où les preuves tiennent en quelques lignes et se lisent sans bagage préalable.



Chacun des deux blocs est ISS. La quantification crée le retour du haut. Si le produit des gains est < 1 , condition dite *de petit gain*, la boucle est stable. Toute la section 3 n'est qu'une mise en œuvre soigneuse de ce diagramme.

A.3.2 Normes pondérées

Fixons $\delta > 0$ et $t_0 \geq 0$. On pose, pour $t \geq t_0$,

$$\|w\|_{[t_0, t]} := \text{ess sup}_{t_0 \leq s \leq t} \|w(\cdot, s)\|_\infty e^{\delta(s-t_0)}, \quad |X|_{[t_0, t]} := \text{ess sup}_{t_0 \leq s \leq t} |X(s)| e^{\delta(s-t_0)}. \quad (\text{A.17})$$

Intuition : à quoi sert le poids $e^{\delta s}$?

Une estimation ISS classique donne « état $\leq$ décroissance + gain $\times$ sup de l'entrée ». Le sup, lui, ne décroît pas : on perd la décroissance exponentielle en bouclant. En pondérant par $e^{\delta s}$, on *fabrique* une norme dans laquelle la boucle fermée est contractante et le taux δ est visible. C'est un simple changement de variable $\tilde{w} = e^{\delta t} w$, mais c'est l'astuce centrale.

A.3.3 ISS de l'EDP de transport en norme sup

Lemme A.11 (estimation ISS, transport). *Soit w solution de $w_t = w_x$ sur $[0, D]$ avec $w(D, t) = d(t)$. Alors pour tout $\nu > 0$ et tous $t \geq t_0 \geq 0$:*

$$\|w(\cdot, t)\|_\infty \leq e^{-\nu(t-t_0-D)} \|w(\cdot, t_0)\|_\infty + e^{\nu D} \sup_{t_0 \leq s \leq t} e^{-\nu(t-s)} |d(s)|. \quad (\text{A.18})$$

Démonstration. Par la proposition A.1 appliquée à partir de t_0 : $w(x, t) = w(x + t - t_0, t_0)$ si $x + t - t_0 \leq D$, et $w(x, t) = d(t + x - D)$ sinon.

Premier cas. Si $x + t - t_0 \leq D$ alors $t - t_0 \leq D$, donc $e^{-\nu(t-t_0-D)} \geq 1$ et $|w(x, t)| \leq \|w(\cdot, t_0)\|_\infty \leq e^{-\nu(t-t_0-D)} \|w(\cdot, t_0)\|_\infty$.

Second cas. Si $x + t - t_0 > D$, posons $s := t + x - D \in [t - D, t]$. Alors $|w(x, t)| = |d(s)|$ et $t - s = D - x \in [0, D]$, d'où

$$|d(s)| = e^{\nu(t-s)} e^{-\nu(t-s)} |d(s)| \leq e^{\nu D} \sup_{t_0 \leq r \leq t} e^{-\nu(t-r)} |d(r)|.$$

En prenant le sup sur x on obtient (A.18). □

Corollaire A.12 (version pondérée). *Si $0 < \delta \leq \nu$, alors avec les notations (A.17)*

$$\|w\|_{[t_0, t]} \leq e^{\nu D} \left(\|w(\cdot, t_0)\|_\infty + |d|_{[t_0, t]} \right). \quad (\text{A.19})$$

Démonstration. Multiplions (A.18) par $e^{\delta(t-t_0)}$. Le premier terme donne $e^{\nu D} e^{-(\nu-\delta)(t-t_0)} \|w(t_0)\|_\infty \leq e^{\nu D} \|w(t_0)\|_\infty$. Pour le second,

$$e^{\delta(t-t_0)} e^{-\nu(t-s)} |d(s)| = e^{-(\nu-\delta)(t-s)} |d(s)| e^{\delta(s-t_0)} \leq |d|_{[t_0, t]},$$

car $\nu \geq \delta$. On conclut en prenant le sup sur t . $\square$

Remarque A.13 (gain de présentation). La littérature invoque ici le lemme de mémoire évanescence (§A.3.5) pour passer du sup non pondéré au sup pondéré, au prix d'un facteur $(1 + \varepsilon)$. La démonstration directe ci-dessus l'évite pour l'EDP : c'est plus court et la constante est meilleure.

A.3.4 ISS de l'EDO en norme pondérée

Lemme A.14. Soit $\dot{X} = (A + BK)X + Bv(t)$ avec $\|e^{(A+BK)t}\| \leq M_\sigma e^{-\sigma t}$. Alors, pour $0 < \delta < \sigma$,

$$|X|_{[t_0, t]} \leq M_\sigma |X(t_0)| + \frac{M_\sigma |B|}{\sigma - \delta} \|v\|_{[t_0, t]}. \quad (\text{A.20})$$

Démonstration. Formule de variation de la constante :

$$X(t) = e^{(A+BK)(t-t_0)} X(t_0) + \int_{t_0}^t e^{(A+BK)(t-s)} Bv(s) ds,$$

d'où

$$|X(t)| \leq M_\sigma e^{-\sigma(t-t_0)} |X(t_0)| + M_\sigma |B| \int_{t_0}^t e^{-\sigma(t-s)} |v(s)| ds.$$

Multiplions par $e^{\delta(t-t_0)}$:

$$|X(t)| e^{\delta(t-t_0)} \leq M_\sigma |X(t_0)| + M_\sigma |B| \int_{t_0}^t e^{-(\sigma-\delta)(t-s)} \underbrace{|v(s)| e^{\delta(s-t_0)}}_{\leq \|v\|_{[t_0, t]}} ds,$$

$$\text{et } \int_{t_0}^t e^{-(\sigma-\delta)(t-s)} ds \leq \frac{1}{\sigma-\delta}.$$

$\square$

Remarque A.15. Ici encore, la version « convolution » évite le lemme de mémoire évanescence et donne la constante explicite $\frac{M_\sigma |B|}{\sigma-\delta}$, à comparer au $(1 + \varepsilon) \frac{M_\sigma |B|}{\sigma}$ de la littérature. Les deux coïncident quand $\delta \rightarrow 0$.

A.3.5 Le lemme de mémoire évanescence $[\star]$

On l'énonce pour mémoire, car il est utilisé tel quel dans [26] et [21].

Lemme A.16 (mémoire évanescence, [21], Lemme 7.1). Soient $\sigma > 0$, $M \geq 1$, $\varepsilon > 0$. Il existe $\delta \in (0, \sigma)$ tel que : si $\varphi, y : \mathbb{R}_+ \rightarrow \mathbb{R}_+$ sont localement bornées et s'il existe $\gamma \geq 0$ tel que pour tous $t \geq t_0 \geq 0$

$$\varphi(t) \leq M e^{-\sigma(t-t_0)} \varphi(t_0) + \gamma \sup_{t_0 \leq s \leq t} y(s), \quad (\text{A.21})$$

alors pour tout $t \geq 0$

$$\varphi(t) \leq M e^{-\delta t} \varphi(0) + \gamma(1 + \varepsilon) \sup_{0 \leq s \leq t} (y(s) e^{-\delta(t-s)}). \quad (\text{A.22})$$

Idée. L'hypothèse (A.21) vaut pour tout t_0 (propriété de semi-groupe). On découpe $[0, t]$ en $[0, t - \theta]$ et $[t - \theta, t]$ avec θ grand : sur le second morceau on applique (A.21) avec $t_0 = t - \theta$, ce qui écrase le passé lointain d'un facteur $M e^{-\sigma\theta}$; on itère. Le choix δ petit et θ tel que $M e^{-(\sigma-\delta)\theta} \leq \varepsilon/(1 + \varepsilon)$ fournit (A.22). $\square$

Intuition : ce que dit vraiment ce lemme

Une estimation ISS « brute » retient l'entrée par son *sup*, donc n'oublie jamais un pic ancien. Le lemme dit que si le système est exponentiellement stable, on peut remplacer ce *sup* par un *sup pondéré*, où les valeurs anciennes sont oubliées exponentiellement. C'est exactement ce dont on a besoin pour conclure à une décroissance.

A.3.6 Le lemme de petit gain

Lemme A.17 (petit gain, 2×2). Soient $p, q \geq 0$ et des constantes $a_1, a_2, b_1, b_2 \geq 0$ telles que

$$p \leq a_1 P_0 + a_2 q, \quad q \leq b_1 Q_0 + b_2 p.$$

Si $a_2 b_2 < 1$, alors

$$p \leq \frac{a_1 P_0 + a_2 b_1 Q_0}{1 - a_2 b_2}, \quad q \leq \frac{b_1 Q_0 + b_2 a_1 P_0}{1 - a_2 b_2}.$$

Démonstration. En substituant : $p \leq a_1 P_0 + a_2 b_1 Q_0 + a_2 b_2 p$, d'où $(1 - a_2 b_2)p \leq a_1 P_0 + a_2 b_1 Q_0$. Idem pour q . $\square$

Attention : une subtilité que l'on oublie souvent

Le lemme suppose $p, q < \infty$! Dans les applications, $p = |X|_{[t_0, t]}$ et $q = \|w\|_{[t_0, t]}$ sont finis sur tout intervalle borné où la solution existe, et c'est ce qui légitime la substitution. On raisonne donc sur $[t_0, t]$ avec t fini, puis on fait tendre $t \rightarrow \infty$. Le même soin est nécessaire dans la preuve du lemme 3.8.

A.4 Le pont : EDP de transport et équations à retard**A.4.1 Une EDP de transport est un retard**

Le dictionnaire présenté dans ce chapitre est celui de Karafyllis et Krstic [18], qui établissent l'équivalence entre équations à retard et EDP hyperboliques du premier ordre. C'est par ce biais que [24] obtient ses estimations ; nous les redémontrons directement à la section A.3 pour rester auto-contenu.

Proposition A.18. Soit w solution de $w_t = w_x$ sur $[0, D]$. Posons $\eta(\theta) := w(D, \theta)$ (la trace au bord d'entrée), prolongée par $\eta(\theta) := w(D + \theta - t, t)$ pour $\theta < t$. Alors

$$w(x, t) = \eta(t + x - D), \quad x \in [0, D]. \quad (\text{A.23})$$

En particulier $w(0, t) = \eta(t - D)$: la sortie de l'EDP est l'entrée retardée de D .

Démonstration. Immédiat par la proposition A.1 : w est constante sur les droites $x + t = \text{cste}$, et l'on paramètre chacune par la valeur qu'elle prend en $x = D$. $\square$

Intuition : le dictionnaire

Langage EDP	Langage retard
état $w(\cdot, t) \in L^\infty([0, D])$	historique $\eta_t = \eta(t + \cdot)$ sur $[-D, 0]$
$\ w(\cdot, t)\ _\infty$	$\sup_{-D \leq \theta \leq 0} \eta(t + \theta) $
condition au bord $w(D, t) = d(t)$	équation $\eta(t) = d(t)$
temps de traversée D	retard D

Les deux points de vue sont *rigoureusement équivalents* ; on utilise l'EDP pour les estimations ISS (lemme A.11) et le point de vue retard pour les estimations de croissance (lemme A.19).

A.4.2 L'équation intégrale à retard associée

Reprenons le système cible (A.7) avec la condition au bord (A.10), en boucle ouverte ($U \equiv 0$) :

$$w(D, t) = - \int_0^D k(D, x) \left[w(x, t) + \int_0^x \ell(x, y) w(y, t) dy \right] dx.$$

En utilisant (A.23), $w(x, t) = \eta(t + x - D)$, et en posant $s = t + x - D$:

$$\eta(t) = - \int_{t-D}^t k(D, s - t + D) \left[\eta(s) + \int_{t-D}^s \ell(s - t + D, r - t + D) \eta(r) dr \right] ds. \quad (\text{A.24})$$

C'est une *équation intégrale à retard* (IDE) : $\eta(t)$ est déterminé par son passé sur une fenêtre de longueur D .

Lemme A.19 (inégalité de croissance). *Posons*

$$\bar{M}_1 := \frac{M_3}{D M_2}. \quad (\text{A.25})$$

Alors, pour $t \geq D$,

$$|\eta(t)| \leq \bar{M}_1 \int_{t-D}^t |\eta(s)| ds \quad \text{et} \quad \|w(\cdot, t)\|_\infty \leq e^{\bar{M}_1 t} \|w(\cdot, 0)\|_\infty \cdot C \quad (\text{A.26})$$

pour une constante C ne dépendant que de D et $\bar{M}_1$.

Esquisse. Majorer (A.24) : le noyau $k(D, \cdot)$ est majoré par M_3/D (par définition (A.16)), et le terme entre crochets est majoré par $M_2^{-1} \sup_{[t-D, t]} |\eta|$ grâce à l'équivalence de normes (proposition A.8), d'où la première inégalité. La seconde s'obtient en itérant sur les fenêtres $[kD, (k+1)D]$, ou par un argument de type Grönwall pour les équations à retard. $\square$

Remarque A.20 (interprétation de $\bar{M}_1$). $\bar{M}_1$ est le *taux de croissance en boucle ouverte* du système cible. C'est l'exact analogue de $\|A\|$ dans (2.21). Il apparaîtra au dénominateur de la borne sur t_1^* (lemme 3.7) : plus le système est instable, plus la capture est rapide à *déclencher* mais plus μ doit croître vite.

Annexe B

Pour aller plus loin

Cette annexe contient ce qui prolonge le cours sans en faire partie : les extensions démontrées ailleurs, ce qui casse en pratique, ce qui reste ouvert, et (pour finir) la borne fondamentale en nombre de bits, qui est le contrepoint théorique de tout le reste.

B.1 Quantification de la sortie : observateurs

B.1.1 Le problème

Jusqu'ici, l'état complet était mesuré (même mal). Supposons maintenant que seule une **sortie** soit disponible, et quantifiée. Pour l'EDP de transport de la section A.1, la sortie naturelle est la valeur au bord non commandé :

$$y(t) = u(0, t), \quad \text{mesure disponible} = q_\mu(y(t)). \quad (\text{B.1})$$

Intuition : pourquoi c'est bien plus dur

Avec l'état complet, l'événement de capture est une *quantité mesurable* : on regarde $\|q_\mu(u)\|$ et on décide. Avec la seule sortie, on ne peut plus tester directement $\|u\|_\infty \leq \vartheta M\mu$: il faut d'abord *reconstruire* u , or l'observateur a lui-même besoin de mesures non saturées pour converger. C'est un problème de **poule et d'œuf** :

pour bien observer il faut ne pas saturer, et pour savoir si l'on sature il faut bien observer.

B.1.2 L'observateur backstepping

L'observateur frontière et sa transformation duale sont ceux de [15, ch. 5]. Pour le cas hyperbolique 2×2 avec sortie quantifiée, traité complètement, voir [31].

Pour le système (A.3), l'observateur prend la forme

$$\hat{u}_t(x, t) = \hat{u}_x(x, t) + g(x) \hat{u}(0, t) + p(x) [q_\mu(y(t)) - \hat{u}(0, t)], \quad (\text{B.2})$$

$$\hat{u}(D, t) = U(t), \quad (\text{B.3})$$

où le gain d'injection $p(\cdot)$ est obtenu par une transformation de backstepping *duale* (Krstic-Smyshlyaev [15]). L'erreur $\tilde{u} = u - \hat{u}$ obéit à

$$\tilde{u}_t = \tilde{u}_x + [g(x) - p(x)] \tilde{u}(0, t) - p(x) \underbrace{[q_\mu(y) - y]}_{\text{erreur de quantification}}, \quad \tilde{u}(D, t) = 0. \quad (\text{B.4})$$

Proposition B.1 (la structure est la bonne). *Si p est choisi tel que le système d'erreur nominal ($q_\mu(y) = y$) soit exponentiellement stable de taux σ_e avec constante M_e , alors, tant que $\|u\|_\infty \leq M\mu$,*

$$\|\tilde{u}(\cdot, t)\|_\infty \leq M_e e^{-\sigma_e(t-t_0)} \|\tilde{u}(\cdot, t_0)\|_\infty + \frac{M_e \|p\|_\infty}{\sigma_e} \Delta\mu. \quad (\text{B.5})$$

Pour le transport, $\tilde{u}(D, t) = 0$ donne mieux : l'erreur nominale est *nulle en temps fini* D (deadbeat), donc M_e peut être pris égal à 1 et σ_e arbitrairement grand, au prix d'un $\|p\|_\infty$ grand.

B.1.3 La stratégie à trois phases

L'architecture qui fonctionne ajoute une phase intermédiaire :

	phase	but
1	zoom-out	Augmenter μ jusqu'à ce que la <i>sortie</i> ne soit plus saturée. Commande nulle.
2	apprentissage	μ figé pendant une durée $\geq D$: l'observateur converge (deadbeat) et $\hat{u}$ devient une estimation fiable, avec erreur $O(\Delta\mu)$.
3	zoom-in	Commande $U = \int k(D, x) \hat{u} dx$ et décroissance de μ comme à la section 3.2.2, en propageant conjointement $(\hat{u}, \tilde{u})$.

Théorème B.2 (sortie quantifiée, énoncé informel). *Sous une condition en résolution de la forme*

$$\frac{\Delta}{M} < \frac{M_2}{(1 + M_0)(1 + M'_e) \max\{\dots\}},$$

où M'_e mesure l'amplification de l'observateur, la stratégie à trois phases rend l'origine globalement asymptotiquement stable pour le système en boucle fermée $(u, \tilde{u})$.

Attention : pourquoi je ne démontre pas ce théorème ici

Trois raisons, toutes honnêtes :

1. la preuve nécessite un petit gain 3×3 (état, erreur d'observation, quantification) dont l'écriture complète prendrait une vingtaine de pages sans idée nouvelle ;
2. la « détection de capture à partir de la sortie » demande une hypothèse d'*observabilité quantitative* (grammien minoré) qui, pour le transport, est vraie mais dont la version générale est technique ;
3. c'est précisément un **sujet de recherche ouvert** dans le cas des EDP générales. Le cas des systèmes hyperboliques 2×2 vient d'être traité dans [31], où la difficulté est levée par un observateur frontière couplé à une commande événementielle ; la question reste ouverte pour des classes plus larges.

Je préfère donner la structure et les obstacles plutôt qu'une preuve recopiée.

B.2 Systèmes hyperboliques 2×2 et commande événementielle

B.2.1 Pourquoi deux équations plutôt qu'une

L'EDP du chapitre 3 ne transporte que dans un sens. La plupart des applications réelles en transportent deux, en sens opposés :

$$u_t(t, x) + a(x) u_x(t, x) = c_1(x) v(t, x), \quad (\text{B.6})$$

$$v_t(t, x) - b(x) v_x(t, x) = c_2(x) u(t, x), \quad (\text{B.7})$$

$$u(t, 0) = \eta v(t, 1), \quad v(t, 1) = U(t), \quad (\text{B.8})$$

avec $a, b > 0$ et $|\eta| < 1$. Une onde de pression qui descend et sa réflexion qui remonte, un débit et une hauteur d'eau, une colonne de forage : ce sont tous des systèmes 2×2 [19].

Intuition : ce qui change vraiment

La difficulté n'est pas le passage de un à deux états. C'est que u et v se nourrissent mutuellement à travers c_1, c_2 et se réfléchissent en $x = 0$ à travers η : la boucle intérieure existe déjà, avant même qu'on ajoute la commande. Le backstepping devient matriciel, les constantes M_1, M_2, M_3 deviennent des normes de noyaux matriciels, et la condition de petit gain doit absorber la réflexion η en plus de la quantification.

B.2.2 Deux ressources, deux leviers

Avant d'entrer dans les résultats, il faut être clair sur ce que l'on cherche à économiser. Un canal de communication est caractérisé par deux quantités, et la littérature les attaque séparément.

	Quantification	Commande événementielle
Ce que l'on réduit	le nombre de <i>bits</i> par message	le nombre de <i>messages</i>
Paramètre réglable	μ (portée/résolution)	le seuil d'échantillonnage
Danger propre	saturation, cycle limite	phénomène de Zénon
Outil d'analyse	(P1) et (P2) + petit gain	minoration des intervalles entre deux mises à jour

Combiner les deux est la chose naturelle à faire, et c'est aussi là que le travail devient délicat : chacun des deux mécanismes engendre une perturbation, et il faut que la somme des deux reste absorbable par la marge de petit gain. Les deux travaux ci-dessous font exactement cela, dans les deux configurations possibles.

B.2.3 Entrée quantifiée et commande événementielle

Le problème. On considère (B.6) et (B.8) avec l'état complet $(u(\cdot, t), v(\cdot, t))$ disponible, mais une commande frontière U qui subit *simultanément* deux dégradations : elle n'est mise à jour qu'aux instants de déclenchement t_k , et la valeur transmise est quantifiée. C'est le cadre de Koudohode, Espitia, Humaloja et Bekiaris-Liberis [30].

Les trois ingrédients du design.

1. **Une loi de backstepping** pour le système 2×2 , qui donne le contrôleur nominal continu $U_{\text{nom}}(t)$, l'analogie matriciel de (3.3).
2. **Une loi d'échantillonnage** qui fait intervenir à la fois la norme courante de l'état et celle du dernier état échantillonné. Ce second terme est ce qui distingue le schéma des conditions de déclenchement naïves : c'est lui qui permet de minorer l'intervalle entre deux mises à jour.

3. **La stratégie de commutation à deux phases** sur μ , exactement celle de tout ce cours : une phase d'élargissement qui ramène l'état dans la portée du quantificateur *en temps fini*, suivie de réductions répétées qui font décroître l'erreur et amènent l'état à l'origine.

Le résultat. Stabilité exponentielle **globale** en norme sup de l'état de l'EDP. La preuve suit l'architecture habituelle : on établit une estimation ISS pour le système cible vis-à-vis des perturbations engendrées par la quantification *et* par l'échantillonnage, puis on ferme par un argument de petit gain. Le lecteur reconnaîtra la même charpente qu'à la section 3.2.

La contribution technique délicate. C'est le caractère bien posé du système hybride en boucle fermée, et en particulier l'**absence de phénomène de Zénon** : il faut montrer que les intervalles entre deux mises à jour sont minorés par une constante *strictement positive*, malgré la perturbation supplémentaire due à la quantification. Sans cela, le schéma demanderait une infinité de mises à jour en temps fini et ne serait pas implémentable. Ce point n'est pas une formalité : la quantification injecte en permanence une erreur d'amplitude $\Delta\mu$ qui tend à faire franchir le seuil d'échantillonnage, et c'est la décroissance de μ qui vient compenser cette tendance.

Code

Code MATLAB/Simulink de l'article : <https://github.com/Flo3221/QuantizedInput-ETC-2x2HyperbolicPDE>.

En pratique : un bénéfice inattendu : l'implémentation auto-événementielle

Une fois la minoration des intervalles établie, on en tire gratuitement une implémentation *auto-événementielle* (*self-triggered*) : au lieu de surveiller en continu la loi d'échantillonnage (ce qui suppose de mesurer l'état en permanence, donc de consommer du canal) le contrôleur *calcule à l'avance* la prochaine date de mise à jour. C'est opérationnellement très différent : le capteur peut dormir entre deux événements.




FIGURE B.1 : Profils espace-temps de u (haut) et v (bas) en boucle fermée sous commande événementielle à entrée quantifiée, avec $M = 2$, $\Delta = M/30$, $\mu_0 = 4$, $\Omega = 0,6$, $T = 1$. On retrouve la signature du schéma : une excursion initiale importante pendant la phase d'élargissement, puis une convergence vers zéro. Les deux composantes convergent ensemble, ce qui n'a rien d'évident : elles sont couplées par c_1, c_2 et par la réflexion η en $x = 0$.¹

B.2.4 Sortie quantifiée : observateur et résultat semi-global

Le problème. Cette fois, l'état complet n'est pas disponible : on ne dispose que d'une *mesure frontière*, et elle est quantifiée. C'est le cadre de [31]. Il faut donc reconstruire l'état, et l'erreur d'estimation va interagir avec l'erreur de quantification.

Le design. Deux éléments, comme précédemment, mais le premier change de nature :

1. une loi de commande **fondée sur un observateur**, déclenchée par événements, et qui n'utilise que les mesures quantifiées, c'est-à-dire que l'observateur lui-même est alimenté par $q_\mu(y)$ et non par y ;
2. la même stratégie de commutation sur μ .

Le résultat, et pourquoi il est semi-global. On obtient la stabilité exponentielle **semi-globale** en norme sup, et non globale. La différence tient à un point précis : on établit que l'état *reste* dans la portée du quantificateur *s'il y est à l'instant initial*, puis qu'il converge vers l'origine. Il n'y a donc pas de phase de capture « gratuite » comme dans le cas de l'état mesuré : il faut

1. *Source* : Figures empruntées à [30, Fig. 1], préprint [hal-05669800](https://hal.archives-ouvertes.fr/hal-05669800).

supposer que l'on démarre dans la portée, quitte à choisir μ_0 assez grand en fonction d'une borne connue sur la condition initiale.

Intuition : pourquoi la capture est perdue en sortie

C'est le même phénomène qu'à la section 2.5.2 en dimension finie, et c'est fondamental plutôt qu'anecdotique. En phase 1, le contrôleur utilise (P2) pour *déduire* de la mesure quantifiée que l'état est rentré dans la portée. Avec l'état complet, cette déduction porte directement sur ce qui compte. Avec une seule mesure frontière, elle ne porte que sur la sortie : on peut avoir une sortie petite et un état intérieur grand. Il faudrait donc, en plus, une estimation de l'écart entre les deux, et cette estimation demande un observateur, qui a lui-même besoin d'un régime transitoire pour converger. On tourne en rond, sauf si l'on s'autorise une hypothèse sur μ_0 .

L'architecture de la preuve. Elle repose sur deux briques.

1. Des estimations ISS pour l'**interconnexion système et observateur** vis-à-vis des perturbations engendrées par la quantification et par l'échantillonnage. C'est l'objet réellement nouveau : ce n'est plus le système seul que l'on doit rendre robuste, mais le couple.
2. L'établissement du fait que l'état reste dans la portée, puis converge, moyennant une conception appropriée de la loi de μ .

Comme dans le cas de l'entrée, le caractère bien posé du système hybride et l'absence de Zénon sont établis.




FIGURE B.2 : Densité des intervalles entre deux mises à jour, en échelle logarithmique, pour deux valeurs du facteur de contraction Ω . Un Ω petit, donc une convergence plus agressive, concentre les mises à jour sur des intervalles courts : on paie la vitesse en débit de communication. **L'absence de masse près de zéro est la traduction graphique de l'absence de Zénon :** c'est exactement ce que la minoration des intervalles garantit théoriquement.²

2. Source : Figure empruntée à [31, Fig. 6], préprint [hal-05570991](#).

Code

Code MATLAB/Simulink de l'article : <https://github.com/Flo3221/QuantizedOutput-ETC-2x2HyperbolicPDE>.

B.2.5 Ce que ces deux travaux apprennent au praticien

En pratique : trois conclusions opérationnelles

1. **Quantification et déclenchement ne sont pas indépendants.** Ils attaquent la même ressource, le débit du canal, mais par deux leviers différents. La figure B.2 le montre de façon frappante : le réglage de Ω , qui appartient au monde de la quantification, déplace la distribution des instants d'échantillonnage. Dimensionner l'un sans l'autre conduit à sous-estimer le débit réellement consommé.
2. **Le vrai indicateur de dimensionnement est le produit « bits par message $\times$ messages par seconde ».** Les deux articles incluent une comparaison de performance avec un quantificateur à portée et erreur *fixes* : c'est ce genre de comparaison qu'il faut refaire sur son propre système, parce que c'est elle qui dit si l'appareillage à deux phases vaut son coût en complexité.
3. **Mesurer tout l'état, si on le peut, change la nature du résultat**, pas seulement ses constantes : global d'un côté, semi-global de l'autre. En pratique, cela veut dire qu'avec une seule mesure frontière, il *faut* une borne a priori sur la condition initiale, et qu'elle doit être documentée comme une hypothèse de conception et non cachée dans un choix de μ_0 .

Remarque B.3 (où lire la suite). Les deux préprints sont librement accessibles sur HAL, avec les énoncés complets, les constantes et les preuves : [30] ([hal-05669800](https://hal.archives-ouvertes.fr/hal-05669800)) et [31] ([hal-05570991](https://hal.archives-ouvertes.fr/hal-05570991)). On a délibérément choisi ici de décrire l'architecture complète (problème, ingrédients, résultat, difficulté technique, portée pratique) plutôt que de recopier les constantes : elles n'ont d'intérêt qu'avec les notations de ces articles, qui diffèrent des nôtres sur plusieurs points.

B.3 Robustesse : ce qui casse en vrai

B.3.1 Le zoom infini n'existe pas

Tous les théorèmes de ce cours concluent $\mu(t) \rightarrow 0$. C'est mathématiquement propre et **physiquement impossible** : $\mu \rightarrow 0$ signifie que le pas du quantificateur $\Delta\mu$ tend vers 0, donc que le capteur devient infiniment précis.

Attention : le scénario catastrophe

Ajoutons un bruit de mesure borné $|n(t)| \leq \bar{n}$. Le contrôleur voit $q_\mu(x+n)$. Quand $\Delta\mu \ll \bar{n}$, la quantification ne « voit » plus que le bruit : la mesure devient une variable quasi aléatoire de la taille de $\bar{n}/\mu$ en unités quantificateur, la commande $U \sim K\mu q(\cdot)$ devient erratique, et **le système diverge**. C'est un phénomène observé en pratique et souvent mal diagnostiqué (« le régulateur devient instable au bout de quelques minutes »).

Recette : le correctif standard : plancher de zoom

On remplace la loi (3.13) par

$$\mu(t) = \max \{ \mu_{\min}, \Omega^{i-1} \mu_{\star} \}, \quad \mu_{\min} := \frac{c \bar{n}}{\Delta} \quad (c \geq 2), \quad (\text{B.9})$$

c'est-à-dire : *on cesse de zoomer quand le pas atteint quelques fois le bruit*. On perd la convergence asymptotique et on obtient une **stabilité pratique** :

$$\limsup_{t \rightarrow \infty} \|(X, u)(t)\| \leq \frac{(1 + M_0)}{M_2} (M_3 \Delta + \text{const}) \mu_{\min} = O(\bar{n}). \quad (\text{B.10})$$

Le rayon ultime est *proportionnel au bruit*, pas à Δ : c'est le meilleur résultat possible.

Intuition : la vraie hiérarchie des erreurs

En boucle fermée numérique il y a au moins quatre sources d'erreur :

$$\underbrace{\Delta \mu}_{\text{quantification}}, \quad \underbrace{\bar{n}}_{\text{bruit capteur}}, \quad \underbrace{O(h)}_{\text{échantillonnage}}, \quad \underbrace{|\hat{D} - D|}_{\text{modèle}}.$$

Le zoom ne combat *que* la première. Le régler pour descendre bien en dessous des trois autres est du gaspillage et, on vient de le voir, dangereux. **Régler $\mu_{\min}$ au niveau du plus grand des trois autres termes.**

B.3.2 Échantillonnage : quantifier n'est pas discrétiser

Les résultats de ce cours supposent la mesure disponible en *temps continu*. En pratique on échantillonne à la période h . Deux effets :

- **Retard supplémentaire** $\approx h/2$ (bloqueur d'ordre zéro). Dans le cadre de la section 3, il suffit de remplacer D par $D + h/2$ dans toutes les constantes, ce qui, on l'a vu, coûte des bits.
- **Perte de l'événement instantané** : l'événement (3.58) n'est testé qu'aux instants kh . Le lemme de capture reste valable (il est déjà énoncé sur une grille $j\tau$!), à condition de prendre τ multiple de h .

Proposition B.4 (condition combinée, forme heuristique). *En première approximation, la condition en bits devient*

$$N > \log_2 \frac{M_3(D + h/2)}{M_2(D + h/2)} + 3 \log_2 \left(1 + \frac{M_\sigma |B|}{\sigma} \right) + 2,75 + \log_2 \frac{1}{1 - e^{-\sigma h}},$$

le dernier terme traduisant la perte de contraction due au blocage.

B.3.3 Retard incertain

Le prédictor (3.33) utilise D ; si l'on implémente $\hat{D} \neq D$, le système cible acquiert un terme supplémentaire proportionnel à $|\hat{D} - D|$.

Attention : fragilité intrinsèque

Le *predictor feedback* est connu pour être robuste à une erreur *petite* sur D (résultat de Karafyllis-Krstic), mais la marge est d'autant plus faible que $|A|D$ est grand. Combiné à la

quantification, cela donne une règle empirique :

$$\frac{|\hat{D} - D|}{D} \lesssim \frac{1}{|A|D} \frac{\sigma}{M_\sigma} \quad \text{et} \quad \Delta\mu_{\min} \gtrsim |\hat{D} - D| |B| \|U\|_\infty.$$

Autrement dit : **l'incertitude sur le retard fixe un plancher de zoom**, exactement comme le bruit.

B.3.4 Pertes de paquets et canal non idéal

Si le canal perd des paquets, la mesure n'arrive pas : pendant la perte, le contrôleur doit fonctionner en boucle ouverte. Deux stratégies :

1. **Geler μ** et la commande. Fonctionne si la durée maximale de perte $\bar{\ell}$ vérifie $e^{|A|\bar{\ell}} < \frac{1}{\Omega}$ (on ne perd pas plus que ce qu'on gagne par période).
2. **Zoom-out préventif** : multiplier μ par $e^{2|A|\bar{\ell}}$ pendant la perte, comme en phase 1. Plus robuste, moins performant.

Ces questions relèvent de la théorie des *networked control systems* ; elles se marient bien avec le cadre de ce cours parce que la structure à deux phases est déjà hybride.

B.4 Ce qui est fait, ce qui reste à faire

B.4.1 L'état des lieux en une page

Avant de lister des problèmes ouverts, il faut savoir ce qui est déjà démontré. Le tableau ci-dessous résume la situation pour la ligne « quantificateur dynamique à commutation » suivie dans ce cours.

classe de systèmes	quantification	résultat et référence
Linéaire, dimension finie	état, sortie, entrée	stabilité asymptotique globale [4, 6]
EDP hyperbolique du premier ordre, un état	mesures et entrée	stabilité asymptotique globale en norme sup [24]
Linéaire avec retard d'entrée	état et entrée	stabilité asymptotique globale par prédicteur commuté [26]
Non linéaire globalement lipschitzien et EDP de réaction-diffusion, avec retard	état et entrée	stabilité asymptotique globale [28]
Non linéaire sans hypothèse de Lipschitz globale, avec retard	état et entrée	stabilité semi-globale [29]
Hyperbolique 2×2 , commande événementielle	entrée	stabilité exponentielle globale, absence de Zénon [30]
Hyperbolique 2×2 , retour de sortie par observateur	sortie	stabilité exponentielle semi-globale [31]

Deux enseignements. D'abord, la méthode est robuste : à chaque fois, le même triptyque backstepping, stabilité entrée-état, petit gain a suffi, au prix d'un travail technique croissant sur les constantes. Ensuite, les questions qui résistent ne sont pas celles auxquelles on pense d'abord ; ce ne sont pas des extensions de classe de systèmes, ce sont des questions de fondement.

B.4.2 Problème 1 : le caractère bien posé sous quantification exacte

Le problème le plus important de cette liste

Question. Tous les résultats du tableau ci-dessus supposent le quantificateur *localement lipschitzien* (section 1.7.5). Que devient le problème avec un escalier exact, c'est-à-dire discontinu ?

Pourquoi c'est délicat. Sous quantification de l'état et avec une loi de backstepping, la commande frontière $U = \int_0^D k(D, x) q_\mu(u(x, t)) dx$ dépend de l'état de façon discontinue. Le système en boucle fermée devient une équation d'évolution à second membre discontinu *en dimension infinie* : l'existence et l'unicité des solutions ne découlent d'aucun théorème standard. La notion même de solution est à choisir, et le choix n'est pas neutre : solutions de Carathéodory, de Filippov, de Krasovskii donnent des ensembles de solutions différents, et rien ne garantit que les estimations de stabilité démontrées pour le quantificateur régularisé passent à la limite.

Ce dont on dispose. En dimension finie, Ceragioli et De Persis [9] montrent que les solutions de Krasovskii sont la bonne notion pour les retours quantifiés, et Ferrante, Gouaisbaut et Tarbouriech [14] en tirent des conditions vérifiables par programmation semi-définie. Le formalisme hybride de Goebel, Sanfelice et Teel [35] fournit par ailleurs un cadre où la commutation de μ est naturellement modélisée.

Piste. Commencer par le transport pur avec quantification de l'entrée seule. Là, la discontinuité n'affecte qu'une donnée au bord scalaire, et la solution par caractéristiques reste définie tant que $t \mapsto U(t)$ est mesurable bornée. Le vrai obstacle apparaît ensuite, avec la quantification de l'état, quand $U(t)$ dépend de $u(\cdot, t)$ tout entier. Un résultat, même partiel, sur cette classe serait une contribution nette.

B.4.3 Problème 2 : le débit minimal pour une EDP

Combien de bits faut-il vraiment ?

Question. Existe-t-il un analogue du théorème du débit minimal (section B.6) pour les EDP considérées ici ?

Ce qui est connu. Pour une équation différentielle ordinaire, $R_{\min} = \frac{1}{\ln 2} \sum_i \operatorname{Re} \lambda_i^+$ [7, 10]. Pour un transport avec terme non local, le spectre en boucle ouverte peut compter une infinité de valeurs propres instables, mais leurs parties réelles sont bornées et s'accumulent.

Ce qui bloque. La somme $\sum \operatorname{Re} \lambda_i^+$ peut diverger alors que le système est stabilisable par une seule commande scalaire au bord. La quantité pertinente n'est donc pas cette somme, mais vraisemblablement une notion d'entropie du semi-groupe.

Piste. Le cas test naturel est $u_t = u_x + g u(0, t)$ avec g grand : on sait le stabiliser (section 3) et on connaît explicitement son spectre par l'équation caractéristique de l'exercice A.1. Comparer le débit consommé par le schéma commuté à une borne inférieure d'entropie sur cet exemple serait déjà un résultat.

B.4.4 Problème 3 : réduire le conservatisme

Dix bits d'écart entre la théorie et la pratique

La section 3.3.5 montre un écart d'une dizaine de bits entre la condition suffisante démontrée et le seuil observé en simulation. Cet écart vient presque entièrement du facteur $(1 + M_0)^2(1 + \lambda)$, donc de la fermeture par petit gain en norme sup.

Trois pistes.

1. Remplacer les normes sup par des fonctionnelles de Lyapunov-Krasovskii pondérées, du type $V = |X|_P^2 + b \int_0^D e^{cx} w(x)^2 dx$, et calculer les constantes par inégalités matricielles linéaires. C'est la méthode employée par Tanwani, Prieur et Tarbouriech [22] pour obtenir des bornes ultimes explicites.
2. Traiter l'erreur de quantification comme une non-linéarité de secteur plutôt que comme une perturbation additive, dans l'esprit de [8, 13].
3. Modéliser l'erreur comme aléatoire et uniforme, et démontrer un résultat en moyenne quadratique. La quantification est, depuis [37], très bien comprise sous cet angle en traitement du signal ; elle l'est beaucoup moins en boucle fermée.

B.4.5 Problème 4 : au-delà du transport linéaire

Lois de conservation quasi-linéaires

Pour $u_t + f(u)_x = 0$ (trafic routier, Saint-Venant), la vitesse de propagation dépend de l'état : le temps de purge D n'est plus constant et des chocs peuvent apparaître. Or toute la stratégie de zoom repose sur une estimation de stabilité entrée-état dont le gain *ne dépend pas* de l'état, ce qui tombe.

Piste. Se restreindre aux solutions à variation totale petite et chercher une estimation entrée-état en norme BV pour le transport avec condition au bord quantifiée. Question préalable, autonome et bien posée : un tel lemme existe-t-il ?

Retard incertain ou variable

Le prédicteur (3.33) utilise la valeur exacte de D . Sa robustesse à une erreur d'estimation est connue sans quantification, mais la marge se dégrade lorsque $|A|D$ croît (§B.3.3).

Question. Quelle est la relation entre l'erreur admissible $|\hat{D} - D|$ et le nombre de bits ? On s'attend à ce que l'incertitude sur le retard impose un *plancher de zoom*, exactement comme le bruit, mais personne ne l'a quantifié. Le cas du retard variable $D(t)$ avec $\dot{D} < 1$ est ouvert dans le même sens.

B.4.6 Problème 5 : identification et quantification

Un conflit structurel

Coupler le zoom à un estimateur de paramètres se heurte à une difficulté qui n'est pas technique mais structurelle : l'identification a besoin d'*excitation*, alors que le schéma fait converger l'état vers zéro et, simultanément, fait tendre $\Delta\mu$ vers zéro. À la fin, il n'y a plus ni signal ni résolution. Les deux objectifs sont antagonistes.

Piste. Renoncer à $\mu \rightarrow 0$ et viser une stabilité pratique avec un plancher $\mu_{\min}$ choisi pour préserver un niveau d'excitation minimal. C'est le lien naturel avec le §B.3.1, qui impose déjà un plancher pour d'autres raisons.

B.4.7 Problème 6 : valider expérimentalement

Le maillon manquant

À ma connaissance, le seul travail où un schéma quantifié avec retard est mis en œuvre sur un dispositif physique est celui de Schlanbusch, Aamo et Zhou [25] sur un banc hélicoptère. Aucun schéma à zoom commuté pour EDP n'a été validé expérimentalement.

Ce qu'il faudrait. Un banc où la quantification est réellement la contrainte dominante : liaison bas débit, capteur 8 bits, actionneur sur bus de terrain. Les questions qui apparaîtraient alors sont celles du section B.3 plutôt que celles des théorèmes : réglage de $\mu_{\min}$, pertes de paquets, dérive de l'échelle. C'est un excellent sujet pour qui a accès à une plateforme.

En pratique : comment choisir

Si l'on veut un résultat publiable en un an, les problèmes 3 et 4 sont les plus accessibles : ils demandent du travail technique sur des objets bien définis. Le problème 1 est le plus profond et le plus risqué. Le problème 6 est celui qui aurait le plus d'impact hors de la communauté.

B.5 Programme de travail

B.5.1 Lectures graduées

niveau	référence	ce qu'on y trouve
0	Khalil [34], ch. 4 et 4.9	Lyapunov, stabilité entrée-état, systèmes en cascade. Le prérequis unique.
1	Brockett & Liberzon [4]	La stratégie à deux phases en dimension finie, en douze pages. À lire en premier.
2	Liberzon [6]	La généralisation non linéaire, avec les trois configurations état, sortie, entrée.
3	Elia & Mitter [5], Fu & Xie [8]	L'autre école. Utile pour comprendre ce que l'on gagne et ce que l'on perd avec le zoom.
4	Krstic & Smyshlyaev [15]	Backstepping frontière, transformation de Volterra, équations du noyau.
5	Krstic [17]	Compensation de retard par prédicteur, vue comme un backstepping sur une cascade EDO-EDP.
6	Karafyllis & Krstic [21], ch. 1 à 3 et 9 à 10	Stabilité entrée-état pour les EDP, normes pondérées, petit gain. Technique mais incontournable.
7	Bekiaris-Liberis [24]	Le cas EDP de la section 3, dans sa forme originale.
8	Koudohode & Bekiaris-Liberis [26]	Le cas retard de la section 3.
9	Nair <i>et al.</i> [10]	Débit minimal et entropie. L'autre moitié du sujet.

En pratique : un ordre de lecture réaliste

Un étudiant de master qui commence peut viser : niveaux 0 et 1 en deux semaines, niveau 2 en une semaine, niveaux 4 et 5 en un mois, puis attaquer directement [24] avec ce cours en parallèle. Le niveau 6 se lit ensuite par nécessité, chapitre par chapitre, quand une estimation résiste.

B.5.2 Six mini-projets

- P1. (Une semaine)** Reprendre le code de la section 2.4 pour un système de dimension trois et tracer le nombre de bits minimal observé en fonction du placement de pôles. Comparer à la prédiction (B.13). On devrait retrouver la croissance en cube du gain de boucle.
- P2. (Une semaine)** Implémenter la variante logarithmique et vérifier expérimentalement la densité de quantification critique prédite par Elia et Mitter [5].
- P3. (Deux semaines)** Ajouter un bruit de mesure au code de la section 3.3.5, déterminer empiriquement le $\mu_{\min}$ optimal et comparer à (B.9). C'est le projet le plus utile pour un ingénieur.
- P4. (Un mois)** Écrire les constantes M_1, M_2, M_3 pour l'équation de réaction-diffusion, dont le noyau de backstepping s'exprime en fonctions de Bessel, et obtenir une condition en bits. Comparer à [28], qui traite le cas avec retard.
- P5. (Difficile)** Reformuler la section 3.2.2 avec une fonctionnelle $V = \int_0^D e^{cx} w^2 dx$ au lieu des normes sup et mesurer le gain en nombre de bits. C'est le problème 3 du section B.4, sur un cas particulier.
- P6. (Difficile)** Traiter le problème 1 du section B.4 dans le cas le plus simple possible : transport pur, quantification de l'entrée seule, escalier exact. Établir l'existence de solutions au sens de Krasovskii et vérifier que l'estimation de stabilité passe à la limite.

B.5.3 Comment lire un article de ce domaine**Recette : méthode en cinq passes**

1. **Le système et l'espace d'état.** Quelle norme ? L^2 ou L^∞ ? Cela détermine tout le reste.
2. **La transformation.** Chercher la formule de type Volterra et *son inverse* : les constantes M_1, M_2 sont là.
3. **Le système cible.** S'il n'est pas écrit explicitement, méfiance.
4. **Où entre la quantification ?** Presque toujours dans la condition au bord du système cible. Chercher le « $d(t)$ ».
5. **La condition en bits.** Vérifier son **homogénéité** : elle doit relier Δ/M (sans dimension) à des constantes sans dimension. Une inégalité qui comparerait Δ à M^2 ne peut pas être correcte : le test coûte trente secondes et évite bien des heures.

B.6 Combien de bits faut-il ? Le théorème du débit minimal**Anatomie de la condition en bits**

Avant la borne fondamentale, il est utile de disposer d'une lecture *approchée* mais parlante de ce que les conditions de ce cours exigent réellement. Toutes, en dimension finie comme en

dimension infinie, ont la même forme : M/Δ doit dépasser un produit de gains. En passant au logarithme et en écrivant $N = \log_2(M/\Delta)$, on obtient l'*anatomie* suivante :

$$N \gtrsim \underbrace{\log_2 \frac{M_3}{M_2}}_{\text{coût du contrôleur}} + \underbrace{\log_2 [(1+\lambda)(1+M_0)^2]}_{\text{coût de la fermeture petit gain}} + \underbrace{O(1)}_{\text{marges}}, \quad (\text{B.11})$$

où M_2, M_3 sont les constantes d'équivalence de normes et de gain du contrôleur nominal (§A.2.7), λ le paramètre de norme pondérée et M_0 la constante d'*overshoot* issue du petit gain.

Proposition B.5 (réglage optimal de λ). *Posons $a := 1 + g_B$ avec $g_B = \frac{M_\sigma |B|}{\sigma - \delta}$. Si $a \geq M_\sigma$, alors $1 + M_0 = \frac{a(1+\lambda)}{1+\lambda-a}$ et la quantité $(1+\lambda)(1+M_0)^2$ à minimiser vaut $\frac{a^2(1+\lambda)^3}{(1+\lambda-a)^2}$; son minimum est atteint en*

$$1 + \lambda^* = 3a, \quad \text{et vaut} \quad (1+\lambda)(1+M_0)^2|_{\lambda^*} = \frac{27}{4} a^3. \quad (\text{B.12})$$

Démonstration. Avec $s = 1 + \lambda$, $\varphi = a/s$ et $1 + M_0 = \max\{M_\sigma, a\}/(1 - a/s) = as/(s - a)$. Donc $f(s) = a^2 s^3 / (s - a)^2$ et $f'(s) = a^2 s^2 (s - 3a) / (s - a)^3$, qui s'annule en $s = 3a$ et y change de signe. $\square$

Intuition : la conclusion pratique la plus importante du cours

En reportant (B.12) dans (B.11) :

$$N \gtrsim \log_2 \frac{M_3}{M_2} + 3 \log_2 \left(1 + \frac{M_\sigma |B|}{\sigma} \right) + 2,75. \quad (\text{B.13})$$

Le terme dominant est le **cube** du gain de boucle $1 + M_\sigma |B| / \sigma$. Autrement dit : *le nombre de bits est gouverné par le conditionnement de la boucle nominale, bien plus que par la précision que l'on souhaite*. C'est ce qui explique le saut, constaté à la section 3.3, entre les six bits qui suffisent en dimension finie et les dix-neuf bits que réclame la version certifiée avec retard.

Attention : statut de (B.13)

Cette formule est une *lecture* des conditions suffisantes de ce cours, pas un théorème sur le nombre de bits nécessaire. Elle dit combien de bits *notre* schéma consomme, avec *nos* majorations. La borne fondamentale, qui dit combien de bits sont nécessaires quelle que soit la méthode, est l'objet de ce qui suit, et elle est bien plus basse.

Ce chapitre, culturel mais fondamental, répond à la question que tout ingénieur pose : *combien de bits par seconde faut-il pour stabiliser ?*

B.6.1 L'intuition du volume

Le résultat de cette section est dû à Tatikonda et Mitter [7] et à Nair, Fagnani, Zampieri et Evans [10], où l'on trouvera les énoncés précis et les hypothèses exactes. On se contente ici d'en donner l'intuition et la conséquence pratique.

Considérons $\dot{x} = Ax$ sans commande. Le flot transforme un ensemble d'incertitude de volume $\text{Vol}(0)$ en un ensemble de volume

$$\text{Vol}(t) = e^{\text{tr}(A)t} \text{Vol}(0).$$

Si l'on ne regarde que les directions instables, l'incertitude *croît* au taux $\sum_{i: \text{Re} \lambda_i > 0} \text{Re} \lambda_i$.

Chaque bit reçu *divise par deux* l'incertitude dans une direction : avec R bits par seconde, on *réduit* le logarithme du volume au taux $R \ln 2$. La stabilisation exige donc que la réduction batte la croissance :

Théorème B.6 (théorème du débit minimal, temps continu, forme informelle). *Pour $\dot{x} = Ax + Bu$ avec (A, B) stabilisable et un canal de débit R bits/seconde entre le capteur et le contrôleur, la stabilisation asymptotique est possible si*

$$R > R_{\min} := \frac{1}{\ln 2} \sum_{i: \operatorname{Re} \lambda_i(A) > 0} \operatorname{Re} \lambda_i(A) \quad (\text{bits/s}),$$

et impossible si $R < R_{\min}$.

Voir [10, 7]. Ce résultat est l'analogie, en commande, du théorème de codage de Shannon : il sépare le possible de l'impossible par une inégalité sur un débit.

B.6.2 Le cas bruité, et ce que change le codage

Le théorème énoncé ci-dessus suppose un système sans perturbation. Nair et Evans [11] traitent le cas stochastique, avec bruit de processus et bruit d'observation, et obtiennent, pour la stabilité en moyenne quadratique, la même borne infime : le débit critique reste $\frac{1}{\ln 2} \sum_i \operatorname{Re} \lambda_i^+$, sous des hypothèses très faibles sur les lois de probabilité. C'est un résultat remarquable : le bruit dégrade la précision atteignable, mais ne change pas le débit minimal.

Intuition : quantifier l'innovation plutôt que l'état

Une idée venue du traitement du signal permet souvent de s'approcher de la borne sans codeur sophistiqué : au lieu de transmettre l'état, on transmet l'écart entre l'état et sa prédiction. Cet écart est plus petit et moins corrélé, donc plus facile à quantifier avec une portée réduite. C'est le principe de la modulation delta et des normes ADPCM en téléphonie. Huang, Amini et Bitmead [12] analysent précisément cette architecture en boucle fermée et montrent que la simplicité apparente cache une difficulté : le récepteur doit reconstruire la densité jointe de l'état de la machine et de celui du prédicteur, et une condition de stabilité de la machine réapparaît. Le codage prédictif n'est donc pas gratuit, ce qui justifie *a posteriori* l'approche par zoom suivie ici, qui n'exige aucune reconstruction probabiliste.

B.6.3 Ce que consomme notre schéma

Rendons la stratégie de la section 2.3 échantillonnée : on transmet la mesure quantifiée toutes les T_s secondes, sur $N = \log_2(M/\Delta)$ bits par composante, soit un débit

$$R_{\text{schéma}} = \frac{n \log_2(M/\Delta)}{T_s} \text{ bits/s.}$$

En pratique : ordre de grandeur

Pour l'exemple du §2.4 ($n = 2$, $M/\Delta = 48$, $T_s = 10$ ms) : $R_{\text{schéma}} \approx 2 \times 5,6 / 0,01 = 1120$ bits/s. Le minimum théorique vaut $R_{\min} = \sqrt{2} / \ln 2 \approx 2,0$ bits/s. On est donc à *trois ordres de grandeur* du minimum !

Intuition : pourquoi un tel écart, et pourquoi ce n'est pas grave

Les schémas qui atteignent $R_{\min}$ sont des schémas de *codage* très fins : ils exploitent la connaissance exacte du modèle pour propager un « ensemble d'incertitude » et n'encodent que l'*innovation*. Ils sont fragiles : une erreur de modèle, une perte de paquet, et l'ensemble d'incertitude devient faux. Le schéma à zoom, lui, est :

- **robuste** : il ne suppose rien sur la façon dont l'état est entré dans la portée ;
- **modulaire** : il se greffe sur n'importe quelle loi nominale *ISS*, y compris en dimension

infinie, ce qu'aucun schéma de codage optimal ne sait faire aujourd'hui ;

- **implémentable** : un ADC standard suffit.

Le lecteur intéressé par le compromis « optimalité informationnelle contre robustesse » consultera [10].

Exercice B.1. Calculer $R_{\min}$ pour un pendule inversé linéarisé de valeurs propres $\pm 3,1 \text{ s}^{-1}$. Combien de bits par seconde au minimum ? Comparer à une liaison série à 9600 bauds.

Annexe C

Rappels d'analyse

C.1 Inégalité de Grönwall

Lemme C.1 (forme intégrale). Si $v(t) \leq c + \int_{t_0}^t a(s)v(s) ds$ avec $a \geq 0$, alors $v(t) \leq c e^{\int_{t_0}^t a}$.

Lemme C.2 (forme différentielle avec terme source). Si $\dot{v} \leq -\alpha v + b(t)$ alors $v(t) \leq e^{-\alpha(t-t_0)}v(t_0) + \int_{t_0}^t e^{-\alpha(t-s)}b(s) ds \leq e^{-\alpha(t-t_0)}v(t_0) + \frac{\sup b}{\alpha}$.

C.2 Normes et conditionnement

Pour $P = P^\top \succ 0$: $\lambda_{\min}(P) |x|^2 \leq x^\top P x \leq \lambda_{\max}(P) |x|^2$, et $\kappa_P = \sqrt{\lambda_{\max}(P)/\lambda_{\min}(P)}$ est le facteur d'excentricité des ellipsoïdes $\{x^\top P x = c\}$. C'est *lui*, et non $\lambda_{\min}$ ou $\lambda_{\max}$ séparément, qui apparaît dans les conditions en bits : la quantification est isotrope, la fonction de Lyapunov ne l'est pas.

C.3 Semi-groupes et estimation exponentielle

Si A_c est Hurwitz, il existe $M_\sigma \geq 1$ et $\sigma > 0$ avec $\|e^{A_c t}\| \leq M_\sigma e^{-\sigma t}$. Un choix constructif : résoudre $A_c^\top P + P A_c = -Q$ et prendre

$$\sigma = \frac{\lambda_{\min}(Q)}{2\lambda_{\max}(P)}, \quad M_\sigma = \kappa_P.$$

Attention : M_σ et σ ne s'optimisent pas indépendamment. Le rapport M_σ/σ , qui est la quantité réellement pertinente ici d'après (B.13), possède un minimum, souvent atteint pour des pôles modérés.

C.4 Opérateurs de Volterra

Un opérateur $(\mathcal{K}f)(x) = \int_0^x k(x,y)f(y) dy$ avec k continu est *quasi-nilpotent* : $\|\mathcal{K}^n\| \leq \frac{(\|k\|_\infty^D)^n}{n!}$. Donc $I - \mathcal{K}$ est inversible et $(I - \mathcal{K})^{-1} = I + \sum_{n \geq 1} \mathcal{K}^n$, avec $\|(I - \mathcal{K})^{-1}\| \leq e^{\|k\|_\infty^D}$. C'est ce qui garantit l'existence de la transformation inverse en backstepping, *sans* calcul explicite.

C.5 ISS : définitions

$\dot{z} = f(z, d)$ est ISS s'il existe $\beta \in \mathcal{KL}$ et $\gamma \in \mathcal{K}_\infty$ telles que $|z(t)| \leq \beta(|z_0|, t) + \gamma(\|d\|_{[0,t]})$. Pour les systèmes linéaires, $\beta(r, t) = M_\sigma e^{-\sigma t} r$ et γ est linéaire : $\gamma(r) = \frac{M_\sigma \|B\|}{\sigma} r$. Le *gain ISS* est la pente de γ ; c'est cette pente qui entre dans les théorèmes de petit gain.

C.6 Normes pondérées : le seul truc à retenir

Poser $\|z\|_{[t_0, t]} := \sup_{s \in [t_0, t]} e^{\delta(s-t_0)} |z(s)|$ transforme « décroissance exponentielle de taux δ » en « borne uniforme ». Toute estimation ISS écrite dans ces normes se relit automatiquement comme une estimation de décroissance :

$$\|z\|_{[t_0, t]} \leq C \iff |z(t)| \leq C e^{-\delta(t-t_0)}.$$

C'est l'unique astuce technique de la section [A.3](#), et elle vaut qu'on la retienne.

Annexe D

Corrigés des exercices

Les corrigés qui suivent sont rédigés avec tous les calculs intermédiaires. Un exercice n'a d'intérêt que si l'on peut vérifier chaque ligne ; on a donc préféré la longueur à l'élégance. Les valeurs numériques sont reproductibles par les scripts de l'annexe F.

Section 1.7

(1) (P2) pour le quantificateur uniforme. *Énoncé.* Vérifier que le quantificateur (1.4) satisfait (P2) avec la constante Δ , et que cette constante est optimale.

Vérification. Soit $|z| > M$. Par définition, $q(z) = M$ si $z > M$ et $q(z) = -M$ si $z < -M$. Dans les deux cas $|q(z)| = M$. Or $\Delta > 0$, donc

$$|q(z)| = M > M - \Delta,$$

ce qui est exactement (P2).

Optimalité. On montre qu'aucune constante $\Delta' < \Delta$ ne convient *uniformément* sur la classe des quantificateurs vérifiant (P1) avec le paramètre Δ . Construisons un contre-exemple. Soit $\tilde{q}$ identique à q partout sauf sur $(M, M + \delta)$ où l'on pose $\tilde{q}(z) = M - \Delta$, avec $\delta > 0$ petit. Alors :

- $\tilde{q}$ vérifie encore (P1), car pour $|z| \leq M$ rien n'a changé ;
- mais pour $z \in (M, M + \delta)$ on a $|\tilde{q}(z)| = M - \Delta$, qui n'est pas $> M - \Delta'$ dès que $\Delta' < \Delta$.

Donc la constante Δ ne peut pas être améliorée si l'on veut un énoncé valable pour tous les quantificateurs de la classe.

Pourquoi cela compte. (P2) est le seul outil qui permette au contrôleur de *détecter* la sortie de portée. Une constante trop optimiste rendrait l'événement de capture peu fiable, et la phase 1 s'arrêterait trop tôt.

(2) Quantificateur vectoriel. *Énoncé.* On quantifie $z \in \mathbb{R}^\ell$ composante par composante avec un pas h . Calculer Δ pour les normes $\|\cdot\|_\infty$, $\|\cdot\|_1$ et $\|\cdot\|_2$.

Calcul. Posons $e = q(z) - z$, de composantes $e_i = q(z_i) - z_i$. Le quantificateur scalaire donne $|e_i| \leq h/2$ pour chaque i . Alors :

$$\begin{aligned} \|e\|_\infty = \max_i |e_i| &\leq \frac{h}{2} &\Rightarrow \Delta_\infty &= \frac{h}{2}, \\ \|e\|_1 = \sum_{i=1}^\ell |e_i| &\leq \ell \frac{h}{2} &\Rightarrow \Delta_1 &= \frac{\ell h}{2}, \\ \|e\|_2 = \left(\sum_{i=1}^\ell e_i^2 \right)^{1/2} &\leq \left(\ell \frac{h^2}{4} \right)^{1/2} = \frac{h}{2} \sqrt{\ell} &\Rightarrow \Delta_2 &= \frac{h}{2} \sqrt{\ell}. \end{aligned}$$

Les trois bornes sont atteintes (prendre $e_i = h/2$ pour tout i), donc elles sont optimales.

Conséquence en bits. En norme euclidienne, la condition du cours porte sur M/Δ_2 . À portée M fixée,

$$\log_2 \frac{M}{\Delta_2} = \log_2 \frac{2M}{h\sqrt{\ell}} = \underbrace{\log_2 \frac{2M}{h}}_{\text{cas scalaire}} - \frac{1}{2} \log_2 \ell.$$

On perd donc $\frac{1}{2} \log_2 \ell$ bits en dimension ℓ : un demi-bit en dimension 2, un bit et demi en dimension 8. Un quantificateur *vectoriel* (réseau de points optimal plutôt que grille cubique) récupérerait une partie de cette perte, au prix d'une implémentation bien plus lourde ; voir [37, §III].

(3) Portée et résolution effectives. *Énoncé.* Avec $M = 6$, $h = 0,25$ et $\mu = 0,5$, calculer la portée, la résolution et le nombre de niveaux.

Calcul. Par définition $q_\mu(z) = \mu q(z/\mu)$, donc tout se dilate d'un facteur μ :

$$\text{portée} = M\mu = 6 \times 0,5 = 3, \quad \Delta = \frac{h}{2} = 0,125, \quad \text{résolution} = \Delta\mu = 0,125 \times 0,5 = 0,0625,$$

et le pas effectif vaut $h\mu = 0,25 \times 0,5 = 0,125$.

Nombre de niveaux. La zone non saturée est $[-M\mu, M\mu]$, de longueur $2M\mu = 3$; divisée par le pas effectif $h\mu = 0,125$, cela fait

$$\frac{2M\mu}{h\mu} = \frac{2M}{h} = \frac{12}{0,25} = 48$$

cellules, auxquelles s'ajoutent les deux niveaux de saturation, soit 50 symboles.

Le point de l'exercice. Le facteur μ se simplifie : le nombre de niveaux $2M/h$ **ne dépend pas de μ** . Zoomer ne coûte donc pas un seul bit de plus. C'est toute la raison d'être de la famille q_μ : on déplace la fenêtre sans changer le débit. En bits, $\log_2 48 \approx 5,58$, soit six bits en pratique.

(4*) Si $\Delta \geq M$. *Énoncé.* Que deviennent (P1) et (P2) si la résolution dépasse la portée ?

Analyse de (P2). L'énoncé devient $|z| > M \Rightarrow |q(z)| > M - \Delta$. Comme $\Delta \geq M$, on a $M - \Delta \leq 0$, et $|q(z)| \geq 0 > M - \Delta$ est vrai dès que $q(z) \neq 0$. L'implication est donc *vraie sans rien dire* : elle ne fournit aucune information exploitable, et l'événement de capture ne peut plus être testé.

Analyse de (P1). L'énoncé autorise $|q(z) - z| \leq \Delta$ avec $\Delta \geq M$, c'est-à-dire une erreur au moins aussi grande que toute la portée : la sortie peut être n'importe quel point de $[-M, M]$ sans violer (P1).

En bits. Avec $M/\Delta = 2^N$, la contrainte $\Delta \geq M$ s'écrit $2^N \leq 1$, soit $N \leq 0$. Aucune des conditions du cours n'est alors satisfaite ; par exemple (2.20) exige $M/\Delta > 2\kappa_P \geq 2$, donc $N \geq 1$ au strict minimum, et en pratique $N \geq 4$ à 6 en dimension finie, $N \geq 19$ dans le cas avec retard de la section 3.3.

Section 1.8

(5) Rayon ultime. *Énoncé.* Pour $\dot{x} = ax + u$ avec $a = 1$, $u = -kq_\mu(x)$, $k = 3$, $\Delta\mu = 0,1$, $M\mu = 5$: calculer le rayon de la bande ultime, puis déterminer à partir de quelle condition initiale la boucle diverge.

Régime non saturé. Tant que $|x| \leq M\mu$, écrivons $q_\mu(x) = x + e$ avec $|e| \leq \Delta\mu$. La boucle fermée est

$$\dot{x} = ax - k(x + e) = -(k - a)x - ke.$$

Multiplions par $\text{sgn}(x)$ pour obtenir une inégalité sur $|x|$:

$$\frac{d}{dt} |x| \leq -(k - a) |x| + k |e| \leq -(k - a) |x| + k \Delta\mu.$$

Comme $k - a = 3 - 1 = 2 > 0$, le membre de droite est négatif dès que

$$|x| > \frac{k}{k-a} \Delta \mu = \frac{3}{2} \times 0,1 = 0,15 =: r.$$

Donc $|x|$ décroît strictement hors de la boule de rayon r , et $\limsup_{t \rightarrow \infty} |x(t)| \leq r$. Le rayon ultime vaut $r = 0,15$.

Vérification de la cohérence. Il faut $r < M\mu$, sinon la bande ultime sortirait de la portée et l'analyse s'effondrerait : ici $0,15 < 5$, largement. Cette condition s'écrit en général $\frac{k}{k-a} \Delta < M$, soit $\frac{M}{\Delta} > \frac{k}{k-a}$: c'est déjà, sous forme scalaire, la condition en bits du cours.

Régime saturé. Si $x > M\mu = 5$, alors $q_\mu(x) = M\mu$ et $u = -kM\mu = -3 \times 5 = -15$, donc

$$\dot{x} = x - 15.$$

Ce champ est négatif tant que $x < 15$ et positif au-delà. Le point $x = 15$ est donc un équilibre instable qui sépare deux comportements :

- $x_0 < 15$: x décroît, rentre dans la portée, puis converge vers la bande de rayon 0,15 ;
- $x_0 > 15$: $\dot{x} = x - 15 > 0$ et x croît indéfiniment. **Divergence.**

Le point de l'exercice. Le bassin d'attraction est $(-15, 15)$: il est *borné*. On voudrait un résultat *global*, valable pour tout x_0 . Aucun choix de μ figé ne le donne, puisque le bassin est toujours de taille $\sim \frac{k}{a} M\mu$ et qu'agrandir μ dégrade la bande ultime dans la même proportion. C'est précisément ce blocage que la loi hybride lève.

(6) Zoom exponentiel continu. *Énoncé.* On prend $\mu(t) = \mu_0 e^{-\beta t}$, décroissance continue. Que se passe-t-il ?

Régime non saturé. En reprenant le calcul de l'exercice (5) avec $\mu(t)$ variable,

$$\frac{d}{dt} |x| \leq -(k-a) |x| + k\Delta\mu_0 e^{-\beta t}.$$

Posons $\alpha := k - a > 0$. Le lemme de comparaison donne

$$|x(t)| \leq e^{-\alpha t} |x_0| + k\Delta\mu_0 \int_0^t e^{-\alpha(t-s)} e^{-\beta s} ds.$$

Calculons l'intégrale. Si $\beta \neq \alpha$,

$$\int_0^t e^{-\alpha(t-s)} e^{-\beta s} ds = e^{-\alpha t} \int_0^t e^{(\alpha-\beta)s} ds = e^{-\alpha t} \frac{e^{(\alpha-\beta)t} - 1}{\alpha - \beta} = \frac{e^{-\beta t} - e^{-\alpha t}}{\alpha - \beta}.$$

D'où

$$|x(t)| \leq e^{-\alpha t} |x_0| + \frac{k\Delta\mu_0}{\alpha - \beta} (e^{-\beta t} - e^{-\alpha t}),$$

qui tend vers 0 pourvu que $\beta < \alpha = k - a$. Jusque-là, tout va bien.

Pourquoi cela échoue quand même. L'estimation ci-dessus n'est valable que *tant qu'on reste dans la portée*, c'est-à-dire tant que $|x(t)| \leq M\mu(t) = M\mu_0 e^{-\beta t}$. Comparons les deux vitesses :

- la portée décroît exactement comme $e^{-\beta t}$;
- l'état décroît au mieux comme $\max\{e^{-\alpha t}, e^{-\beta t}\}$, et le terme dominant est $e^{-\beta t}$ dès que $\beta < \alpha$.

Le rapport $|x(t)| / (M\mu(t))$ tend donc vers la constante $\frac{k\Delta}{M(\alpha-\beta)}$, qui n'est *pas* nécessairement < 1 . Si β est choisi proche de α , cette constante explose et l'état sort de la portée : on entre en saturation et toute l'analyse s'effondre. Si β est trop petit, la convergence est inutilement lente.

La morale. Une loi de zoom continue ne peut pas être réglée de façon robuste, parce qu'elle exige de connaître à l'avance le rapport entre la vitesse de l'état et celle de la portée. La loi commutée, elle, *mesure* ce rapport par l'événement de capture et n'a besoin d'aucune hypothèse de ce type. C'est la raison technique de la structure par paliers du théorème 2.15.

Section 2.2

(7) Choix de Q . *Énoncé.* Refaire le calcul de l'exemple numérique avec $Q = \text{diag}(1, \theta)$ et discuter.

Mise en place. Avec $A + BK = \begin{pmatrix} 0 & 1 \\ -3 & -4 \end{pmatrix}$, l'équation de Lyapunov $(A + BK)^\top P + P(A + BK) = -Q$ s'écrit, en posant $P = \begin{pmatrix} p_1 & p_2 \\ p_2 & p_3 \end{pmatrix}$ et $Q = \text{diag}(1, \theta)$:

$$\begin{cases} -6p_2 = -1, \\ p_1 - 4p_2 - 3p_3 = 0, \\ 2p_2 - 8p_3 = -\theta. \end{cases}$$

La première ligne donne $p_2 = \frac{1}{6}$. La troisième donne $p_3 = \frac{2p_2 + \theta}{8} = \frac{1}{24} + \frac{\theta}{8}$. La deuxième donne $p_1 = 4p_2 + 3p_3 = \frac{2}{3} + \frac{1}{8} + \frac{3\theta}{8} = \frac{19}{24} + \frac{3\theta}{8}$.

Cas $\theta = 1$ (l'exemple du cours). $p_1 = \frac{19}{24} + \frac{3}{8} = \frac{28}{24} = \frac{7}{6}$, $p_2 = \frac{1}{6}$, $p_3 = \frac{1}{24} + \frac{1}{8} = \frac{4}{24} = \frac{1}{6}$. On retrouve bien $P = \begin{pmatrix} 7/6 & 1/6 \\ 1/6 & 1/6 \end{pmatrix}$, donc $\lambda_{\min}(P) = 0,1396$, $\lambda_{\max}(P) = 1,1937$, $\kappa_P = 2,924$.

Cas $\theta = 10$. $p_1 = \frac{19}{24} + \frac{30}{8} = 4,5417$, $p_2 = 0,1667$, $p_3 = \frac{1}{24} + \frac{10}{8} = 1,2917$. Les valeurs propres de P sont racines de $\lambda^2 - (p_1 + p_3)\lambda + (p_1p_3 - p_2^2) = 0$, soit $\lambda^2 - 5,8333\lambda + 5,8386 = 0$, d'où $\lambda = 1,2688$ et $\lambda = 4,5645$. Donc

$$\kappa_P = \sqrt{4,5645/1,2688} = 1,897,$$

qui est *meilleur* que 2,924. Mais il faut aussi recalculer $\gamma = 2 \|PBK\| / \lambda_{\min}(Q)$. Ici $\lambda_{\min}(Q) = \min\{1, \theta\} = 1$ dans les deux cas, et $PBK = P \begin{pmatrix} 0 \\ 1 \end{pmatrix} \begin{pmatrix} -5 & -4 \end{pmatrix} = \begin{pmatrix} -5p_2 & -4p_2 \\ -5p_3 & -4p_3 \end{pmatrix}$, de norme spectrale $\sqrt{41} \sqrt{p_2^2 + p_3^2}$. Pour $\theta = 1$: $\sqrt{41} \times 0,2357 = 1,509$, donc $\gamma = 3,019$ et $\kappa_P \gamma = 8,83$. Pour $\theta = 10$: $\sqrt{41} \times 1,3024 = 8,340$, donc $\gamma = 16,68$ et $\kappa_P \gamma = 31,6$.

Conclusion. Le produit $\kappa_P \gamma$ passe de 8,83 à 31,6 : on a *perdu* $\log_2(31,6/8,83) = 1,84$ bit. Le gain sur κ_P est largement annulé par la dégradation de γ . **Heuristique** : prendre Q proche de l'identité, ou minimiser numériquement $\kappa_P \gamma$ sur la famille $Q = \text{diag}(1, \theta)$; le script compagnon le fait en trois lignes et trouve un optimum vers $\theta \approx 0,8$.

(8*) Invariance d'échelle. *Énoncé.* Montrer que $\kappa_P \gamma$ est invariant par changement d'unités $x \mapsto cx$.

Calcul. Posons $\tilde{x} = cx$, $c > 0$. Alors $\dot{\tilde{x}} = A\tilde{x} + cBu$, donc $\tilde{B} = cB$, et pour que la commande soit la même il faut $\tilde{K} = K/c$, de sorte que $\tilde{B}\tilde{K} = BK$ et $A + \tilde{B}\tilde{K} = A + BK$ inchangée. À Q fixé, l'équation de Lyapunov est donc inchangée et $\tilde{P} = P$.

Il reste $\tilde{\gamma} = 2 \|\tilde{P}\tilde{B}\tilde{K}\| / \lambda_{\min}(Q) = 2 \|PBK\| / \lambda_{\min}(Q) = \gamma$ et $\tilde{\kappa}_P = \kappa_P$. Le produit est donc invariant. Quant aux paramètres du quantificateur, ils se transforment en $\tilde{M} = M$, $\tilde{\Delta} = \Delta$ et $\tilde{\mu} = c\mu$: c'est la variable de zoom, et elle seule, qui porte les unités.

Pourquoi c'est rassurant. La condition (2.14) porte sur M/Δ et $\kappa_P \gamma$, deux quantités sans dimension. Un nombre de bits ne peut pas dépendre du fait qu'on mesure en mètres ou en millimètres : si c'était le cas, la formule serait fautive. C'est un test de cohérence gratuit et très efficace, qu'on peut appliquer à toutes les conditions du document.

(9) Automate hybride. *Énoncé.* Écrire la loi du théorème 2.15 dans le formalisme (C, F, D, G) de [35] et identifier le temps de séjour minimal.

État étendu. On prend $\xi = (x, \mu, \tau, \ell)$ où $x \in \mathbb{R}^n$ est l'état, $\mu > 0$ la variable de zoom, $\tau \geq 0$ une horloge et $\ell \in \{1, 2\}$ le numéro de phase.

Ensemble et champ de flux.

$$C = \{\xi : \ell = 1, \tau \in [0, \tau_p]\} \cup \{\xi : \ell = 2, \tau \in [0, T]\}, \quad F(\xi) = \begin{pmatrix} Ax + B\mathcal{K}(\xi) \\ 0 \\ 1 \\ 0 \end{pmatrix},$$

avec $\mathcal{K}(\xi) = 0$ si $\ell = 1$ et $\mathcal{K}(\xi) = Kq_\mu(x)$ si $\ell = 2$. La deuxième ligne exprime que μ est *constant entre deux sauts*, la troisième que l'horloge avance à vitesse un.

Ensemble et application de saut.

$$D = \underbrace{\{\xi : \ell = 1, \tau = \tau_p\}}_{D_1} \cup \underbrace{\{\xi : \ell = 1, \mathcal{E}(\xi)\}}_{D_c} \cup \underbrace{\{\xi : \ell = 2, \tau = T\}}_{D_2},$$

où $\mathcal{E}(\xi)$ est l'événement de capture $\|q_\mu(x)\| \leq (\vartheta M - \Delta)\mu$, et

$$G(\xi) = \begin{cases} (x, \Lambda\mu, 0, 1) & \text{sur } D_1 \quad (\text{phase 1 : on élargit}), \\ (x, \mu, 0, 2) & \text{sur } D_c \quad (\text{capture}), \\ (x, \Omega\mu, 0, 2) & \text{sur } D_2 \quad (\text{phase 2 : on affine}). \end{cases}$$

Temps de séjour minimal. Entre deux sauts, l'horloge doit parcourir τ_p (en phase 1) ou T (en phase 2); le seul saut qui puisse se produire à $\tau < \tau_p$ est la capture, et elle ne se produit qu'une seule fois. Le temps de séjour minimal est donc

$$\tau_{\min} = \min\{\tau_p, T\} > 0.$$

Comme $\tau_{\min} > 0$, il ne peut pas y avoir d'accumulation d'instant de saut : le comportement de Zénon est exclu, et la solution hybride est complète. C'est exactement l'argument qu'on retrouvera, sous une forme plus technique, à la section B.2.3 pour la commande événementielle.

Section 2.4

(9bis) Recalculer la ligne $\varepsilon = 3$ de la table. *Données.* $\kappa_P = 2,9240$, $\gamma = 3,0185$, $M = 6$, $\Delta = 0,125$, $\lambda_{\min}(Q) = 1$, $\lambda_{\max}(P) = 1,1937$, $\lambda_{\min}(P) = 0,1396$.

Facteur de contraction.

$$\Omega = \frac{\kappa_P \gamma \Delta (1 + \varepsilon)}{M} = \frac{2,9240 \times 3,0185 \times 0,125 \times 4}{6} = \frac{4,4130}{6} = 0,7355.$$

Taux de décroissance.

$$\alpha = \frac{\varepsilon}{1 + \varepsilon} \cdot \frac{\lambda_{\min}(Q)}{\lambda_{\max}(P)} = \frac{3}{4} \times \frac{1}{1,1937} = 0,6283 \text{ s}^{-1}.$$

Borne exponentielle.

$$T_{\exp} = \frac{2}{\alpha} \ln \frac{1}{\Omega} = \frac{2}{0,6283} \times \ln \frac{1}{0,7355} = 3,1834 \times 0,3072 = 0,978 \text{ s}.$$

Borne de l'article original (2.17). Numérateur :

$$\lambda_{\min}(P)M^2 - \lambda_{\max}(P)\gamma^2\Delta^2(1+\varepsilon)^2 = 0,1396 \times 36 - 1,1937 \times 9,111 \times 0,015625 \times 16 = 5,0256 - 2,7188 = 2,3068.$$

Dénominateur :

$$\lambda_{\min}(Q)\gamma^2\Delta^2\varepsilon(1+\varepsilon) = 1 \times 9,111 \times 0,015625 \times 3 \times 4 = 1,7083.$$

D'où $T_{\text{BL}} = 2,3068/1,7083 = 1,350$ s. On retient $T = \min\{0,978; 1,350\} = 0,978$ s, ce qui confirme la table et la figure 2.3.

Taux garanti. $\ln(1/\Omega)/T = 0,3072/0,978 = 0,314$ s⁻¹.

Marge maximale. La condition (2.14) s'écrit $\Omega < 1$, soit $\kappa_P\gamma\Delta(1+\varepsilon) < M$, donc

$$\varepsilon < \varepsilon_{\max} = \frac{M}{\kappa_P\gamma\Delta} - 1 = \frac{6}{8,8259 \times 0,125} - 1 = \frac{6}{1,1032} - 1 = 5,439 - 1 = 4,439.$$

Section B.6

(10) Pendule inversé. *Énoncé.* Un pendule inversé a pour valeurs propres instables $\lambda_1 = 3,1$ et $\lambda_2 = -3,1$. Quel débit minimal la théorie impose-t-elle? Comparer à une liaison série à 9600 bauds.

Formule. Le théorème du débit minimal donne

$$R_{\min} = \frac{1}{\ln 2} \sum_{\Re\lambda_i > 0} \Re\lambda_i \quad \text{bits par seconde.}$$

Seule $\lambda_1 = 3,1$ est instable, donc

$$R_{\min} = \frac{3,1}{0,6931} = 4,47 \text{ bit/s.}$$

Comparaison. Une liaison série à 9600 bauds transporte, avec un codage 8-N-1 (dix symboles binaires par octet utile), environ $9600/10 \times 8 = 7680$ bit/s. Le rapport est

$$\frac{7680}{4,47} \approx 1720.$$

Interprétation. On dispose d'un facteur de l'ordre de 2000. Autrement dit, **le débit brut n'est presque jamais la contrainte**. Ce qui contraint, en pratique, c'est (i) la *résolution* disponible, car les conditions du cours portent sur M/Δ et non sur le nombre de bits par seconde, et (ii) la *latence*, traitée à la section 3.3. C'est d'ailleurs pourquoi le théorème du débit minimal, bien que fondamental, est relégué en fin d'annexe : il est beau et il est rarement actif.

Section A.1

(11) Instabilité en boucle ouverte. *Énoncé.* Montrer que (3.1) avec $U \equiv 0$, $\bar{g} \equiv 0$ et g constante est instable dès que $gD > 1$.

Réduction à une équation caractéristique. En boucle ouverte, la méthode des caractéristiques donne, pour $t \geq D$,

$$u(x, t) = u(D, t - (D - x)) + \int_x^D g u(D, t - (y - x)) dy.$$

Posons $\eta(t) := u(D, t)$. En évaluant en $x = 0$ et en changeant de variable $s = t - y$, on obtient

$$\eta(t) \text{ satisfait } \eta(t) = g \int_{t-D}^t \eta(s) ds.$$

Recherche de modes. Cherchons $\eta(s) = e^{\sigma s}$:

$$e^{\sigma t} = g \int_{t-D}^t e^{\sigma s} ds = g \frac{e^{\sigma t} - e^{\sigma(t-D)}}{\sigma} = e^{\sigma t} \frac{g(1 - e^{-\sigma D})}{\sigma},$$

d'où l'équation caractéristique

$$\sigma = g(1 - e^{-\sigma D}).$$

Existence d'une racine réelle positive. Posons $\psi(\sigma) := g(1 - e^{-\sigma D}) - \sigma$. Alors :

- $\psi(0) = 0$;
- $\psi'(\sigma) = gDe^{-\sigma D} - 1$, donc $\psi'(0) = gD - 1 > 0$ si $gD > 1$: ψ est strictement croissante en 0^+ , donc $\psi(\sigma) > 0$ pour $\sigma > 0$ petit ;
- $\psi(\sigma) \rightarrow -\infty$ quand $\sigma \rightarrow +\infty$, car $g(1 - e^{-\sigma D}) \rightarrow g$ est borné tandis que $-\sigma \rightarrow -\infty$.

Par le théorème des valeurs intermédiaires, il existe $\sigma^* > 0$ avec $\psi(\sigma^*) = 0$. Le mode $e^{\sigma^* t}$ croît exponentiellement : la boucle ouverte est instable.

Application numérique. Pour $g = 1,25$ et $D = 1$: $gD = 1,25 > 1$. On résout $\sigma = 1,25(1 - e^{-\sigma})$ par itérations de point fixe à partir de $\sigma_0 = 0,5$:

$$\sigma_1 = 1,25(1 - e^{-0,5}) = 0,4919, \quad \sigma_2 = 0,4859, \quad \sigma_3 = 0,4814, \quad \dots$$

La convergence est lente ; en utilisant Newton sur ψ on trouve $\sigma^* \approx 0,4645$. L'état croît donc d'un facteur $e^{0,4645} \approx 1,59$ par seconde en boucle ouverte, ce qui est cohérent avec les transitoires observés sur les figures 3.4.

Section A.2

(12) Vérification directe du noyau. *Énoncé.* Pour $\bar{g} \equiv 0$ et g constante, vérifier que $k(x, y) = -g e^{g(x-y)}$ transporte bien le système sur la cible $w_t = w_x$, $w(D, t) = 0$.

Transformation inverse. On admet que l'inverse de $w = u - \int_x^D k(x, y)u(y) dy$ s'écrit $u = w + \int_x^D \ell(x, y)w(y) dy$ avec, dans ce cas particulier, $\ell(x, y) = -g$ (constante).

Dérivation en temps. En utilisant $w_t = w_x$ sous l'intégrale,

$$u_t = w_t + \int_x^D \ell w_t(y) dy = w_x + \int_x^D \ell w_y(y) dy.$$

Intégrons par parties le second terme, avec ℓ constante :

$$\int_x^D \ell w_y(y) dy = \ell[w(D) - w(x)] = -\ell w(x)$$

puisque $w(D, t) = 0$. Donc $u_t = w_x - \ell w(x) = w_x + g w(x)$.

Dérivation en espace. La règle de Leibniz donne

$$u_x = w_x + \frac{\partial}{\partial x} \int_x^D \ell w(y) dy = w_x - \ell w(x) + \int_x^D \underbrace{\ell_x}_{=0} w(y) dy = w_x + g w(x).$$

Conclusion. On obtient $u_t = u_x$, donc $u_t - u_x = 0$. Il reste à retrouver le terme $g u(D, t)$ de (3.1) : il provient du terme de bord dans la dérivation de la transformation *directe*, et l'on vérifie que c'est bien la condition $k(x, x) = -g$ sur la diagonale qui le produit.

Ce qu'il faut retenir. Le calcul tient en une dizaine de lignes, et *seule* la valeur du noyau sur la diagonale, $k(x, x)$, intervient dans le terme de bord. C'est une constante de ce type de démonstration : la condition diagonale détermine le terme d'ordre zéro, l'EDP du noyau détermine le reste.

Section 3.2

(13) Optimisation de (λ, ν) . *Énoncé.* À M/Δ fixé, maximiser le taux garanti $\frac{1}{T} \ln \frac{1}{\Omega}$ sur les paramètres de norme pondérée (λ, ν) .

Structure du problème. Ω croît avec λ (la condition d’emboîtement se resserre) tandis que T décroît (la contraction est plus rapide) : le produit admet donc un maximum intérieur. Il n’y a pas de forme close, et c’est normal : Ω et T dépendent de λ et ν à travers M_0 , qui est lui-même défini par un problème de point fixe.

Résultat numérique. À 8 bits ($M/\Delta = 256$), $D = 1$, $g = 1,25$, une recherche sur grille donne

$$\lambda^* \approx 4,1, \quad \nu^* \approx 0,16,$$

pour un taux garanti d’environ $0,09 \text{ s}^{-1}$. Le script du §3.2.2.5 refait ce balayage ; il est instructif de tracer la surface, car elle est très plate autour de l’optimum, ce qui signifie que le réglage exact importe peu (bonne nouvelle en pratique).

Recoupement avec la dimension finie. La proposition B.5 donne, dans le cas analogue de la cascade avec retard, $1 + \lambda^* = 3a$. Ici $a \approx 1,7$ donnerait $\lambda^* \approx 4,1$: les deux approches concordent, ce qui est un bon test de cohérence.

(14★) Les deux quantifications à la fois. *Énoncé.* Que devient la condition si l’on quantifie et les mesures et l’entrée ?

Décomposition de la perturbation. Notons U_{nom} la commande nominale calculée sur les mesures exactes, et U_{nom}^q celle calculée sur les mesures quantifiées. La commande réellement appliquée est $q_\mu(U_{\text{nom}}^q)$, donc la perturbation frontière du système cible vaut

$$d = q_\mu(U_{\text{nom}}^q) - U_{\text{nom}} = \underbrace{[q_\mu(U_{\text{nom}}^q) - U_{\text{nom}}^q]}_{\text{quantification de l'entrée}} + \underbrace{[U_{\text{nom}}^q - U_{\text{nom}}]}_{\text{quantification des mesures}}.$$

Majoration terme à terme.

- Premier crochet : c’est directement (P1) appliqué à la valeur scalaire U_{nom}^q , donc $|\cdot| \leq \Delta\mu$.
- Second crochet : par linéarité du contrôleur nominal, $U_{\text{nom}}^q - U_{\text{nom}} = \int_0^D k(D, y)[q_\mu(u(y)) - u(y)] dy$, donc $|\cdot| \leq M_3 \|q_\mu(u) - u\|_\infty \leq M_3 \Delta\mu$, où $M_3 = \int_0^D |k(D, y)| dy$ est précisément la constante de gain de la section A.2.7.

D’où $|d| \leq (1 + M_3)\Delta\mu$, au lieu de $M_3\Delta\mu$ dans le cas « mesures seules ».

Condition modifiée. En reportant dans la condition de petit gain, le facteur M_3 est remplacé par $1 + M_3$:

$$\frac{\Delta}{M} < \frac{M_2}{(1 + M_0) \max\{(1 + \lambda)(1 + M_0)(1 + M_3), 2M_1\}}.$$

Coût en bits. Le surcoût est

$$\log_2 \frac{1 + M_3}{M_3} = \log_2 \left(1 + \frac{1}{M_3} \right).$$

Pour $M_3 = 10$ cela fait 0,14 bit ; pour $M_3 = 100$, 0,014 bit. **Autrement dit, c’est gratuit dès que $M_3 \gg 1$** , ce qui est toujours le cas en pratique puisque M_3 est le gain du contrôleur nominal. La conclusion est contre-intuitive et mérite d’être retenue : quantifier en plus l’entrée ne coûte presque rien une fois qu’on a payé le prix de quantifier les mesures.

Annexe E

Glossaire français-anglais

français	anglais	où
quantificateur	quantizer	§1.7
portée, plage	range, saturation level	M
résolution, pas	resolution, step size	Δ, h
zone morte	dead zone	(P3)
variable de zoom	zoom variable	μ
agrandir / affiner	zoom out / zoom in	phases 1 / 2
temps de séjour	dwel time	T, τ
stabilité pratique	practical stability	§2.2
stabilité entrée-état	input-to-state stability (ISS)	§A.3
gain (ISS)	gain	γ
théorème du petit gain	small-gain theorem	lem. A.17
système cible	target system	§A.2
transformation de Volterra	Volterra (backstepping) trans- formation	(3.35)
noyau	kernel	$k(x, y)$
commande par prédiction	predictor feedback	§3.3
rétroaction d'état	state feedback	$U = KX$
observateur	observer	§B.1
débit minimal	minimum data rate	§B.6
mémoire évanescente	fading memory	lem. A.16
dépassement	overshoot	M_0
bloqueur d'ordre zéro	zero-order hold	§B.3.1
commande événementielle	event-triggered	§B.4
comportement de Zénon	Zeno behaviour	idem

Annexe F

Codes et reproductibilité

F.1 Le dépôt compagnon

Les six programmes qui produisent toutes les figures numériques de ce document sont disponibles à l'adresse

https://github.com/Flo3221/codes_mini_cours_quantification

dans le dossier `codes/`. Ils sont écrits en Python et ne dépendent que de `numpy`, `scipy` et `matplotlib`. Chacun s'exécute en moins d'une minute et écrit ses sorties dans `figs/`.

Organisation du dépôt

Les six fichiers Python sont à la racine du dépôt, avec `run_all.py` et `requirements.txt`. Chaque programme crée au besoin un sous-dossier `figs/` et y dépose ses sorties.

Pour tout régénérer d'un coup :

```
pip install -r requirements.txt && python run_all.py
```

Les six programmes

programme	section	contenu
<code>scalar_quantized_demo.py</code>	1.8	Système scalaire instable sous commande quantifiée, trois valeurs de μ : divergence, bande large, bande étroite.
<code>quantized_state_feedback.py</code>	2.4	Système linéaire de dimension deux, retour d'état quantifié, automate à deux phases, trois scénarios comparés. Imprime aussi les constantes certifiées κ_P , γ , Ω et T .
<code>make_tradeoff_fig.py</code>	2.4	Compromis marge/vitesse : Ω , T et taux garanti en fonction de ε (figure 2.3).
<code>transport_backstepping_demo.py</code>	A	EDP de transport : boucle ouverte instable contre backstepping nominal.
<code>transport_quantized_control.py</code>	3.2	EDP de transport en boucle fermée par backstepping quantifié, schéma décentré amont.
<code>delay_quantized_predictor.py</code>	3.3	Cascade EDO-EDP avec retard d'entrée, prédicteur quantifié, comparaison entre réglage certifié et réglage pratique.

F.2 Les codes MATLAB des articles

Les programmes ci-dessus sont des *réimplémentations* en Python, écrites pour ce cours, volontairement courtes et lisibles. Les codes d'origine, qui accompagnent les articles et qui produisent les figures reproduites dans ce document, sont en MATLAB ou MATLAB/Simulink et sont disponibles séparément. Le lecteur qui veut refaire exactement les figures publiées doit utiliser ceux-là.

dépôt	section	article illustré
<code>quantizerp</code>	3.3	Compensation simultanée d'un retard d'entrée et de la quantification de l'état ou de l'entrée, par prédicteur commuté [26]. C'est le code qui produit les figures 3.8 et 3.9.
<code>QuantizedInput-ETC-2x2</code> <code>HyperbolicPDE</code>	B.2.3	Compensation de la quantification de l'entrée en commande frontière événementielle de systèmes hyperboliques 2×2 [30]. Produit la figure B.1.
<code>QuantizedOutput-ETC-2x2</code> <code>HyperbolicPDE</code>	B.2.4	Compensation de la quantification de la sortie en commande backstepping événementielle [31]. Produit la figure B.2.
<code>quantizerNTDS-RD</code>	B.4	Prédicteurs commutés pour les EDP de réaction-diffusion et les systèmes non linéaires globalement lipschitziens [28].
<code>QuantizerNTDS-Semiglobal</code>	B.4	Stabilisation semi-globale par prédicteur commuté de systèmes non linéaires avec retard d'entrée et quantification [29].

En pratique : lequel prendre ?

Pour *comprendre* le mécanisme et le modifier, prenez les programmes Python de ce cours : ils tiennent en une page chacun et recalculent les constantes à partir des données. Pour *reproduire* un résultat publié, prenez le dépôt MATLAB correspondant : c'est le code qui a servi à faire les figures de l'article, avec ses paramètres exacts.

F.3 Structure commune des programmes

Les fichiers suivent tous le même plan, de sorte qu'on peut passer de l'un à l'autre sans réapprendre.

1. **Données du système.** Les matrices, le retard, le gain nominal. C'est la seule partie à modifier pour traiter un autre exemple.
2. **Calcul automatique des constantes.** Les quantités M_1 , M_2 , M_3 , M_0 , ϑ , Ω et T sont recalculées à partir des données par les formules *exactes* des théorèmes. Il ne faut pas les modifier : si une simulation ne converge pas, c'est le réglage (λ, ν) ou le nombre de bits qu'il faut revoir, pas les formules.
3. **Boucle d'intégration.** Le quantificateur est implémenté comme un vrai escalier saturé, sans régularisation. La logique à deux phases tient en une dizaine de lignes.
4. **Sorties.** Norme de l'état, variable de zoom, commande, et, pour l'EDP, une carte espace-temps.

Attention : trois erreurs d'implémentation fréquentes

- **Condition CFL.** Avec un schéma décentré amont, $\Delta t \leq \Delta x$ est obligatoire. Au-delà, le schéma explose et l'on croit à tort à une instabilité du système.
- **μ qui atteint zéro.** On divise par μ à chaque pas ; il faut un plancher, ne serait-ce que numérique (§B.3.1).
- **Quantifier avant ou après l'intégrale.** $\int k q_\mu(u) dx$ et $q_\mu(\int k u dx)$ ne sont pas le même objet : ce sont les deux problèmes distincts des théorèmes 3.4 et 3.11.

Annexe G

Crédits des illustrations

Ce document utilise trois sortes de figures.

1. **Les figures dessinées pour ce cours** (schémas TikZ, diagrammes, graphes pgfplots). Elles sont dans le fichier source et libres de réutilisation avec le reste du document.
2. **Les figures numériques**, produites par les codes du dépôt compagnon (annexe F). Chacune est reproductible en une commande ; le nom du script est donné en légende.
3. **Les illustrations empruntées**, listées ci-dessous. Chacune est déjà créditée dans sa légende ; cette table sert de récapitulatif et donne l'adresse exacte de la source.

G.1 Photographies et schémas sous licence Creative Commons

Figure	Sujet, auteur	Licence	Source
1.1	Thermostat Honeywell T87, par l'utilisateur Flickr <i>mid-nightcomm</i>	CC BY 2.0	Wikimedia Commons
1.2	Quadrirrotor en vol, par <i>Project Kei</i>	CC BY-SA 4.0	Wikimedia Commons
1.3(a)	Électrovanne, par <i>Sparpo</i>	CC BY-SA 4.0	Wikimedia Commons
1.3(b)	Levier de boîte manuelle, par <i>Winkelbohrer</i>	CC BY-SA 2.0	Wikimedia Commons
1.4(a)	Trafic routier, par Ken Lund	CC BY-SA 2.0	Wikimedia Commons
1.4(b)	Canal d'irrigation, par Mike Faherty	CC BY-SA 2.0	Wikimedia Commons
1.4(c)	Plateforme de forage, par <i>Liberaler Humanist</i>	CC BY-SA 3.0	Wikimedia Commons
1.9	Erreur de quantification, par Gregory Maxwell	CC BY 3.0	Wikimedia Commons
1.6	Série « Focal length » (24, 70, 1000 mm), par Armin Kübelbeck	CC BY-SA 3.0	Wikimedia Commons

G.2 Figures reprises d'articles

Figure	Origine	Statut
1.11	[26, Fig. 1]	Préprint d'auteur, arXiv:2404.11194
3.3, 3.4, 3.5	[24, Fig. 2 à 5]	Creative Commons Attribution 4.0 International ; dépôt institutionnel de l'Université technique de Crète, dias.library.tuc.gr/view/88732
3.8, 3.9	[26, Fig. 2 à 6]	Préprint d'auteur, arXiv:2404.11194
B.1	[30, Fig. 1]	Préprint d'auteur, hal-05669800
B.2	[31, Fig. 6]	Préprint d'auteur, hal-05570991

Remarque G.1 (sur la licence *share-alike*). Plusieurs images ci-dessus sont sous licence CC BY-SA. Elles sont reproduites ici sans modification, avec mention de l'auteur et de la licence, ce que cette licence autorise. Quiconque en produirait une *version dérivée* devrait la rediffuser sous la même licence ; ce n'est pas le cas d'une simple inclusion dans un document plus vaste.

Bibliographie

- [1] D. F. Delchamps, *Extracting state information from a quantized output record*, Systems & Control Letters, vol. 13, pp. 365 à 372, 1989.
- [2] D. F. Delchamps, *Stabilizing a linear system with quantized state feedback*, IEEE Transactions on Automatic Control, vol. 35, no. 8, pp. 916 à 924, 1990.
- [3] W. S. Wong and R. W. Brockett, *Systems with finite communication bandwidth constraints II : stabilization with limited information feedback*, IEEE Transactions on Automatic Control, vol. 44, no. 5, pp. 1049 à 1053, 1999.
- [4] R. W. Brockett and D. Liberzon, *Quantized feedback stabilization of linear systems*, IEEE Transactions on Automatic Control, vol. 45, no. 7, pp. 1279 à 1289, 2000.
- [5] N. Elia and S. K. Mitter, *Stabilization of linear systems with limited information*, IEEE Transactions on Automatic Control, vol. 46, no. 9, pp. 1384 à 1400, 2001.
- [6] D. Liberzon, *Hybrid feedback stabilization of systems with quantized signals*, Automatica, vol. 39, no. 9, pp. 1543 à 1554, 2003.
- [7] S. Tatikonda and S. Mitter, *Control under communication constraints*, IEEE Transactions on Automatic Control, vol. 49, no. 7, pp. 1056 à 1068, 2004.
- [8] M. Fu and L. Xie, *The sector bound approach to quantized feedback control*, IEEE Transactions on Automatic Control, vol. 50, no. 11, pp. 1698 à 1711, 2005.
- [9] F. Ceragioli and C. De Persis, *Discontinuous stabilization of nonlinear systems : quantized and switching controls*, Systems & Control Letters, vol. 56, no. 7 à 8, pp. 461 à 473, 2007.
- [10] G. N. Nair, F. Fagnani, S. Zampieri and R. J. Evans, *Feedback control under data rate constraints : an overview*, Proceedings of the IEEE, vol. 95, no. 1, pp. 108 à 137, 2007.
- [11] G. N. Nair and R. J. Evans, *Stabilizability of stochastic linear systems with finite feedback data rates*, SIAM Journal on Control and Optimization, vol. 43, no. 2, pp. 413 à 436, 2004.
- [12] C.-C. Huang, B. Amini and R. R. Bitmead, *Predictive coding and control*, IEEE Transactions on Control of Network Systems, vol. 6, no. 2, pp. 906 à 918, 2019.
- [13] S. Tarbouriech and F. Gouaisbaut, *Control design for quantized linear systems with saturations*, IEEE Transactions on Automatic Control, vol. 57, no. 7, pp. 1883 à 1889, 2012.
- [14] F. Ferrante, F. Gouaisbaut and S. Tarbouriech, *On sensor quantization in linear control systems : Krasovskii solutions meet semidefinite programming*, IMA Journal of Mathematical Control and Information, vol. 37, no. 1, pp. 395 à 417, 2020.

Commande frontière, backstepping, retard

- [15] M. Krstic and A. Smyshlyaev, *Boundary Control of PDEs : A Course on Backstepping Designs*, SIAM, Philadelphia, 2008.
- [16] M. Krstic and A. Smyshlyaev, *Backstepping boundary control for first-order hyperbolic PDEs and application to systems with actuator and sensor delays*, Systems & Control Letters, vol. 57, pp. 750 à 758, 2008.

- [17] M. Krstic, *Delay Compensation for Nonlinear, Adaptive, and PDE Systems*, Birkhäuser, Boston, 2009.
- [18] I. Karafyllis and M. Krstic, *On the relation of delay equations to first-order hyperbolic partial differential equations*, ESAIM : Control, Optimisation and Calculus of Variations, vol. 20, pp. 894 à 923, 2014.
- [19] G. Bastin and J.-M. Coron, *Stability and Boundary Stabilization of 1-D Hyperbolic Systems*, Birkhäuser, 2016.
- [20] I. Karafyllis and M. Krstic, *Predictor Feedback for Delay Systems : Implementations and Approximations*, Birkhäuser, Cham, 2017.
- [21] I. Karafyllis and M. Krstic, *Input-to-State Stability for PDEs*, Springer, Cham, 2019.

Quantification pour les EDP et les systèmes à retard

- [22] A. Tanwani, C. Prieur and S. Tarbouriech, *Disturbance-to-state stabilization and quantized control for linear hyperbolic systems*, arXiv preprint arXiv :1703.00302, 2017. Version courte : *Input-to-state stabilization in H^1 -norm for boundary controlled linear hyperbolic PDEs with application to quantized control*, Proc. 55th IEEE CDC, Las Vegas, pp. 3112 à 3117, 2016.
- [23] N. Espitia, A. Tanwani and S. Tarbouriech, *Stabilization of boundary controlled hyperbolic PDEs via Lyapunov-based event-triggered sampling and quantization*, Proc. 56th IEEE Conference on Decision and Control, Melbourne, pp. 1266 à 1271, 2017.
- [24] N. Bekiaris-Liberis, *Hybrid boundary stabilization of linear first-order hyperbolic PDEs despite almost quantized measurements and control input*, Systems & Control Letters, vol. 146, 104809, 2020. Version en accès libre sous licence CC BY 4.0 : <https://dias.library.tuc.gr/view/88732>.
- [25] S. M. Schlanbusch, O.-M. Aamo and J. Zhou, *Attitude control of a 2-DOF helicopter system with input quantization and delay*, IECON 2022, 48th Annual Conference of the IEEE Industrial Electronics Society, Brussels, pp. 1 à 6, 2022.
- [26] F. Koudohode and N. Bekiaris-Liberis, *Simultaneous compensation of input delay and state/input quantization for linear systems via switched predictor feedback*, Systems & Control Letters, vol. 192, 105912, 2024; préprint <https://arxiv.org/abs/2404.11194>; code <https://github.com/Flo3221/quantizerp>.
- [27] F. Koudohode, N. Espitia and M. Krstic, *Event-triggered boundary control of an unstable reaction-diffusion PDE with input delay*, Systems & Control Letters, vol. 186, 105775, 2024.
- [28] F. Koudohode and N. Bekiaris-Liberis, *Switched predictor feedbacks for reaction-diffusion PDEs and globally Lipschitz non-linear ODE systems subject to almost state and input quantization*, IMA Journal of Mathematical Control and Information, vol. 42, no. 4, pp. 1 à 39, 2025; code <https://github.com/Flo3221/quantizerNTDS-RD>.
- [29] F. Koudohode and N. Bekiaris-Liberis, *Semiglobal switched predictor-feedback stabilization of nonlinear systems with input delay and state/input quantization*, IEEE Transactions on Automatic Control, à paraître, 2026; code <https://github.com/Flo3221/QuantizerNTDS-Semiglobal>.
- [30] F. Koudohode, N. Espitia, J.-P. Humaloja and N. Bekiaris-Liberis, *Compensation of input quantization in event-triggered boundary control of 2×2 hyperbolic systems*, préprint, 2026; soumis à *Systems & Control Letters* (numéro spécial en l'honneur d'E. D. Sontag). HAL : <https://hal.science/hal-05669800>; code <https://github.com/Flo3221/QuantizedInput-ETC-2x2HyperbolicPDE>.
- [31] F. Koudohode, N. Espitia, J.-P. Humaloja and N. Bekiaris-Liberis, *Output quantization compensation in event-triggered backstepping control of 2×2 hyperbolic systems*, préprint,

2026; soumis à *Automatica*. HAL : <https://hal.science/hal-05570991>; code <https://github.com/Flo3221/QuantizedOutput-ETC-2x2HyperbolicPDE>.

Outils généraux

- [32] E. D. Sontag, *Smooth stabilization implies coprime factorization*, IEEE Transactions on Automatic Control, vol. 34, no. 4, pp. 435 à 443, 1989.
- [33] E. D. Sontag and Y. Wang, *On characterizations of the input-to-state stability property*, Systems & Control Letters, vol. 24, pp. 351 à 359, 1995.
- [34] H. K. Khalil, *Nonlinear Systems*, 3rd ed., Prentice Hall, 2002.
- [35] R. Goebel, R. G. Sanfelice and A. R. Teel, *Hybrid Dynamical Systems : Modeling, Stability, and Robustness*, Princeton University Press, 2012.
- [36] K. J. Åström and B. Wittenmark, *Computer-Controlled Systems : Theory and Design*, 3rd ed., Prentice Hall, 1997.

Quantification hors de l'automatique

- [37] R. M. Gray and D. L. Neuhoff, *Quantization*, IEEE Transactions on Information Theory, vol. 44, no. 6, pp. 2325 à 2383, 1998.
- [38] A. V. Oppenheim, R. W. Schaffer and J. R. Buck, *Discrete-Time Signal Processing*, 2nd ed., Prentice Hall, Upper Saddle River, 1999; §4.8 « Quantization ». (3rd ed., Pearson, 2010.)
- [39] IEEE, *IEEE Standard for Floating-Point Arithmetic*, IEEE Std 754-2019 (révision de IEEE Std 754-2008), pp. 1 à 84, 2019.
- [40] A. Gholami, S. Kim, Z. Dong, Z. Yao, M. W. Mahoney and K. Keutzer, *A survey of quantization methods for efficient neural network inference*, arXiv :2103.13630, 2021; version publiée dans *Low-Power Computer Vision*, Chapman and Hall/CRC, 2022.